



دانشگاه صنعتی شریف
دانشکده‌ی مهندسی هوافضا

پروژه کارشناسی ارشد
مهندسی فضا

عنوان:

هدایت یادگیری تقویتی مقاوم مبتنی بر بازی دیفرانسیلی در محیط‌های پویای چندجسمی با پیشران کم

نگارش:

علی بنی اسد

استاد راهنما:

دکتر هادی نوبهاری

شهریور ۱۴۰۴

سلام الله عليه

به نام خدا

دانشگاه صنعتی شریف

دانشکده‌ی مهندسی هوافضا

پروژه کارشناسی ارشد

عنوان:

هدایت یادگیری تقویتی مقاوم مبتنی بر بازی دیفرانسیلی در محیط‌های پویای چندجسمی با
پیشران کم

نگارش: علی بنی اسد

کمیته‌ی ممتحنین

استاد راهنما: دکتر هادی نوبهاری امضاء:

استاد ممتحن: دکتر سیدعلی امامی خوانساری امضاء:

استاد ممتحن: دکتر علیرضا باصحبت نوین زاده امضاء:

تاریخ:

سپاس

از استاد بزرگوارم، جناب آقای دکتر هادی نوبهاری، به پاس زحمات فراوانی که برای این شاگرد کوچکشان کشیدند، صمیمانه سپاسگزارم. در عرصه‌های گوناگون علمی، اخلاقی و انسانی از ایشان بسیار آموختم و بی‌گمان توفیق شاگردی ایشان برای من لطفی الهی بوده است که به آن می‌بالم. بخش چشمگیری از موفقیت‌هایم در دوره‌های کارشناسی و کارشناسی‌ارشد را مرهون راهنمایی‌ها و همراهی‌های این بزرگوار هستم. برای ایشان و خانواده‌ی گرامیشان سلامتی، عزت و سربلندی روزافزون در همه‌ی مراحل زندگی آرزو می‌کنم و امیدوارم بتوانم دینِ شاگردی را به‌خوبی ادا کنم. همچنین، از جناب آقای مهندس میثم علی‌زاد که نظرات ارزشمند او همواره راهگشای مشکلات بنده بود، تشکر می‌کنم. از پدر دلسوزم ممنونم که در انجام این پروژه مرا یاری نمود. در نهایت در کمال تواضع، با تمام وجود بر دستان مادرم بوسه می‌زنم که اگر حمایت بی‌دریغش، نگاه مهربانش و دستان گرمش نبود برگ برگ این دست نوشته و پروژه وجود نداشت.

چکیده

در این پژوهش، یک چارچوب هدایت مقاوم برای فضاییهای کم‌پیشران در محیط‌های دینامیکی چندجسمی (سامانه سه جسمی زمین-ماه) ارائه شده است. مسئله به صورت بازی دیفرانسیلی مجموع صفر بین عامل هدایت (فضایما) و عامل مزاحم (عدم قطعیت‌های محیطی) فرمول‌بندی شده و با رویکرد آموزش متمرکز و اجرای توزیع شده پیاده‌سازی گردیده است. در این راستا، چهار الگوریتم یادگیری تقویتی پیوسته SAC، TD3، DDPG و PPO به نسخه‌های چندعاملی مجموع صفر گسترش یافته‌اند (MA-SAC، MA-TD3، MA-DDPG و MA-PPO) و جریان آموزش آن‌ها همراه با ساختار شبکه‌ها در قالب اطلاعات کامل تشریح شده است. ارزیابی الگوریتم‌ها در سناریوهای متنوع عدم قطعیت شامل شرایط اولیه تصادفی، اغتشاش عملگر، نویز حسگر، تأخیر زمانی و عدم تطابق مدل روی مسیر مدار لیاپانوف زمین-ماه انجام گرفت. نتایج به وضوح نشان می‌دهد که نسخه‌های مجموع صفر در تمامی معیارهای ارزیابی بر نسخه‌های تک‌عاملی برتری دارند. به ویژه الگوریتم MA-TD3 با حفظ پایداری سیستم، کمترین انحراف مسیر و مصرف سوخت بهینه را حتی در سخت‌ترین سناریوهای آزمون از خود نشان داد. در نهایت، چارچوب پیشنهادی نشان می‌دهد که یادگیری تقویتی چندعاملی مبتنی بر بازی دیفرانسیلی مجموع صفر می‌تواند بدون نیاز به مدل‌سازی دقیق، هدایت تطبیقی و مقاوم فضاییهای کم‌پیشران را در نواحی ناپایدار سیستم‌های سه جسمی تضمین کند.

کلیدواژه‌ها: یادگیری تقویتی عمیق، بازی دیفرانسیلی، سامانه‌های چندعاملی، هدایت کم‌پیشران، بازی مجموع صفر، مسئله محدود سه جسمی، کنترل مقاوم.

فهرست مطالب

۱	مقدمه	۱
۱-۱	انگیزه پژوهش	۱
۲-۱	تعریف مسئله	۲
۳-۱	یادگیری تقویتی	۳
۴-۱	یادگیری تقویتی چندعاملی	۴
۵-۱	ارزش افزوده و نوآوری های پژوهش	۴
۶-۱	ساختار گزارش	۵
۲	پیشینه پژوهش	۶
۱-۲	ماموریت های بین مداری	۶
۲-۲	یادگیری تقویتی	۸
۳-۲	پیشینه ی پژوهش یادگیری تقویتی چندعاملی	۹
۴-۲	جمع بندی و گپ پژوهشی	۱۱
۳	مدل سازی محیط یادگیری سه جسمی	۱۳
۱-۳	مسئله ی سه جسمی محدود دایره ای (CRTBP)	۱۳
۱-۱-۳	لاگرانژ و معادلات حرکت	۱۵
۲-۳	نقاط تعادل لاگرانژ	۱۵

۱۹	۴ یادگیری تقویتی
۱۹	۱-۴ مفاهیم اولیه
۲۰	۱-۱-۴ حالت و مشاهدات
۲۰	۲-۱-۴ فضای عمل
۲۰	۳-۱-۴ سیاست
۲۱	۴-۱-۴ مسیر
۲۱	۵-۱-۴ تابع پاداش و برگشت
۲۲	۶-۱-۴ ارزش در یادگیری تقویتی
۲۳	۷-۱-۴ معادلات بلمن
۲۴	۸-۱-۴ تابع مزیت
۲۵	۲-۴ عامل گرادیان سیاست عمیق قطعی
۲۵	۱-۲-۴ یادگیری Q در DDPG
۲۷	۲-۲-۴ سیاست در DDPG
۲۷	۳-۲-۴ اکتشاف و بهره‌برداری در DDPG
۲۷	۴-۲-۴ شبکه‌د DDPG
۲۹	۳-۴ عامل گرادیان سیاست عمیق قطعی تاخیری دوگانه
۳۰	۱-۳-۴ اکتشاف و بهره‌برداری در TD3
۳۰	۲-۳-۴ شبکه‌د TD3
۳۲	۴-۴ عامل عملگر نقاد نرم
۳۲	۱-۴-۴ یادگیری تقویتی تنظیم‌شده با آنتروپی
۳۲	۲-۴-۴ سیاست در SAC
۳۳	۳-۴-۴ تابع ارزش در SAC
۳۳	۴-۴-۴ تابع Q در SAC
۳۳	۵-۴-۴ معادله بلمن در SAC

۳۴	یادگیری Q ۶-۴-۴
۳۴	سیاست در SAC ۷-۴-۴
۳۵	اکتشاف و بهره‌برداری در SAC ۸-۴-۴
۳۶	شبکه‌کد SAC ۹-۴-۴
۳۷	عامل بهینه‌سازی سیاست مجاور ۵-۴
۳۸	سیاست در الگوریتم PPO ۱-۵-۴
۳۹	اکتشاف و بهره‌برداری در PPO ۲-۵-۴
۳۹	شبکه‌کد PPO ۳-۵-۴
۴۱	شبیه‌سازی عامل در محیط سه جسمی ۵
۴۱	طراحی عامل ۱-۵
۴۱	فضای حالت ۱-۱-۵
۴۲	فضای عمل ۲-۱-۵
۴۴	تابع پاداش ۳-۱-۵
۴۵	شبیه‌سازی عامل ۲-۵
۴۵	پارامترهای یادگیری و منطق انتخاب الگوریتم‌ها ۱-۲-۵
۴۹	فرآیند آموزش ۲-۲-۵
۵۱	یادگیری تقویتی چندعاملی ۶
۵۱	تعاریف و مفاهیم اساسی ۱-۶
۵۳	نظریه بازی‌ها ۲-۶
۵۳	تعادل نش ۱-۲-۶
۵۴	بازی مجموع صفر ۲-۲-۶
۵۶	چالش‌های استایی در یادگیری تقویتی تک‌عاملی ۳-۲-۶
۵۷	ضرورت استفاده از یادگیری تقویتی چندعاملی ۴-۲-۶

۵۸	۳-۶	گرادیان سیاست عمیق قطعی چندعاملی
۵۹	۱-۳-۶	معماری MA-DDPG در بازی‌های مجموع‌صفر
۵۹	۲-۳-۶	آموزش MA-DDPG در بازی‌های مجموع‌صفر
۶۰	۳-۳-۶	اکتشاف در MA-DDPG
۶۰	۴-۳-۶	شبکه‌کد MA-DDPG برای بازی‌های دوعاملی مجموع‌صفر
۶۲	۵-۳-۶	مزایای MA-DDPG در بازی‌های مجموع‌صفر
۶۲	۴-۶	عامل گرادیان سیاست عمیق قطعی تاخیری دوگانه چندعاملی
۶۲	۱-۴-۶	چالش‌های یادگیری تقویتی در محیط‌های چندعاملی و راه‌حل MA-TD3
۶۳	۲-۴-۶	معماری MA-TD3 در بازی‌های مجموع‌صفر
۶۳	۳-۴-۶	آموزش MA-TD3
۶۴	۴-۴-۶	اکتشاف در MA-TD3
۶۴	۵-۴-۶	شبکه‌کد MA-TD3 برای بازی‌های چندعاملی مجموع‌صفر
۶۶	۶-۴-۶	مزایای MA-TD3 در بازی‌های مجموع‌صفر
۶۶	۵-۶	عامل عملگر نقاد نرم چندعاملی
۶۶	۱-۵-۶	چالش‌های یادگیری تقویتی در محیط‌های چندعاملی و راه‌حل MA-SAC
۶۷	۲-۵-۶	معماری MA-SAC در بازی‌های مجموع‌صفر
۶۷	۳-۵-۶	آموزش MA-SAC
۶۹	۴-۵-۶	اکتشاف در MA-SAC
۶۹	۵-۵-۶	شبکه‌کد MA-SAC برای بازی‌های چندعاملی مجموع‌صفر
۷۱	۶-۵-۶	مزایای MA-SAC در بازی‌های مجموع‌صفر
۷۱	۶-۶	عامل بهینه‌سازی سیاست مجاور چندعاملی
۷۱	۱-۶-۶	چالش‌های یادگیری تقویتی در محیط‌های چندعاملی و راه‌حل MA-PPO
۷۲	۲-۶-۶	معماری MA-PPO در بازی‌های مجموع‌صفر
۷۲	۳-۶-۶	آموزش MA-PPO

۷۴	اکتشاف در MA-PPO ۴-۶-۶
۷۴	شبکه MA-PPO برای بازی‌های چندعاملی مجموع صفر ۵-۶-۶
۷۵	مزایای MA-PPO در بازی‌های مجموع صفر ۶-۶-۶

۷ ارزیابی و نتایج یادگیری ۷۷

۷۷	ارزیابی مقاومت الگوریتم‌ها ۱-۷
۷۸	سناریوهای ارزیابی مقاومت ۱-۱-۷
۷۹	الگوریتم DDPG ۲-۷
۷۹	مسیر طی شده ۱-۲-۷
۷۹	مسیر و فرمان پیشران ۲-۲-۷
۸۰	توزیع پاداش تجمعی ۳-۲-۷
۸۱	مقایسه عددی ۴-۲-۷
۸۲	الگوریتم TD3 ۳-۷
۸۲	مسیر طی شده ۱-۳-۷
۸۳	مسیر و فرمان پیشران ۲-۳-۷
۸۳	توزیع پاداش تجمعی ۳-۳-۷
۸۴	مقایسه عددی ۴-۳-۷
۸۶	الگوریتم SAC ۴-۷
۸۶	مسیر طی شده ۱-۴-۷
۸۷	مسیر و فرمان پیشران ۲-۴-۷
۸۸	توزیع پاداش تجمعی ۳-۴-۷
۸۸	مقایسه عددی ۴-۴-۷
۸۹	الگوریتم PPO ۵-۷
۹۰	مسیر طی شده ۱-۵-۷
۹۰	مسیر و فرمان پیشران ۲-۵-۷

۹۱	۳-۵-۷ توزیع پاداش تجمعی
۹۲	۴-۵-۷ مقایسه عددی
۹۳	۶-۷ نتایج نسخه استاندارد
۹۳	۱-۶-۷ توزیع پاداش تجمعی
۹۴	۲-۶-۷ مقایسه عددی
۹۵	۷-۷ نتایج نسخه چندعاملی
۹۵	۱-۷-۷ توزیع پاداش تجمعی
۹۶	۲-۷-۷ مقایسه عددی
۹۷		۸ نتیجه‌گیری و پیشنهادها
۹۷	۱-۸ جمع‌بندی دستاوردها
۹۸	۲-۸ محدودیت سناریوهای آزمون
۹۸	۳-۸ پیشنهادهایی برای کارهای آینده

فهرست جداول

۱-۳	مقادیر عددی برای مسئله سه جسمی محدود (سامانه زمین-ماه)	۱۴
۲-۳	مقادیر عددی نقاط لاگرانژ برای مسئله سه جسمی محدود سیستم زمین-ماه	۱۷
۱-۵	قابلیت های بی بعد پیشران کم تراست فضاپیمای مختلف در سامانه ی زمین-ماه [۵۵].	۴۳
۲-۵	جدول پارامترها و مقادیر پیش فرض الگوریتم DDPG [۶۲]	۴۶
۳-۵	جدول پارامترها و مقادیر پیش فرض الگوریتم TD3 [۶۲]	۴۶
۴-۵	جدول پارامترها و مقادیر پیش فرض الگوریتم SAC [۶۲]	۴۷
۵-۵	جدول پارامترها و مقادیر پیش فرض الگوریتم PPO [۶۲]	۴۷
۱-۷	مقایسه عملکرد DDPG و MA-DDPG در سناریوهای مختلف مقاومت	۸۱
۲-۷	مقایسه عملکرد TD3 و MA-TD3 در سناریوهای مختلف مقاومت	۸۵
۳-۷	مقایسه عملکرد SAC و MA-SAC در سناریوهای مختلف مقاومت	۸۹
۴-۷	مقایسه عملکرد PPO و MA-PPO در سناریوهای مختلف مقاومت	۹۲
۵-۷	مقایسه الگوریتم های چندعاملی در سناریوهای مختلف مقاومت	۹۴
۶-۷	مقایسه الگوریتم های چندعاملی در سناریوهای مختلف مقاومت	۹۶

فهرست تصاویر

۱-۳	هندسه‌ی مسئله‌ی سه‌جسمی محدود در چارچوب چرخان	۱۴
۲-۳	نقاط لاگرانژ در سامانه‌ی زمین-ماه	۱۶
۱-۴	حلقه تعامل عامل و محیط	۲۰
۱-۵	ساختار شبکه عصبی سیاست	۴۸
۲-۵	ساختار شبکه عصبی نقاد	۴۸
۱-۶	حلقه تعامل عامل‌های یادگیری تقویتی چند عاملی با محیط	۵۳
۱-۷	مسیر طی‌شده فضایی با DDPG استاندارد و نسخه بازی مجموع صفر MA-DDPG	۷۹
۲-۷	مسیر و فرمان پیشران فضایی در DDPG استاندارد و نسخه بازی مجموع صفر MA-DDPG	۸۰
۳-۷	مقایسه توزیع پاداش تجمعی در سناریوهای مختلف برای DDPG و MA-DDPG	۸۰
۴-۷	مسیر طی‌شده فضایی با TD3 استاندارد و نسخه بازی مجموع صفر MA-TD3	۸۲
۵-۷	مسیر و فرمان پیشران فضایی در TD3 استاندارد و نسخه بازی مجموع صفر MA-TD3	۸۳
۶-۷	مقایسه توزیع پاداش تجمعی در سناریوهای مختلف برای TD3 و MA-TD3	۸۴
۷-۷	مسیر طی‌شده فضایی با SAC استاندارد و نسخه بازی مجموع صفر MA-SAC	۸۶
۸-۷	مسیر و فرمان پیشران فضایی در SAC استاندارد و نسخه بازی مجموع صفر MA-SAC	۸۷
۹-۷	مقایسه توزیع پاداش تجمعی در سناریوهای مختلف برای SAC و MA-SAC	۸۸
۱۰-۷	مسیر طی‌شده فضایی با PPO استاندارد و نسخه بازی مجموع صفر MA-PPO	۹۰

- ۷-۱۱ مسیر و فرمان پیشران فضاپیما در PPO استاندارد و نسخه بازی مجموع صفر MA-PPO. ۹۰
- ۷-۱۲ مقایسه توزیع پاداش تجمعی برای PPO و MA-PPO در سناریوهای مختلف. ۹۱
- ۷-۱۳ مقایسه توزیع پاداش تجمعی برای نسخه‌های تک‌عاملی در سناریوهای مختلف. ۹۳
- ۷-۱۴ مقایسه توزیع پاداش تجمعی برای الگوریتم‌ها در حالت چندعاملی در سناریوهای مختلف. . ۹۵

فهرست الگوریتم‌ها

۲۸	گرایان سیاست عمیق قطعی	۱
۳۱	عامل گرایان سیاست عمیق قطعی تاخیری دوگانه	۲
۳۶	عامل عملگرد نقاد نرم	۳
۴۰	بهینه‌سازی سیاست مجاور (PPO-Clip)	۴
۶۱	عامل گرایان سیاست عمیق قطعی چندعاملی	۵
۶۵	عامل گرایان سیاست عمیق قطعی تاخیری دوگانه چندعاملی	۶
۷۰	عامل عملگرد نقاد نرم چندعاملی	۷
۷۵	عامل بهینه‌سازی سیاست مجاور چندعاملی	۸

فصل ۱

مقدمه

در سال‌های آغازین عصر فضا، فرایند هدایت فضاپیماها عمدتاً بر مبنای دینامیک کلاسیک و کنترل خطی استوار بوده است. با این حال، پیچیدگی روزافزون مأموریت‌های کنونی مانند سفرهای میان‌سیاره‌ای با پیشران‌کم و شبکه‌های انبوه ماهواره‌ای در مدار زمین موجب دوچندان شدن ضرورت بهره‌گیری از روش‌های هوشمند و تطبیق‌پذیر شده است. در ادامه، انگیزه‌ی پژوهش در بخش ۱-۱ و تعریف دقیق مسئله در بخش ۲-۱ آمده است. سپس، مروری کوتاه بر مبنای یادگیری تقویتی و نسخه‌ی چندعاملی آن در بخش‌های ۳-۱ و ۴-۱ ارائه شده و در نهایت، ساختار کل گزارش در بخش ۶-۱ تشریح شده است.

۱-۱ انگیزه پژوهش

در دو دهه‌ی اخیر، به دلیل کوچک‌سازی سامانه‌ها، توسعه‌ی الکترونیک مقرون‌به‌صرفه و افزایش ظرفیت‌های پرتاب، تحولات بنیادینی در مأموریت‌های فضایی تجربه شده است. از پروژه‌های علمی بین‌سیاره‌ای تا منظومه‌های انبوه ماهواره‌ای در مدارهای پایین زمین، مواجهه با چالش فراگیر هدایت بهینه در حضور عدم قطعیت‌ها به طور گسترده گزارش شده است. در مسیرهای فرا-قمری^۱ و به طور خاص در ناحیه‌های ناپایدار نقاط لاگرانژ در چارچوب مسئله‌ی سه جسمی کروی محدود دایروی^۲، طراحی سامانه‌ی کنترل مستلزم تضمین هم‌زمان پایداری ایستا و بهره‌وری سوخت با پیشران‌کم^۳ است.

هم‌راستا با این تحولات، ظهور و گسترش الگوریتم‌های یادگیری تقویتی عمیق^۴ امکانات نوینی برای طراحی

¹Trans-lunar

²Circular Restricted Three-Body Problem (CRTBP)

³Low-thrust

⁴Deep Reinforcement Learning (DRL)

کنترل‌کننده‌های تطبیقی فراهم آورده است؛ با این حال، غالباً رویکردهای رایج بر سناریوهای تک‌عاملی و اتکا به مدل‌های دینامیکی دقیق استوار شده‌اند. غیاب یک راهبرد مقاوم در برابر اغتشاشات مدل و تغییرات محیطی—از جمله خطای تراست پیشران و تأخیر حسگر—به ایجاد فاصله‌ی معنادار میان عملکرد واقعی و پیش‌بینی‌های شبیه‌سازی ایده‌آل منجر شده‌است. در این پژوهش، این شکاف با بهره‌گیری از چارچوب یادگیری تقویتی چندعاملی مقاوم پُر می‌شود و اطمینان هدایت پیشران‌کم در CRTBP ارتقا داده می‌شود. در ادامه، تعریف دقیق مسئله و سپس اهداف و نوآوری‌های پژوهش ارائه می‌شود.

۱-۲ تعریف مسئله

در سال‌های اخیر، پیشرفت‌های فناوری در کنترل پرواز، پردازش و هوش مصنوعی به گسترش کاربرد فضاپیماهای پیشران‌کم در منظومه‌ی زمین-ماه انجامیده است؛ از تعقیب و انتقال مداری تا استقرار و نگهداری. روش‌های هدایت بهینه‌ی کلاسیک، هرچند قدرتمند، عموماً به ساده‌سازی‌های بسیار، منابع محاسباتی زیاد و شرایط اولیه‌ی مناسب متکی بوده‌اند؛ در مقابل، بخشی از این محدودیت‌ها با الگوریتم‌های مبتنی بر یادگیری تقویتی و تکیه بر تعامل و امکان محاسبات درون‌برد^۵ برطرف می‌شود.

هدف، طراحی سیاست کنترلی برای فضاپیمایی با جرم m در میدان گرانش سامانه‌ی زمین-ماه (مدل دوبعدی در چارچوب چرخان) است. ویژگی‌ها به‌اختصار:

- **پویایی‌ها:** معادلات حرکت در چارچوب مرجع چرخان به‌صورت $\dot{x} = f(x) + g(x)a$ با $x = [x, y, \dot{x}, \dot{y}]^T$ و کنترل پیوسته‌ی $a \in \mathcal{A}$ تعریف می‌شود، به‌طوری‌که کران $|a| \leq a_{\max}$ برقرار است.
- **عدم قطعیت‌ها:** شرایط اولیه‌ی تصادفی، اغتشاش‌های عملگر، عدم تطابق مدل (در پارامترهای جرم)، مشاهده‌ی ناقص، نویز حسگر و تأخیر زمانی، که بر پایداری و کارایی اثرگذارند.
- **صورت‌بندی بازی دیفرانسیلی (جمع‌صفر):** فضاپیما و طبیعت (اغتشاشات) به‌ترتیب به‌عنوان عامل کنترل و حریف مزاحم مدل می‌شوند؛ با افق زمانی محدود t_f ، هدف، دستیابی به سیاستی مقاوم در برابر بدترین سناریو است.

صورت فشرده‌ی بهینه‌سازی به‌صورت کمینه-بیشینه است:

$$\min_{\pi} \max_{\omega} \mathbb{E}_{p, \pi, \omega} \left[\sum_{t=0}^T r(s_t, a_t, \delta_t) \right], \quad (1-1)$$

⁵On-board Computing

که در آن، پاداش r به عنوان تابعی از مصرف سوخت، انحراف از مسیر یا مدار نامی و قیود مسئله تعریف می‌شود. خروجی مورد انتظار، سیاستی سبک و غیرمتمرکز برای اجرای درون‌برد مدنظر است.

۳-۱ یادگیری تقویتی

یادگیری تقویتی^۶ شاخه‌ای از یادگیری ماشین است که در آن توالی اقدام‌ها $a_t \in A$ به گونه‌ای انتخاب می‌شود که بازده تجمعی آینده بیشینه شود. یک فرایند تصمیم‌گیری مارکوف^۷ به صورت $\langle S, A, p, r, \gamma \rangle$ تعریف می‌شود که در آن:

• S : مجموعه‌ی حالات،

• $p(s'|s, a)$: دینامیک انتقال،

• $r(s, a)$: پاداش آنی،

• $\gamma \in [0, 1)$: ضریب تنزیل.

سیاست^۸ $\pi(a|s)$ به عنوان احتمال انتخاب اقدام a در وضعیت s بیان می‌شود. هدف، بیشینه‌سازی برگشت^۹ است:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k} \quad (۲-۱)$$

روش‌های RL معمولاً در دو دسته‌ی ارزش‌محور (مانند Q-learning و DQN) و سیاست‌محور (مانند Reinforce) جای می‌گیرند؛ ترکیب این دو به چارچوب Actor-Critic منتهی می‌شود که در آن، یک بازیگر (Actor) سیاست را به روزرسانی می‌کند و یک منتقد (Critic) ارزش یا Q برآورد می‌شود [۱].

در حضور فضاهای پیوسته‌ی حالت-عمل، الگوریتم‌های TD3، DDPG، SAC و PPO با تکیه بر شبکه‌های عصبی به عنوان تقریب‌گر توابع، کارایی بالایی نشان داده‌اند. در این پژوهش، خانواده‌ی Actor-Critic به عنوان پایه‌ی توسعه‌ی کنترل‌کننده پیشنهاد شده است و در ادامه، به نسخه‌ی چندعاملی آن در بخش ۴-۱ پیوند داده می‌شود.

^۶Reinforcement Learning (RL)

^۷Markov Decision Process (MDP)

^۸Policy

^۹Return

۴-۱ یادگیری تقویتی چندعاملی

در یادگیری تقویتی چندعاملی^{۱۰}، فضای تصمیم‌گیری به صورت یک بازی مارکفی^{۱۱} با مجموعه‌ی عامل‌ها $\mathcal{N} = \{1, \dots, N\}$ مدل شده که در آن هر عامل با سیاست π_i به دنبال بیشینه‌سازی بازده تجمعی خود است. در سناریوهای رقابتیِ دونفره‌ی جمع‌صفر^{۱۲}، مفهوم تعادل نش^{۱۳} به عنوان معیار پایداری سیاست‌ها در نظر گرفته می‌شود.

رویکرد آموزش متمرکز، اجرای توزیع‌شده^{۱۴} با جدا کردن مرحله‌ی آموزش که در آن اطلاعات خصوصی همه‌ی عامل‌ها برای منتقدها در دسترس است و مرحله‌ی اجرا در آن هر عامل صرفاً بر مشاهده‌ی محلی اتکا می‌کند که باعث تعادل میان کارایی، مقیاس‌پذیری و هزینه‌ی ارتباطی برقرار شده‌است.

در این پایان‌نامه، یک صورت‌بندیِ دوعاملیِ جمع‌صفر اتخاذ شده‌است که در آن سیاست هدایت توسط عامل کنترل‌آموز می‌شود و اغتشاشات یا نامعینی‌ها توسط عامل مزاحم مدل‌سازی می‌شوند تا سیاستی مقاوم حاصل شود.

- DDPG: الگوریتم مبتنی بر گرادیان سیاستِ قطعی برای فضاهاى کنش پیوسته،
 - TD3: نسخه‌ی بهبودیافته‌ی DDPG با برآورد دوسویه‌ی Q برای کاهش تورش بیش‌برآورد^{۱۵}،
 - PPO: الگوریتم سیاست احتمالی پایدار با قيود نسبت احتمال و بهبود تدریجی سیاست،
 - SAC: الگوریتم حداکثرسازی آنتروپی که تعادل میان بهره‌برداری و اکتشاف به‌طور ذاتی برقرار می‌شود.
- تابع پاداش طراحی شده، مصالحه‌ی سوخت، انحراف و قيود منعکس می‌شود و مبنایی برای ارزیابی کیفیت سیاست‌های مختلف فراهم می‌گردد.

۵-۱ ارزش افزوده و نوآوری‌های پژوهش

نوآوری‌های اصلی این پژوهش را می‌توان به صورت زیر خلاصه نمود:

¹⁰Multi-Agent Reinforcement Learning (MARL)

¹¹Markov Games (MG)

¹²Zero-Sum

¹³Nash Equilibrium

¹⁴Centralized Training with Decentralized Execution (CTDE)

¹⁵Overestimation Bias

۱. صورت‌بندی هدایت کم‌تراست در CRTBP به صورت یک بازی دیفرانسیلی مجموع صفر میان فضاییما (عامل کنترل) و مزاحمت‌های محیطی (عامل حریف)؛
۲. توسعه نسخه‌های چندعاملی از الگوریتم‌های TD3، DDPG، SAC و PPO در چارچوب آموزش متمرکز و اجرای غیرمتمرکز (CTDE) و انطباق آن با دینامیک چندجسمی؛
۳. طراحی تابع پاداش مقاوم شامل مولفه‌های انحراف مسیر، هزینه سوخت، خطای تراستر، تأخیر حسگر، نویز عملگر و عدم تطابق مدل دینامیکی؛
۴. ارائه نتایج شبیه‌سازی گسترده و نشان‌دادن بهبود معنادار در پایداری مسیرهای تغییر مدارهای لیاپانوف نقاط لاگرانژ، کاهش مصرف سوخت و کاهش انحراف مداری نسبت به نسخه‌های تک‌عاملی و روش‌های کلاسیک؛
۵. فراهم‌سازی چارچوبی که بدون نیاز به مدل دقیق دینامیکی، قابلیت هدایت مقاوم، تطبیقی و مناسب برای پیاده‌سازی درون‌برد را ارائه می‌کند.

۱-۶ ساختار گزارش

در فصل ۲ مروری انتقادی بر کارهای مرتبط در هدایت پیشران‌کم و یادگیری تقویتی تک‌عاملی و چندعاملی ارائه می‌شود. در فصل ۳ مدل‌سازی محیط آزمایش بر پایه‌ی CRTBP ارائه می‌گردد. فصل ۴ به مبانی یادگیری تقویتی اختصاص دارد و الگوریتم‌های TD3، DDPG، SAC و PPO در بخش‌های ۴-۲ تا ۴-۵ مرور می‌شوند. در فصل ۵ طراحی شبیه‌سازی شامل تعریف عامل‌ها، فضای حالت، عمل و تابع پاداش توضیح داده می‌شود. در فصل ۶ چارچوب یادگیری تقویتی چندعاملی تشریح شده و پیوند آن با بازی‌های جمع صفر و تعادل نش در بخش ۶-۲ بیان می‌شود. در فصل ۷ نتایج و مقایسه با معیارهای مرجع ارائه می‌شود. در نهایت، فصل ۸ جمع‌بندی دستاوردها و پیشنهادهای پژوهش‌های آینده را ارائه می‌دهد.

فصل ۲

پیشینه پژوهش

این فصل تصویری منسجم از ادبیات مأموریت‌های بین‌مداری، مبانی یادگیری تقویتی و یادگیری تقویتی چندعاملی ارائه می‌کند. تمرکز بر تبیین مفاهیم کلیدی، چالش‌های رایج، و روندهای پژوهشی مؤثر برای طراحی و هدایت درون‌سفینه‌ای است؛ به‌گونه‌ای که زمینه‌ی نظری لازم برای روش‌ها و مسائل مورد استفاده در ادامه‌ی پژوهش فراهم شود. ساختار فصل به این صورت است که ابتدا در بخش ۱-۲ مروری بر روش‌های طراحی مسیر و هدایت درون‌سفینه‌ای و کاربردهای یادگیری ماشین ارائه می‌شود، سپس در بخش ۲-۲ مبانی و الگوریتم‌های اصلی یادگیری تقویتی و خطوط پژوهشی مرتبط مرور می‌گردد و در پایان بخش ۳-۲ به رویکردها و چالش‌های یادگیری تقویتی چندعاملی پرداخته می‌شود.

۱-۲ مأموریت‌های بین‌مداری

هدایت فضاپیماها معمولاً با استفاده از ایستگاه‌های زمینی انجام می‌شود. با این حال، این تکنیک‌ها دارای محدودیت‌هایی از جمله حساسیت به قطع ارتباطات، تأخیرهای زمانی و محدودیت‌های منابع محاسباتی هستند. الگوریتم‌های یادگیری تقویتی و بازی‌های دیفرانسیلی می‌توانند برای بهبود قابلیت‌های هدایت فضاپیماها، از جمله مقاومت در برابر تغییرات محیطی، کاهش تأخیرهای ناشی از ارتباطات زمینی و افزایش کارایی محاسباتی، مورد استفاده قرار گیرند.

هدایت فضاپیماها معمولاً پیش از پرواز انجام می‌شود. این روش‌ها می‌توانند از تکنیک‌های بهینه‌سازی فراگیر [۲] یا برنامه‌نویسی غیرخطی برای تولید مسیرها و فرمان‌های کنترلی بهینه استفاده کنند. با این حال، این روش‌ها معمولاً حجم محاسباتی زیادی دارند و برای استفاده درون‌سفینه‌ای نامناسب هستند [۳]. یادگیری ماشین می‌تواند برای بهبود قابلیت‌های هدایت فضاپیماها استفاده شود. کنترل‌کننده شبکه عصبی حلقه‌بسته

می‌تواند برای محاسبه سریع و خودکار تاریخچه کنترل استفاده شود. یادگیری تقویتی نیز می‌تواند برای یادگیری رفتارهای هدایت بهینه استفاده شود.

روش‌های هدایت و بهینه‌سازی مسیر فضایی‌ها به‌طور کلی به راه‌حل‌های اولیه مناسب نیاز دارند. در مسائل چند جسمی، طراحان مسیر اغلب حدس‌های اولیه کم‌هزینه‌ای برای انتقال‌ها با استفاده از نظریه سیستم‌های دینامیکی و منیفردهای ثابت [۴، ۵] ایجاد می‌کنند.

شبکه‌های عصبی قابلیت‌های منحصر به فردی برای انجام هدایت در فضایی‌ها دارند. به‌عنوان مثال، شبکه‌های عصبی می‌توانند به‌طور مستقیم از تخمین‌های وضعیت به دستورهای پیشران کنترلی که با محدودیت‌های مأموریت سازگار است، برسند. عملکرد مناسب هدایت شبکه‌های عصبی در مطالعاتی مانند فرود بر سیارات [۶]، عملیات نزدیکی به سیارات [۷] و کنترل فضایی‌ها با پیشران از دست‌رفته [۸] نشان داده شده‌است. تازه‌ترین پیشرفت‌های تکنیک‌های یادگیری ماشین در مسائل خودکارسازی درونی به‌طور گسترده‌ای مورد مطالعه قرار گرفته‌اند؛ از پژوهش‌های اولیه تا توانایی‌های پیاده‌سازی. به‌عنوان مثال، الگوریتم‌های یادگیری ماشین ابتدایی در فضایی‌های مریخی‌نورد برای کمک به شناسایی ویژگی‌های زمین‌شناسی تعبیه شده‌اند. الگوریتم AEGIS توانایی انتخاب خودکار هدف توسط یک دوربین در داخل فضایی‌های Spirit، Opportunity و Curiosity را دارد [۹]. در کامپیوتر پرواز اصلی، فرآیند دقت‌افزایی^۱ نیاز به ۹۴ تا ۹۶ ثانیه دارد [۱۰]، که به‌طور قابل توجهی کمتر از زمان مورد نیاز برای ارسال تصاویر به زمین و انتظار برای انتخاب دستی توسط دانشمندان است. برنامه‌های آینده برای کاربردهای یادگیری ماشین درون‌سفینه شامل توانایی‌های رباتیکی درون‌سفینه برای فضایی‌های Perseverance [۱۱، ۱۲] و شناسایی عیب برای Europa Clipper [۱۳] می‌شود. الگوریتم‌های یادگیری ماشین پتانسیل انجام نقش مهمی در مأموریت‌های خودکار آینده را دارند.

علاوه بر رباتیک سیاره‌ای، پژوهش‌های مختلفی به استفاده از تکنیک‌های مختلف یادگیری ماشین در مسائل نجومی پرداخته‌اند. در طراحی مسیر عملکرد رگرسیون معمولاً مؤثرتر هست. به‌عنوان مثال، از یک شبکه عصبی^۲ در بهینه‌سازی مسیرهای رانشگر کم‌پیشران استفاده شده‌است [۱۴]. پژوهش‌های جدید شامل شناسایی انتقال‌های هتروکلینیک [۱۵]، اصلاح مسیر رانشگر کم‌پیشران [۱۶] و تجزیه و تحلیل مشکلات ازدست‌رفتن رانشگر [۸] می‌شود.

تکنیک‌های یادگیری نظارتی می‌توانند نتایج مطلوبی تولید کنند؛ اما، دارای محدودیت‌های قابل توجهی هستند. یکی از این محدودیت‌ها این است که این رویکردها بر وجود دانش پیش از فرآیند تصمیم‌گیری متکی هستند. این امر مستلزم دقیق‌بودن داده‌های تولیدشده توسط کاربر برای نتایج مطلوب و همچنین وجود تکنیک‌های موجود برای حل مشکل کنونی و تولید داده است.

¹Refinement Process

²Neural Network

در سال‌های اخیر، قابلیت یادگیری تقویتی^۳ در دستیابی به عملکرد بهینه در بخش‌هایی با ابهام محیطی قابل توجه، به اثبات رسیده است [۱۷، ۱۸]. هدایت انجام‌شده توسط یادگیری تقویتی را می‌توان به صورت گسترده بر اساس فاز پرواز دسته‌بندی کرد. مسائل فرود [۱۹، ۲۰] و عملیات در نزدیکی اجسام کوچک [۶، ۷]، از حوزه‌های پژوهشی هستند که از یادگیری تقویتی استفاده می‌کنند. تحقیقات دیگر شامل مواجهه تداخل خارجی جوی [۲۱]، نگهداری ایستگاهی [۲۲] و هدایت به صورت جلوگیری از شناسایی [۲۳] است. مطالعاتی که فضاپیمای رانشگر کم‌پیشران را در یک چارچوب دینامیکی چندبندی با استفاده از یادگیری تقویتی انجام شده‌است، شامل طراحی انتقال با استفاده از Q-learning [۲۴]، Proximal Policy Optimization [۲۵] و هدایت نزدیکی مدار [۲۶] است.

۲-۲ یادگیری تقویتی

از نخستین صورت‌بندی‌های فرایند تصمیم‌گیری مارکوفی در یادگیری تقویتی، پژوهش بر آن بوده‌است که عامل بتواند با اجرای عمل‌ها و دریافت پاداش، سیاستی برای بیشینه‌سازی بازگشت بیاموزد. تبیین جامع این چارچوب و الگوریتم‌های بنیادین در کتاب سوتون و بارتو به مثابه مرجع کلاسیک این حوزه ارائه شده و همچنان مبنای بسیاری از آثار معاصر است [۱].

دهه‌ی ۱۹۹۰ میلادی شاهد شکل‌گیری روش‌هایی بر پایه‌ی ارزش^۴ نظیر Q-learning و نخستین رویکردهای گرادیان سیاست بود؛ با وجود این، محدودیت توان محاسباتی و فقدان داده‌ی فراوان، سرعت رشد را کند می‌کرد. ورود شبکه‌های عصبی عمیق^۵ نقطه‌ی عطفی بود: مقاله‌ی معروف دیپ‌ماینده^۶ نشان داد که شبکه‌ی Q عمیق^۷ می‌تواند صرفاً از پیکسل‌های بازی آتاری سیاستی نزدیک به انسان بیاموزد [۲۷].

موفقیت DQN نگاه‌ها را به سوی گرادیان سیاست مقیاس‌پذیر معطوف ساخت. بهینه‌سازی ناحیه‌ی اطمینان^۸ تضمین بهبود یکنواخت سیاست را فراهم کرد [۲۸] و روش A3C با موازی‌سازی بازیگران، سرعت یادگیری را چند برابر افزایش داد [۲۹]. کمی بعد، DDPG اولین بار گرادیان سیاست قطعی را به فضاهای عمل پیوسته وارد کرد [۳۰]. سپس PPO با ساده‌سازی قیود TRPO و کاهش فراپارامترهای حساس، به انتخاب پیش‌فرض بسیاری از کاربردهای مهندسی بدل شد [۳۱].

با گسترش دامنه‌ی مسائل، پایداری و کارایی داده به چالش اصلی بدل گشت. TD3 نشان داد که کمینه‌کردن

³Reinforcement Learning (RL)

⁴Value

⁵Deep Neural Network (DNN)

⁶DeepMind

⁷Deep Q Network (DQN)

⁸Trust Region Policy Optimization (TRPO)

میان دو منتقد می‌تواند برآورد بیش از حد Q را مهار کند [۳۲]، و SAC با افزودن بند آنتروپی، هم‌زمان اکتشاف و بازده را بهبود داد [۳۳].

در محیط‌های پرخطر یا گران، جمع‌آوری داده‌ی برخاسته ناممکن است؛ از این رو یادگیری تقویتی غیربرخط مطرح شد. روش CQL با برقراری کران محافظه‌کارانه بر Q-value از گرایش خارج از توزیع جلوگیری می‌کند [۳۴] و مرور اخیر پروادنیسیو و همکاران طبقه‌بندی جامعی از چالش‌های باز این حوزه ارائه داده است [۳۵].

هم‌زمان، دغدغه‌ی ایمنی و مقاومت در سامانه‌های واقعی پررنگ شد. مرور سال ۲۰۲۲ نشان می‌دهد که ترکیب قیدهای سخت، توابع جریمه‌ی ریسک و شبیه‌سازی محیط‌های بدبینانه سه خط اصلی ایمنی در یادگیری تقویتی هستند [۳۶]. سلسله‌مراتب نیز با هدف انتقال دانش و تسریع یادگیری مورد توجه قرار گرفت و یک مطالعه‌ی جامع در ACM Computing Surveys چهار چالش کشف زیرکار، یادگیری اشتراک‌پذیر، انتقال و مقیاس‌پذیری را برجسته می‌کند [۳۷].

وقتی چند عامل به‌طور هم‌زمان یاد می‌گیرند، پویایی محیط از دید هر عامل غیرایستا می‌شود. مرور جامع ۲۰۲۴ نشان می‌دهد که چارچوب ناظر متمرکز - بازیگر توزیع‌شده^۹ راهکاری موثر برای این چالش است و مباحثی چون تخصیص اعتبار جمعی و کشف تعادل را معرفی می‌کند [۳۸].

پیشرفت‌های یادشده در نهایت به دستاوردهای نمادینی چون AlphaGo [۳۹] و AlphaStar [۴۰] انجامیدند که در بازی‌های Go و StarCraft II از انسان پیشی گرفتند و معماری توزیع‌شده‌ی IMPALA نشان داد که چگونه می‌توان هزاران شبیه‌ساز را با به‌روزرسانی وزن‌های مهم ادغام کرد [۴۱].

به‌رغم این جهش‌ها، سه شکاف اساسی پابرجا مانده است: (۱) تضمین ایمنی سخت‌گیرانه در سناریوهای نزدیک‌برخورد، (۲) کاهش وابستگی به داده‌ی پرهزینه یا نایاب از طریق روش‌های مدل‌مبنا و غیربرخط و (۳) مقیاس‌پذیری یادگیری چندعاملی برای سامانه‌های رباتیکی یا فضایی چندگانه.

۳-۲ پیشینه‌ی پژوهش یادگیری تقویتی چندعاملی

امروز یادگیری تقویتی چندعاملی^{۱۰} به‌عنوان بنیاد اصلی سامانه‌های هوشمند مشارکتی شناخته می‌شود؛ مسیری که از آزمون‌های ساده‌ی دوعاملی در دهه‌ی ۱۹۹۰ آغاز شد و اکنون به معماری‌های توزیع‌شده‌ی در مقیاس هزاران بازیگر رسیده است. این بخش، به بررسی اینکه چگونه ایده‌ی آموزش متمرکز - اجرای توزیع‌شده (CTDE) به پاسخ غالب برای چالش‌های غیرایستایی و انفجار بُعدی^{۱۱} بدل شد و چه گام‌هایی هنوز برای ایمنی، ناهمگونی

^۹Centralized Training with Decentralized Execution (CTDE)

^{۱۰}Multi-Agent Reinforcement Learning (MARL)

^{۱۱}Curse of Dimensionality

و مقیاس‌پذیری باقی مانده است.

دهه‌ی ۱۹۹۰ با مقاله‌ی [۴۲] آغاز شد؛ جایی که برای نخستین بار مقایسه‌ی عامل‌های مستقل با عامل‌های همکار انجام شد و سود ارتباط و اشتراک تجربه به‌صورت تجربی نشان داده شد. در میانه‌ی دهه‌ی بعد، مرور جامع پانایت و لوک [۴۳] چشم‌اندازی از مسائل تخصیص اعتبار و غیرایستایی ترسیم کرد و دو موضوع یادگیری تیمی و یادگیری هم‌زمان را صورت‌بندی نمود. هم‌زمان، بوشونیو و همکاران [۴۴] ادبیات MARL را در قالب اهداف پایداری دینامیک یادگیری و انطباق با رفتار سایر عامل‌ها جمع‌بندی کردند و راه را برای تحلیل‌های بازی‌محور هموار ساختند.

ورود شبکه‌های عمیق در سال‌های ۲۰۱۶ و ۲۰۱۷ نقطه‌ی عطف بعدی بود؛ منتقد متمرکز- بازیگر توزیع‌شده در MA-DDPG [۴۵] نشان داد که می‌توان از حالت سراسری در فاز آموزش بهره برد، اما سیاست نهایی را صرفاً بر اساس مشاهدات محلی اجرا کرد. در همان سال، Value-Decomposition Networks [۴۶] ایده‌ی تجزیه‌ی خطی پاداش را برای همکاری عامل‌ها مطرح کرد و راه را برای تقسیم بندی‌های پیش‌رفته پاداش گشود. ۲۰۱۸ شاهد جهش مهمی با QMIX بود؛ این روش با اعمال قید تک‌نوا^{۱۲} بر ترکیب مقادیر منفرد، هم امکان بهینه‌سازی غیرسیاست‌محور را فراهم کرد و هم تضمین سازگاری سیاست‌های محلی با ارزش مشترک را برقرار ساخت [۴۷].

سال ۲۰۱۹ به گسترش بسترهای آزمایش اختصاص یافت. چالش استاندارد StarCraft Multi-Agent Challenge (SMAC) بر مبنای StarCraft II معرفی شد و معیار مشترکی برای مقایسه‌ی الگوریتم‌ها را مهیا کرد [۴۸]. هم‌زمان، QTRAN [۴۹] نشان داد که می‌توان بدون قید خطی یا تک‌نوا، تابع ارزش مشترک را به فضای قابل تجزیه تبدیل کرد. از سوی دیگر، MAVEN با افزودن متغیر نهفته‌ی مشترک، کاوش هماهنگ و سلسله‌مراتبی را امکان‌پذیر ساخت [۵۰]. نقطه‌ی اوج همان سال، سامانه‌ی AlphaStar بود که نشان داد ترکیب خودبازی و معماری توزیع‌شده می‌تواند به رتبه‌ی استاد بزرگ^{۱۳} انسان برساند [۴۰].

در ۲۰۲۰ مفهوم نقش‌های در حال ظهور با ROMA [۵۱] معرفی شد تا عامل‌ها بر اساس شباهت رفتاری به‌طور خودکار خوشه‌بندی و اشتراک دانش کنند؛ رویکردی که در نقشه‌های پرتراکم SMAC برتری محسوسی نشان داد. پژوهش‌های متا در ۲۰۲۱، از مرور نظری زانگ و بشار [۵۲] تا محک^{۱۴} تطبیقی پاپوداکیس و همکاران [۵۳]، شکاف‌های باقی‌مانده در تضمین همگرایی و مقیاس را فهرست کردند.

آخرین موج مطالعات بر ناهمگونی و ایمنی تمرکز دارد. مرور جامع [۵۴] نشان می‌دهد که تفاوت در قابلیت‌ها و اطلاعات عامل‌ها، مسائلی نظیر تخصیص اعتبار و تعادل را پیچیده‌تر می‌سازد و به الگوریتم‌های سازگار با نقش‌های پویا نیاز دارد.

¹²Monotonic

¹³Grandmaster

¹⁴Benchmark

به طور خلاصه، مسیر تاریخی MARL از الگوهای مستقل دهه ۱۹۹۰ به سامانه‌های توزیع شده‌ی امروزی، همواره با سه دغدغه‌ی اصلی هدایت شده‌است: کنترل انفجار بُعدی توابع ارزش، مقابله با غیریستایی ناشی از یادگیری هم‌زمان، و انتقال مؤثر تجربه میان عامل‌ها. علی‌رغم پیشرفت‌های شتابان، تضمین ایمنی سخت‌گیرانه در محیط‌های شکست‌پذیر، مدیریت نقش‌های پویا در تیم‌های ناهمگون و کاهش نیاز به داده‌ی شبیه‌سازی پرهزینه همچنان چالش‌های باز باقی می‌مانند؛ چالش‌هایی که در این پژوهش با رویکرد ترکیبی مدل‌مبنا، مقاوم و چندعاملی پیگیری می‌شوند.

۴-۲ جمع‌بندی و گپ پژوهشی

مرور ادبیات پژوهش نشان داد که هدایت فضایی‌های کم‌تراست در سامانه‌های دینامیکی چندجسمی، به‌ویژه در چارچوب مسأله‌ی محدود سه‌جسمی (CRTBP)، عمدتاً مبتنی بر روش‌های کلاسیک کنترل بهینه و تکنیک‌های مدل‌مبنا بوده است [۳-۵]. هرچند این رویکردها در شرایط اسمی عملکرد مطلوبی دارند، اما اتکای شدید آن‌ها به مدل‌سازی دقیق دینامیکی و حساسیت نسبت به عدم قطعیت‌های محیطی، موجب کاهش کارایی و پایداری سامانه در حضور اغتشاشات حسگر، خطای عملگر، تاخیر زمانی و عدم تطابق مدلی می‌گردد.

از سوی دیگر، روش‌های یادگیری تقویتی عمیق طی سال‌های اخیر برای هدایت کم‌تراست در محیط‌های مدارپویای سیاره‌ای پیشنهاد شده‌اند [۲۵، ۲۶، ۵۵]. با وجود پیشرفت‌های قابل توجه، بررسی منابع موجود نشان می‌دهد که:

۱. اغلب پژوهش‌ها مبتنی بر چارچوب RL تک‌عاملی بوده و تعامل فضایی با مزاحمت‌های محیطی به‌صورت یک بازی دیفرانسیلی مجموع صفر مدل نشده است؛

۲. در عمده‌ی مطالعات، فرض مشاهده‌ی کامل و بدون نویز از حالت‌ها در نظر گرفته شده و پدیده‌های واقعی نظیر تأخیر حسگر، اغتشاشات تصادفی و تطابق‌ناپذیری مدل لحاظ نشده‌اند؛

۳. کمتر پژوهشی نسخه‌های TD3، DDPG، SAC و PPO را در قالب یادگیری تقویتی چندعاملی با آموزش متمرکز و اجرای غیرمتمرکز (CTDE) برای هدایت فضایی در CRTBP توسعه داده است.

بنابراین، گپ پژوهشی اصلی این رساله را می‌توان به صورت زیر بیان کرد:

هنوز چارچوبی مقاوم، مبتنی بر یادگیری تقویتی چندعاملی مجموع صفر، که توانایی هدایت فضایی‌های کم‌تراست را در محیط‌های ناپایدار CRTBP با حضور گسترده‌ی عدم قطعیت‌های محیطی تضمین نماید، ارائه نشده است.

هدف پژوهش حاضر، طراحی و ارزیابی چنین چارچوبی و بررسی مزایای آن نسبت به نسخه‌های تک‌عاملی و روش‌های کلاسیک هدایت می‌باشد.

فصل ۳

مدل سازی محیط یادگیری سه جسمی

مسیرهای فضایی در بسیاری از مأموریت‌ها نه تنها تحت تأثیر گرانش یک جسم مرکزی (مانند خورشید یا زمین)، بلکه به طور هم‌زمان تحت نفوذ دست‌کم یک جسم دیگر نیز هستند. در این وضعیت، مدل‌های دوجسمی با اختلالات جسم سوم دقت کافی ندارند و باید دینامیک دو جسم اصلی و اثرات آن‌ها به صورت هم‌زمان در نظر گرفته شود. مسئله‌ی سه جسمی محدود با دو جسم اصلی و یک جسم سوم با جرم ناچیز (فضاپیما) چارچوبی طبیعی برای مطالعه‌ی این پدیده‌ها و نیز یک محیط مناسب برای به کارگیری روش‌های یادگیری تقویتی است؛ زیرا دینامیک غیرخطی و پیچیده‌ی آن ویژگی‌های غنی (مانند نقاط تعادل لاگرانژ) ایجاد می‌کند.

در این فصل ابتدا در بخش ۱-۳ دستگاه بی‌بُعد و چارچوب چرخان تعریف شده و در بخش ۲-۳ معادلات حرکت در مسئله‌ی سه جسمی محدود دایره‌ای استخراج می‌شود.

۱-۳ مسئله‌ی سه جسمی محدود دایره‌ای (CRTBP)

دو جرم اصلی (زمین با جرم m_1 و ماه با جرم m_2) روی مدارهایی دایره‌ای و هم‌صفحه پیرامون مرکز جرم مشترک حرکت می‌کنند. جرم سوم (فضاپیما با جرم ناچیز m_3) چنان کوچک فرض می‌شود که تأثیر گرانشی آن بر حرکت دو جسم اصلی قابل نظر است؛ بدین ترتیب، مسئله‌ی سه جسمی محدود دایره‌ای شکل می‌گیرد.

جدول ۱-۳: مقادیر عددی برای مسئله سه جسمی محدود (سامانه زمین-ماه)

پارامتر	توصیف	مقدار عددی
m_1	جرم زمین	$5.972 \times 10^{24} \text{ kg}$
m_2	جرم ماه	$7.348 \times 10^{22} \text{ kg}$
μ	نسبت جرمی	0.0121505856
ω	سرعت زاویه‌ای سامانه	$2.6617 \times 10^{-6} \text{ rad/s}$

دستگاه مختصات چرخانی هم‌دوران با دو جرم اصلی انتخاب می‌شود؛ مبدأ در مرکز جرم سامانه است، محور x خطِ وصلِ دو جرم و محور y بر آن عمود (در صفحه‌ی مدارها) است. واحد طول برابر فاصله‌ی ثابتِ میان دو جرم و واحدِ زمان چنان تعریف می‌شود که دوره‌ی مداری سامانه 2π (و در نتیجه $\omega = 1$) گردد. همچنین جرم‌ها به گونه‌ای مقیاس می‌شود که مجموع دو جرم برابر با یک شود:


$$m_1 + m_2 = 1. \quad (1-3)$$

با نسبتِ جرمی

$$\mu \equiv \frac{m_2}{m_1 + m_2}, \quad (2-3)$$

داریم $m_1 = 1 - \mu$ و $m_2 = \mu$ و مکانِ دو جرم در دستگاه بی‌بُعد به صورت

$$\mathbf{r}_{\text{Earth}} = (-\mu, 0), \quad \mathbf{r}_{\text{Moon}} = (1 - \mu, 0). \quad (3-3)$$



شکل ۱-۳: هندسه‌ی مسئله‌ی سه جسمی محدود در چارچوب چرخان

۱-۱-۳ لاگرانژ و معادلات حرکت

با در نظر گرفتن $G = 1$ در حالت بی‌بعد، تابع لاگرانژ جرم سوم در دستگاه چرخان برابر است با [۵۶]

$$L = \frac{1}{2}(\dot{x}^2 + \dot{y}^2 + \dot{z}^2) + (1 - \mu) \frac{1}{r_1} + \mu \frac{1}{r_2} + \frac{1}{2}(x^2 + y^2), \quad (۴-۳)$$

که در آن

$$r_1 = \sqrt{(x + \mu)^2 + y^2 + z^2}, \quad r_2 = \sqrt{(x - 1 + \mu)^2 + y^2 + z^2}. \quad (۵-۳)$$

با به‌کارگیری رابطه‌ی اوایلر-لاگرانژ

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}_i} - \frac{\partial L}{\partial q_i} = 0, \quad q_i \in \{x, y, z\},$$

معادلات بی‌بعد حرکت جرم سوم به دست می‌آید:

$$\ddot{x} - 2\dot{y} = x - \frac{1 - \mu}{r_1^3}(x + \mu) - \frac{\mu}{r_2^3}(x - 1 + \mu), \quad (۶-۳)$$

$$\ddot{y} + 2\dot{x} = y - \frac{1 - \mu}{r_1^3}y - \frac{\mu}{r_2^3}y, \quad (۷-۳)$$

$$\ddot{z} = -\frac{1 - \mu}{r_1^3}z - \frac{\mu}{r_2^3}z. \quad (۸-۳)$$

یا به نگاشت برداری به صورت زیر است.

$$\ddot{\mathbf{r}} + 2\boldsymbol{\omega} \times \dot{\mathbf{r}} = \nabla \Omega(\mathbf{r}), \quad \Omega(x, y, z) = \frac{1}{2}(x^2 + y^2) + \frac{1 - \mu}{r_1} + \frac{\mu}{r_2}. \quad (۹-۳)$$

که در آن Ω پتانسیل مؤثر است و در بخش ۲-۳ برای یافتن نقاط تعادل از شرط $\nabla \Omega = 0$ استفاده می‌شود.

۲-۳ نقاط تعادل لاگرانژ

نقطه‌ی تعادل مکانی است که در چارچوب چرخان، جرم سوم بی‌حرکت می‌ماند. این شرط با صفر شدن مؤلفه‌های سرعت و شتاب حاصل می‌شود؛ از این رو در معادلات حرکت بخش ۱-۳ قرار می‌دهیم $\dot{x} = \dot{y} = \dot{z} = \ddot{x} = \ddot{y} = \ddot{z} = 0$. در نتیجه دستگاه جبری زیر برای مختصات نقطه‌ی تعادل به دست می‌آید:

$$0 = x - \frac{1 - \mu}{r_1^3}(x + \mu) - \frac{\mu}{r_2^3}(x - 1 + \mu), \quad (۱۰-۳)$$


$$0 = y \left[1 - \frac{1 - \mu}{r_1^3} - \frac{\mu}{r_2^3} \right], \quad (۱۱-۳)$$

$$0 = -\frac{1 - \mu}{r_1^3}z - \frac{\mu}{r_2^3}z. \quad (۱۲-۳)$$

معادله‌ی سوم نشان می‌دهد در حالتِ عمومی باید $z = 0$ باشد؛ بنابراین، نقاطِ تعادل همگی در صفحه‌ی مدار قرار می‌گیرند.

دسته‌بندی کلی

۱. نقاطِ هم‌خط^۱: سه نقطه‌ی L_1 ، L_2 و L_3 روی خطِ واصلِ دو جرم قرار دارند و لذا $y = 0$ است.
۲. نقاطِ سه‌گوش^۲: دو نقطه‌ی L_4 و L_5 رأس‌های مثلثِ متساوی‌الاضلاع با دو جرم اصلی را تشکیل می‌دهند و در آن‌ها $y \neq 0$.



شکل ۳-۲: نقاطِ لاگرانژ در سامانه‌ی زمین-ماه

نقاطِ هم‌خط (L_1, L_2, L_3)

با اعمال $y = 0$ ، تنها معادله‌ی زیر باقی می‌ماند:

$$x - \frac{1 - \mu}{|x + \mu|^3}(x + \mu) - \frac{\mu}{|x - 1 + \mu|^3}(x - 1 + \mu) = 0. \quad (13-3)$$

این معادله در سه ناحیه‌ی مجزا—بین دو جرم، بیرونِ جرمِ کوچک و بیرونِ جرمِ بزرگ—دارای یک ریشه است که به‌ترتیب نقاطِ L_1 ، L_2 و L_3 را تعیین می‌کند.

¹Collinear

²Triangular

برای $1 \ll \mu$ (همچون سامانه‌ی خورشید-زمین یا زمین-ماه) می‌توان تقریب‌های شناخته‌شده را نوشت:

$$\begin{aligned}x_{L_1} &\simeq (1 - \mu) - \left(\frac{\mu}{3}\right)^{1/3}, \\x_{L_2} &\simeq (1 - \mu) + \left(\frac{\mu}{3}\right)^{1/3}, \\x_{L_3} &\simeq -1 - \frac{5}{12}\mu; \quad y_{L_i} = 0.\end{aligned}$$

در عمل، ریشه‌ی دقیقِ معادله‌ی (۱۳-۳) با یک روش عددی (نیوتن-رافسون) محاسبه می‌شود.

نقاط سه‌گوش (L_4, L_5)

در این نقاط $r_1 = r_2 = 1$ و شرط $1 - (1 - \mu)/r_1^3 - \mu/r_2^3 = 0$ به‌طور طبیعی برقرار است. مختصات به عبارت‌اند از

$$x_{L_4} = x_{L_5} = \frac{1}{2} - \mu, \quad y_{L_4} = +\frac{\sqrt{3}}{2}, \quad y_{L_5} = -\frac{\sqrt{3}}{2}. \quad (۱۴-۳)$$

پایداری این نقاط مستلزم نسبتِ جرمِ کافی است؛ شرطِ کلاسیک $m_1/m_2 > 24.96$ (یا معادل آن $\mu < \mu_R \approx 0.03852$) در سامانه‌های خورشید-سیاره یا زمین-ماه برقرار است و سببِ وجودِ خانواده‌ی سیارک‌های تروجان حول L_4 و L_5 می‌شود. در مقابل، نقاطِ هم‌خطِ ناپایدارند و معمولاً مأموریت‌های فضایی روی مدارهای هاله‌ای یا لیسائور در پیرامونِ آن‌ها قرار می‌گیرند.

برای سامانه‌ی زمین-ماه، $\mu \simeq 0.01215$ است. جدولِ زیر مختصاتِ بی‌بعدِ هر پنج نقطه را نشان می‌دهد (واحدِ طول: فاصله‌ی زمین-ماه). موقعیتِ زمین در $(-\mu, 0)$ و ماه در $(1 - \mu, 0)$ است.

جدول ۳-۲: مقادیر عددی نقاط لاگرانژ برای مسئله‌ی سه‌جسمی محدودِ سیستمِ زمین-ماه

نقطه‌ی لاگرانژ	x (بی‌بعد)	y (بی‌بعد)
L_1	+0.83692	0
L_2	+1.15568	0
L_3	-1.00506	0
L_4	+0.48785	+0.86603
L_5	+0.48785	-0.86603

این نتایج نشان می‌دهد که L_1 در حدود 0.84 فاصله‌ی زمین-ماه از زمین قرار دارد (فاصله‌ی آن تا ماه در حدود 0.16 واحد طول است) و L_2 بیرون مدار ماه است. نقطه‌ی L_3 تقریباً یک واحد طول در سوی مقابل ماه نسبت به زمین قرار دارد. دو نقطه‌ی L_4 و L_5 در مختصات $(0.488, \pm 0.866)$ قرار گرفته و با زمین و ماه مثلث متساوی‌الاضلاع می‌سازند.

این نتایج نشان می‌دهد که L_1 در حدود 0.84 فاصله‌ی زمین-ماه از زمین قرار دارد (فاصله‌ی آن تا ماه در حدود 0.16 واحد طول است) و L_2 بیرون مدار ماه است. نقطه‌ی L_3 تقریباً یک واحد طول در سوی مقابل ماه نسبت به زمین قرار دارد. دو نقطه‌ی L_4 و L_5 در مختصات $(0.488, \pm 0.866)$ قرار گرفته و با زمین و ماه مثلث متساوی‌الاضلاع می‌سازند.

فصل ۴

یادگیری تقویتی

در این فصل به بررسی یادگیری تقویتی پرداخته شده است. ابتدا در فصل ۴-۱ مفاهیم اولیه یادگیری تقویتی ارائه شده است. در ادامه عامل‌های گرادیان سیاست عمیق قطعی ۴-۲، گرادیان سیاست عمیق قطعی تاخیری دوگانه ۴-۳، عملگر نقاد نرم ۴-۴ و بهینه‌سازی سیاست مجاور ۴-۵ توضیح داده شده است.

۴-۱ مفاهیم اولیه

دو بخش اصلی یادگیری تقویتی^۱ شامل عامل^۲ و محیط^۳ است. عامل در محیط قرار دارد و با آن در تعامل است. در هر مرحله از تعامل بین عامل و محیط، عامل یک مشاهده جزئی از وضعیت محیط انجام می‌دهد و سپس در مورد اقدامی که باید انجام دهد، تصمیم می‌گیرد. وقتی عامل روی محیط عمل می‌کند، محیط تغییر می‌کند؛ اما، ممکن است محیط به تنهایی نیز تغییر کند. عامل همچنین یک سیگنال پاداش^۴ از محیط دریافت می‌کند؛ سیگنالی که به عامل می‌گوید وضعیت تعامل فعلی آن با محیط چقدر خوب یا بد است. هدف عامل بیشینه‌کردن پاداش انباشته خود است که برگشت^۵ نام دارد. یادگیری تقویتی به روش‌هایی گفته می‌شود که در آن‌ها عامل رفتارهای مناسب برای رسیدن به هدف خود را می‌آموزد. در شکل ۴-۱ تعامل بین محیط و عامل نشان داده شده است.


^۱ Reinforcement Learning (RL)

^۲ Agent

^۳ Environment

^۴ Reward

^۵ Return



شکل ۴-۱: حلقه تعامل عامل و محیط

۴-۱-۱ حالت و مشاهدات

حالت^۶ (s) توصیف کاملی از وضعیت محیط است. همه‌ی اطلاعات محیط در حالت وجود دارد. مشاهده^۷ (o) یک توصیف جزئی از حالت است که ممکن است شامل تمامی اطلاعات نباشد. در این پژوهش مشاهده توصیف کاملی از محیط هست؛ در نتیجه، حالت و مشاهده برابر هستند.

۴-۱-۲ فضای عمل

فضای عمل (a) در یادگیری تقویتی، مجموعه‌ای از تمام اقداماتی است که یک عامل می‌تواند در محیط انجام دهد. این فضا می‌تواند گسسته^۸ یا پیوسته^۹ باشد. در این پژوهش فضای عمل پیوسته و محدود به یک بازه مشخص است.

۴-۱-۳ سیاست

سیاست^{۱۰} قاعده‌ای است که یک عامل برای تصمیم‌گیری در مورد اقدامات خود استفاده می‌کند. در این پژوهش به تناسب الگوریتم پیاده‌سازی شده از سیاست قطعی^{۱۱} یا تصادفی^{۱۲} استفاده شده است که به دو صورت زیر نشان

⁶State

⁷Observation

⁸Discrete

⁹Continuous

¹⁰Policy

¹¹Deterministic

¹²Stochastic

داده می‌شود:

$$a_t = \mu(s_t) \quad (۱-۴)$$

$$a_t \sim \pi(\cdot | s_t) \quad (۲-۴)$$

که زیروند t بیانگر زمان است. در یادگیری تقویتی عمیق از سیاست‌های پارامتری شده استفاده می‌شود. خروجی این سیاست‌ها تابعی پارامترهای سیاست (وزن‌ها و بایاس‌های یک شبکه عصبی) هستند که می‌توان از الگوریتم‌های بهینه‌سازی جهت تعیین مقدار بهینه این پارامترها استفاده کرد. در این پژوهش پارامترهای سیاست با θ نشان داده شده است و سپس نماد آن به عنوان زیروند سیاست مانند معادله (۳-۴) نشان داده شده است.

$$a_t = \mu_\theta(s_t) \quad (۳-۴)$$

$$a_t \sim \pi_\theta(\cdot | s_t)$$

۴-۱-۴ مسیر

یک مسیر^{۱۳} یک توالی از حالت‌ها و عمل‌ها در محیط است.

$$\tau = (s_0, a_0, s_1, a_1, \dots) \quad (۴-۴)$$

گذار حالت^{۱۴} به اتفاقاتی که در محیط بین زمان t در حالت s_t و زمان $t + 1$ در حالت s_{t+1} رخ می‌دهد، گفته می‌شود. این گذارها توسط قوانین طبیعی محیط انجام می‌شوند و تنها به آخرین اقدام انجام شده توسط عامل (a_t) بستگی دارند. گذار حالت را می‌توان به صورت زیر تعریف کرد.

$$s_{t+1} = f(s_t, a_t) \quad (۵-۴)$$

۵-۱-۴ تابع پاداش و برگشت

تابع پاداش^{۱۵} در حالت کلی به حالت فعلی محیط، آخرین عمل انجام شده و حالت بعدی محیط بستگی دارد. تابع پاداش را می‌توان به صورت زیر تعریف کرد.

$$r_t = R(s_t, a_t, s_{t+1}) \quad (۶-۴)$$

¹³Trajectory

¹⁴State Transition

¹⁵Reward Function

در این پژوهش، پاداش تنها تابعی از جفتِ حالت-عمل ($r_t = R(s_t, a_t)$) فرض شده‌است. هدف عامل این است که مجموع پاداش‌های به‌دست‌آمده در طول یک مسیر را به حداکثر برساند. در این پژوهش مجموع پاداش‌ها در طول یک مسیر را با نماد $R(\tau)$ نشان داده شده‌است و به آن تابع برگشت^{۱۶} گفته می‌شود. یکی از انواع برگشت، برگشت بدون تنزیل^{۱۷} با افق محدود^{۱۸} است که مجموع پاداش‌های به‌دست‌آمده در یک بازه زمانی ثابت و از مسیر τ است که در معادله (۷-۴) نشان داده شده‌است.

$$R(\tau) = \sum_{t=0}^T r_t \quad (۷-۴)$$

نوع دیگری از برگشت، برگشت تنزیل‌شده با افق نامحدود^{۱۹} است که مجموع همه پاداش‌هایی است که تا به حال توسط عامل به‌دست آمده‌است. اما، فاصله زمانی تا دریافت پاداش باعث تنزیل ارزش آن می‌شود. این معادله برگشت (۸-۴) شامل یک فاکتور تنزیل^{۲۰} با نماد γ است که عددی بین صفر و یک است.

$$R(\tau) = \sum_{t=0}^{\infty} \gamma^t r_t \quad (۸-۴)$$

۴-۱-۶ ارزش در یادگیری تقویتی

در یادگیری تقویتی، دانستن ارزش^{۲۱} یک حالت یا جفتِ حالت-عمل ضروری است. منظور از ارزش، برگشت مورد انتظار^{۲۲} است. یعنی اگر از آن حالت یا جفتِ حالت-عمل شروع شود و سپس برای همیشه طبق یک سیاست خاص عمل شود، به‌طور میانگین چه مقدار پاداش دریافت خواهد شد. توابع ارزش تقریباً در تمام الگوریتم‌های یادگیری تقویتی به کار می‌روند. در اینجا به چهار تابع مهم اشاره شده‌است.

۱. تابع ارزش تحت سیاست^{۲۳} ($V^\pi(s)$): خروجی این تابع برگشت مورد انتظار است در صورتی که از حالت s شروع شود و همیشه طبق سیاست π عمل شود و به‌صورت زیر بیان می‌شود:

$$V^\pi(s) = \mathbb{E}_{\tau \sim \pi} [R(\tau) | s_0 = s] \quad (۹-۴)$$

۲. تابع ارزش-عمل تحت سیاست^{۲۴} ($Q^\pi(s, a)$): خروجی این تابع برگشت مورد انتظار است در صورتی که از حالت s شروع شود، یک اقدام دلخواه a (که ممکن است از سیاست π نباشد) انجام شود و سپس

¹⁶Return

¹⁷Discount

¹⁸Finite-Horizon Undiscounted Return

¹⁹Infinite-Horizon Discounted Return

²⁰Discount Factor

²¹Value

²²Expected Return

²³On-Policy Value Function

²⁴On-Policy Action-Value Function

برای همیشه طبق سیاست π عمل شود و به صورت زیر بیان می شود:

$$Q^\pi(s, a) = \mathbb{E}_{\tau \sim \pi} [R(\tau) | s_0 = s, a_0 = a] \quad (۱۰-۴)$$

۳. تابع ارزش بهینه^{۲۵} ($V^*(s)$): خروجی این تابع برگشت مورد انتظار است در صورتی که از حالت s شروع شود و همیشه طبق سیاست بهینه در محیط عمل شود و به صورت زیر بیان می شود:

$$V^*(s) = \max_{\pi} (V^\pi(s)) \quad (۱۱-۴)$$

۴. تابع ارزش-عمل بهینه^{۲۶} ($Q^*(s, a)$): خروجی این تابع برگشت مورد انتظار است در صورتی که از حالت s شروع شود، یک اقدام دلخواه a انجام شود و سپس برای همیشه طبق سیاست بهینه در محیط عمل شود و به صورت زیر بیان می شود:

$$Q^*(s, a) = \max_{\pi} (Q^\pi(s, a)) \quad (۱۲-۴)$$

۷-۱-۴ معادلات بلمن

توابع ارزش اشاره شده از معادلات خاصی که به آن ها معادلات بلمن گفته می شود، پیروی می کنند. ایده اصلی پشت معادلات بلمن این است که ارزش نقطه شروع برابر است با پاداشی است که انتظار دارید از آنجا دریافت کنید، به علاوه ارزش مکانی که بعداً به آنجا می رسید. معادلات بلمن برای توابع ارزش سیاست محور به شرح زیر هستند:

$$V^\pi(s) = \mathbb{E}_{\substack{a \sim \pi \\ s' \sim P}} [r(s, a) + \gamma V^\pi(s')] \quad (۱۳-۴)$$

$$Q^\pi(s, a) = r(s, a) + \mathbb{E}_{s' \sim P} \left[\gamma \mathbb{E}_{a' \sim \pi} [Q^\pi(s', a')] \right] \quad (۱۴-۴)$$

که در آن $V^\pi(s)$ تابع ارزش حالت s تحت سیاست π است؛ $Q^\pi(s, a)$ تابع ارزش عمل a در حالت s تحت سیاست π است؛ $R(s, a)$ پاداش دریافتی پس از انجام عمل a در حالت s است؛ γ ضریب تنزیل است که ارزش پاداش های آینده را کاهش می دهد؛ $s' \sim P(\cdot | s, a)$ نشان می دهد که حالت بعدی s' از توزیع انتقال محیط P با شرط های s و a نمونه برداری می شود؛ و $a' \sim \pi(\cdot | s')$ نشان می دهد که عمل بعدی a' از سیاست

²⁵Optimal Value Function

²⁶Optimal Action-Value Function

π با شرط حالت جدید s' نمونه‌برداری می‌شود. این معادلات بیانگر این هستند که ارزش یک حالت یا عمل، مجموع پاداش مورد انتظار آن و ارزش حالت بعدی است که بر اساس سیاست فعلی تعیین می‌شود. معادلات بلمن برای توابع ارزش بهینه به شرح زیر هستند:

$$V^*(s) = \max_a \mathbb{E}_{s' \sim P} [r(s, a) + \gamma V^*(s')] \quad (۱۵-۴)$$

$$Q^*(s, a) = r(s, a) + \mathbb{E}_{s' \sim P} [\gamma \max_{a'} Q^*(s', a')] \quad (۱۶-۴)$$

تفاوت حیاتی بین معادلات بلمن برای توابع ارزش سیاست محور و توابع ارزش بهینه، عدم حضور یا حضور عملگر max بر روی اعمال است. حضور آن منعکس‌کننده این است که هرگاه عامل بتواند عمل خود را انتخاب کند، برای عمل بهینه، باید هر عملی را که منجر به بالاترین ارزش می‌شود انتخاب کند.

۸-۱-۴ تابع مزیت

گاهی در یادگیری تقویتی، نیازی به توصیف میزان خوبی یک عمل به صورت مطلق نیست، بلکه تنها می‌خواهیم بدانیم که چه مقدار بهتر از سایر اعمال به طور متوسط است. به عبارت دیگر، مزیت نسبی آن عمل مورد بررسی قرار می‌گیرد. این مفهوم با تابع مزیت^{۲۷} توضیح داده می‌شود.

تابع مزیت $A^\pi(s, a)$ که مربوط به سیاست π است، توصیف می‌کند که انجام یک عمل خاص a در حالت s چقدر بهتر از انتخاب تصادفی یک عمل بر اساس $\pi(\cdot|s)$ است، با فرض اینکه شما برای همیشه پس از آن مطابق با π عمل می‌کنید. به صورت ریاضی، تابع مزیت به صورت زیر تعریف می‌شود:

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$

که در آن $A^\pi(s, a)$ تابع مزیت برای عمل a در حالت s است. $Q^\pi(s, a)$ تابع ارزش عمل a در حالت s تحت سیاست π است و $V^\pi(s)$ تابع ارزش حالت s تحت سیاست π است. این تابع مزیت نشان می‌دهد که انجام عمل a در حالت s نسبت به میانگین اعمال تحت سیاست π چقدر مزیت دارد. اگر $A^\pi(s, a)$ مثبت باشد، نشان‌دهنده این است که عمل a بهتر از میانگین اعمال است و اگر منفی باشد، نشان‌دهنده کمتر بودن عملکرد آن نسبت به میانگین است.

²⁷ Advantage Function

۲-۴ عامل گرادیان سیاست عمیق قطعی

گرادیان سیاست عمیق قطعی^{۲۸} الگوریتمی است که همزمان یک تابع Q و یک سیاست را یاد می‌گیرد. این الگوریتم برای یادگیری تابع Q از داده‌های غیرسیاست محور^{۲۹} و معادله بلمن استفاده می‌کند. این الگوریتم برای یادگیری سیاست نیز از تابع Q استفاده می‌کند.

این رویکرد وابستگی نزدیکی به یادگیری Q دارد. اگر تابع ارزش-عمل بهینه مشخص باشد، در هر حالت داده‌شده عمل بهینه را می‌توان با حل معادله (۱۷-۴) به دست آورد.

$$a^*(s) = \arg \max_a Q^*(s, a) \quad (۱۷-۴)$$

الگوریتم DDPG ترکیبی از یادگیری تقریبی برای $Q^*(s, a)$ و یادگیری تقریبی برای $a^*(s)$ است و به صورتی طراحی شده است که برای محیط‌هایی با فضاها عمل پیوسته مناسب باشد. آنچه این الگوریتم را برای فضای عمل پیوسته مناسب می‌کند، روش محاسبه $a^*(s)$ است. فرض می‌شود که تابع $Q^*(s, a)$ نسبت به آرگومان عمل مشتق‌پذیر است. مشتق‌پذیری این امکان را می‌دهد که یک روش یادگیری مبتنی بر گرادیان برای سیاست $\mu(s)$ استفاده شود. سپس، به جای اجرای یک بهینه‌سازی زمان‌بر در هر بار محاسبه $\max_a Q(s, a)$ ، می‌توان آن را با رابطه $\max_a Q(s, a) \approx Q(s, \mu(s))$ تقریب زد.

۱-۲-۴ یادگیری Q در DDPG

معادله بلمن که تابع ارزش عمل بهینه $(Q^*(s, a))$ را توصیف می‌کند، در پایین آورده شده است.

$$Q^*(s, a) = r(s, a) + \mathbb{E}_{s' \sim P} \left[\gamma \max_{a'} Q^*(s', a') \right] \quad (۱۸-۴)$$

عبارت $s' \sim P$ به این معنی است که وضعیت بعدی یعنی s' از توزیع احتمال $P(\cdot | s, a)$ نمونه گرفته می‌شود. در معادله بلمن نقطه شروع برای یادگیری $Q^*(s, a)$ یک مقداردهی تقریبی است. پارامترهای شبکه عصبی $Q_\phi(s, a)$ با علامت ϕ نشان داده شده است. مجموعه \mathcal{D} شامل اطلاعات جمع‌آوری شده تغییر از یک حالت به حالت دیگر (s, a, r, s', d) (که d نشان می‌دهد که آیا وضعیت s' پایانی است یا خیر) است. در بهینه‌سازی از تابع خطای میانگین مربعات بلمن^{۳۰} (MSBE) استفاده شده است که معیاری برای نزدیکی Q_ϕ به حالت بهینه برای برآورده کردن معادله بلمن است.

²⁸Deep Deterministic Policy Gradient (DDPG)

²⁹Off-Policy

³⁰Mean Squared Bellman Error

$$L(\phi, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - \left(r + \gamma(1-d) \max_{a'} Q_{\phi}(s', a') \right) \right)^2 \right] \quad (19-4)$$

در الگوریتم DDPG دو طرفند برای عملکرد بهتر استفاده شده است که در ادامه به بررسی آن پرداخته شده است.

- بافرهای تکرار بازی

الگوریتم‌های یادگیری تقویتی جهت آموزش یک شبکه عصبی عمیق برای تقریب $Q^*(s, a)$ از بافرهای تکرار بازی^{۳۱} تجربه شده استفاده می‌کنند. این مجموعه \mathcal{D} شامل تجربیات قبلی عامل است. برای داشتن رفتار پایدار در الگوریتم، بافر تکرار بازی باید به اندازه کافی بزرگ باشد تا شامل یک دامنه گسترده از تجربیات شود. انتخاب داده‌های بافر به دقت انجام شده است چرا که اگر فقط از داده‌های بسیار جدید استفاده شود، بیش‌برازش^{۳۲} رخ می‌دهد و اگر از تجربه بیش از حد استفاده شود، ممکن است فرآیند یادگیری کند شود.

- شبکه‌های هدف

الگوریتم‌های یادگیری Q از شبکه‌های هدف استفاده می‌کنند. اصطلاح زیر به عنوان هدف شناخته می‌شود.

$$r + \gamma(1-d) \max_{a'} Q_{\phi}(s', a') \quad (20-4)$$

در هنگام کمینه کردن تابع خطای میانگین مربعات بلمن، سعی شده است تا تابع Q شبیه‌تر به هدف یعنی رابطه (۲۰-۴) شود. اما مشکل این است که هدف بستگی به پارامترهای در حال آموزش ϕ دارد. این باعث ایجاد ناپایداری در کمینه کردن تابع خطای میانگین مربعات بلمن می‌شود. راه حل آن استفاده از یک مجموعه پارامترهایی است که با تأخیر زمانی به ϕ نزدیک می‌شوند. به عبارت دیگر، یک شبکه دوم ایجاد می‌شود که به آن شبکه هدف گفته می‌شود. شبکه هدف پارامترهای شبکه اول را با تأخیر دنبال می‌کند. پارامترهای شبکه هدف با نشان ϕ_{targ} نشان داده می‌شوند. در الگوریتم DDPG، شبکه هدف در هر به‌روزرسانی شبکه اصلی، با میانگین‌گیری پولیاک^{۳۳} به صورت زیر به‌روزرسانی می‌شود.

$$\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi \quad (21-4)$$

در رابطه بالا ρ یک ابرپارامتر^{۳۴} است که بین صفر و یک انتخاب می‌شود. در این پژوهش این مقدار نزدیک به یک در نظر گرفته شده است.

³¹Replay Buffers

³²Overfit

³³Polyak Averaging

³⁴Hyperparameter

الگوریتم DDPG نیاز به یک شبکه سیاست هدف ($\mu_{\theta_{\text{targ}}}$) برای محاسبه عمل‌هایی که به‌طور تقریبی بیشینه $Q_{\phi_{\text{targ}}}$ را حاصل کند، را دارد. برای رسیدن به این شبکه سیاست هدف از همان روشی که تابع Q به دست می‌آید یعنی با میانگین‌گیری پولیاک از پارامترهای سیاست در طول زمان آموزش استفاده می‌شود.

با در نظر گرفتن موارد اشاره‌شده، یادگیری Q در DDPG با کمینه‌کردن تابع خطای میانگین مربعات بلمن (MSBE) یعنی معادله (۲۲-۴) با استفاده از کاهش گرادیان تصادفی^{۳۵} انجام می‌شود.

$$L(\phi, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi}(s, a) - (r + \gamma(1-d)Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))) \right)^2 \right] \quad (22-4)$$

۲-۲-۴ سیاست در DDPG

در این بخش یک سیاست تعیین‌شده $\mu_{\theta}(s)$ یاد گرفته می‌شود تا عملی را انجام می‌دهد که بیشینه $Q_{\phi}(s, a)$ رخ دهد. از آنجا که فضای عمل پیوسته است و فرض شده‌است که تابع Q نسبت به عمل مشتق‌پذیر است، رابطه زیر با استفاده از صعود گرادیان^{۳۶} (تنها نسبت به پارامترهای سیاست) بیشینه می‌شود.

$$\max_{\theta} \mathbb{E}_{s \sim \mathcal{D}} [Q_{\phi}(s, \mu_{\theta}(s))] \quad (23-4)$$

۳-۲-۴ اکتشاف و بهره‌برداری در DDPG

برای بهبود اکتشاف^{۳۷} در سیاست‌های DDPG، در زمان آموزش نویز به عمل‌ها اضافه می‌شود. نویسندگان مقاله DDPG [۵۷] توصیه کرده‌اند که نویز OU^{۳۸} با هم‌بندی زمانی^{۳۹} اضافه شود. در زمان بهره‌برداری^{۴۰} سیاست، از آنچه یاد گرفته است، نویز به عمل‌ها اضافه نمی‌شود.

۴-۲-۴ شبکه‌کد DDPG

در این بخش، شبکه‌کد الگوریتم DDPG پیاده‌سازی شده آورده شده‌است. در این پژوهش الگوریتم ۱ در محیط پایتون با استفاده از کتابخانه TensorFlow [۵۸] پیاده‌سازی شده‌است.

³⁵Stochastic Gradient Descent

³⁶Gradient Ascent

³⁷Exploration

³⁸Ornstein-Uhlenbeck

³⁹Time-Correlated

⁴⁰Exploitation

ورودی: پارامترهای اولیه سیاست (θ) ، پارامترهای تابع $Q(\phi)$ ، بافر تکرار بازی خالی (\mathcal{D})

۱: پارامترهای هدف را برابر با پارامترهای اصلی قرار دهید $\phi_{\text{targ}} \leftarrow \phi, \theta_{\text{targ}} \leftarrow \theta$

۲: تا وقتی همگرایی رخ دهد:

۳: وضعیت s را مشاهده کرده و عمل $a = \text{clip}(\mu_\theta(s) + \epsilon, a_{\text{Low}}, a_{\text{High}})$ را انتخاب کنید به طوری که $\epsilon \sim \mathcal{N}$ است.

۴: عمل a را در محیط اجرا کنید.

۵: وضعیت بعدی s' ، پاداش r و سیگنال پایان d را مشاهده کنید تا نشان دهد آیا s' پایانی است یا خیر.

۶: اگر s' پایانی است، وضعیت محیط را بازنشانی کنید.

۷: اگر زمان بهروزرسانی فرا رسیده است:

۸: به ازای هر تعداد بهروزرسانی:

۹: یک دسته تصادفی گذر از یک حالت به حالت دیگر، $B = \{(s, a, r, s', d)\}$ ، از \mathcal{D} نمونه‌گیری شود.

۱۰: هدف را محاسبه کنید:

$$y(r, s', d) = r + \gamma(1 - d)Q_{\phi_{\text{targ}}}(s', \mu_{\theta_{\text{targ}}}(s'))$$

۱۱: تابع Q را با یک مرحله از نزول گرادیان با استفاده از رابطه زیر بهروزرسانی کنید:

$$\nabla_{\phi} \frac{1}{|B|} \sum_{(s, a, r, s', d) \in B} (Q_{\phi}(s, a) - y(r, s', d))^2$$

۱۲: سیاست را با یک مرحله از صعود گرادیان با استفاده از رابطه زیر بهروزرسانی کنید:

$$\nabla_{\theta} \frac{1}{|B|} \sum_{s \in B} Q_{\phi}(s, \mu_{\theta}(s))$$

۱۳: شبکه‌های هدف را با استفاده از معادلات زیر بهروزرسانی کنید:

$$\phi_{\text{targ}} \leftarrow \rho \phi_{\text{targ}} + (1 - \rho) \phi$$

$$\theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$$

۳-۴ عامل گرادیان سیاست عمیق قطعی تاخیری دوگانه

عامل گرادیان سیاست عمیق قطعی تاخیری دوگانه^{۴۱} یکی از الگوریتم‌های یادگیری تقویتی است که برای حل مسائل کنترل در محیط‌های پیوسته طراحی شده است. این الگوریتم بر اساس الگوریتم DDPG توسعه یافته و با استفاده از تکنیک‌های مختلف، پایداری و کارایی یادگیری را بهبود می‌بخشد. در حالی که DDPG گاهی اوقات می‌تواند عملکرد بسیار خوبی داشته باشد، اما اغلب نسبت به ابرپارامترها و سایر انواع تنظیمات یادگیری حساس است. یک حالت رایج شکست عامل DDPG در یادگیری این است که تابع Q یادگرفته شده شروع به بیش‌برآورد مقادیر Q می‌کند که منجر به واگرایی سیاست می‌شود. واگرایی به این دلیل رخ می‌دهد که در فرآیند یادگیری سیاست از تخمین تابع Q استفاده می‌شود که افزایش خطای تابع Q منجر به ناپایداری در یادگیری سیاست می‌شود.

الگوریتم TD3 (Twin Delayed DDPG) از دو ترفند زیر جهت بهبود مشکلات اشاره شده استفاده می‌کند.

- یادگیری دوگانه‌ی محدود شده^{۴۲}: الگوریتم TD3 به جای یک تابع Q ، دو تابع Q_{ϕ_1} و Q_{ϕ_2} را یاد می‌گیرد (از این رو دوگانه^{۴۳} نامیده می‌شود) و از کوچک‌ترین مقدار این دو Q_{ϕ_1} و Q_{ϕ_2} در تابع بلمن استفاده می‌شود. نحوه محاسبه هدف بر اساس دو تابع Q اشاره شده در رابطه (۴-۲۴) آورده شده است.

$$y(r, s', d) = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_i, \text{targ}}(s', a'(s')) \quad (۴-۲۴)$$

سپس، در هر دو تابع Q_{ϕ_1} و Q_{ϕ_2} یادگیری انجام می‌شود.

$$L(\phi_1, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left(Q_{\phi_1}(s, a) - y(r, s', d) \right)^2 \quad (۴-۲۵)$$

$$L(\phi_2, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left(Q_{\phi_2}(s, a) - y(r, s', d) \right)^2 \quad (۴-۲۶)$$

- به‌روزرسانی‌های تاخیری سیاست^{۴۴}: الگوریتم TD3 سیاست را با تاخیر بیشتری نسبت به تابع Q به‌روزرسانی می‌کند. در مرجع [۵۹] توصیه شده است که برای هر دو به‌روزرسانی تابع Q ، یک به‌روزرسانی سیاست انجام شود.

^{۴۱}Twin Delayed Deep Deterministic Policy Gradient (TD3)

^{۴۲}Clipped Double-Q Learning

^{۴۳}twin

^{۴۴}Delayed Policy Updates

این دو ترفند منجر به بهبود قابل توجه عملکرد TD3 نسبت به DDPG پایه می‌شوند. در نهایت سیاست با پیشنهاد کردن Q_{ϕ_1} آموخته می‌شود:

$$\max_{\theta} E_{s \sim \mathcal{D}} [Q_{\phi_1}(s, \mu_{\theta}(s))] \quad (27-4)$$

۱-۳-۴ اکتشاف و بهره‌برداری در TD3

الگوریتم TD3 یک سیاست قطعی را به صورت غیرسیاست محور آموزش می‌دهد. از آنجایی که سیاست قطعی است، در ابتدا عامل تنوع کافی از اعمال را برای یافتن روش‌های مفید امتحان نمی‌کند. برای بهبود اکتشاف سیاست‌های TD3، در زمان آموزش نویز به عمل‌ها اضافه می‌شود. در این پژوهش، نویز گاوسی با میانگین صفر بدون هم‌بندی زمانی اعمال شده‌است. شدت نویز جهت بهره‌برداری بهتر در طول زمان کاهش می‌یابد.

۲-۳-۴ شبه‌کد TD3

در این بخش الگوریتم TD3 پیاده‌سازی شده آورده شده‌است. در این پژوهش الگوریتم ۴ در محیط پایتون با استفاده از کتابخانه PyTorch [۶۰] پیاده‌سازی شده‌است.

الگوریتم ۲ عامل گرادیان سیاست عمیق قطعی تاخیری دوگانه

ورودی: پارامترهای اولیه سیاست (θ) ، پارامترهای تابع Q (ϕ_1, ϕ_2) ، بافر بازی خالی (\mathcal{D})

۱: پارامترهای هدف را برابر با پارامترهای اصلی قرار دهید $\phi_{\text{targ},2} \leftarrow \phi_2, \phi_{\text{targ},1} \leftarrow \phi_1, \theta_{\text{targ}} \leftarrow \theta$

۲: تا وقتی همگرایی رخ دهد:

۳: وضعیت (s) را مشاهده کرده و عمل $a = \text{clip}(\mu_\theta(s) + \epsilon, a_{\text{Low}}, a_{\text{High}})$ را انتخاب کنید، به طوری که $\epsilon \sim \mathcal{N}$ است.

۴: عمل a را در محیط اجرا کنید.

۵: وضعیت بعدی s' ، پاداش r و سیگنال پایان d را مشاهده کنید تا نشان دهد آیا s' پایانی است یا خیر.

۶: اگر s' پایانی است، وضعیت محیط را بازنشانی کنید.

۷: اگر زمان به روزرسانی فرا رسیده است:

۸: به ازای j در هر تعداد به روزرسانی:

۹: یک دسته تصادفی گذر از یک حالت به حالت دیگر، $B = \{(s, a, r, s', d)\}$ ، از \mathcal{D} نمونه‌گیری شود.

۱۰: هدف را محاسبه کنید:

$$y(r, s', d) = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', a'(s'))$$

۱۱: تابع Q را با یک مرحله از نزول گرادیان با استفاده از رابطه زیر به روزرسانی کنید:

$$\nabla_{\phi_i} \frac{1}{|B|} \sum_{(s,a,r,s',d) \in B} (Q_{\phi_i}(s, a) - y(r, s', d))^2 \quad \text{for } i = 1, 2$$

۱۲: اگر باقیمانده j بر تاخیر سیاست برابر ۰ باشد :

۱۳: سیاست را با یک مرحله از صعود گرادیان با استفاده از رابطه زیر به روزرسانی کنید:

$$\nabla_{\theta} \frac{1}{|B|} \sum_{s \in B} Q_{\phi_1}(s, \mu_\theta(s))$$

۱۴: شبکه‌های هدف را با استفاده از معادلات زیر به روزرسانی کنید:

$$\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i \quad \text{for } i = 1, 2$$

$$\theta_{\text{targ}} \leftarrow \rho \theta_{\text{targ}} + (1 - \rho) \theta$$

۴-۴ عامل عملگر نقاد نرم

عملگر نقاد نرم^{۴۵} الگوریتمی است که یک سیاست تصادفی را به صورت غیرسیاست محور بهینه می کند و پلی بین بهینه سازی سیاست تصادفی و رویکردهای غیرسیاست محور مانند DDPG ایجاد می کند. این الگوریتم جانشین مستقیم TD3 نیست (زیرا تقریباً همزمان منتشر شده است)؛ اما، ترفند یادگیری دوگانه محدود شده را در خود جای داده است و به دلیل سیاست تصادفی SAC، از روشی به نام صاف کردن سیاست هدف^{۴۶} استفاده شده است. یکی از ویژگی های اصلی SAC، تنظیم آنتروپی است. آنتروپی معیاری از تصادفی بودن انتخاب عمل در سیاست است. آموزش سیاست در جهت تعادل بهینه بین آنتروپی و بیشینه سازی بازده مورد انتظار است. این شرایط ارتباط نزدیکی با تعادل اکتشاف-بهره برداری دارد. افزایش آنتروپی منجر به اکتشاف بیشتر می شود که می تواند یادگیری را در مراحل بعدی تسریع کند. همچنین، می تواند از همگرایی زودهنگام سیاست به یک بهینه محلی بد جلوگیری کند. برای توضیح SAC، ابتدا باید به بررسی یادگیری تقویتی تنظیم شده با آنتروپی^{۴۷} پرداخته شود. در RL تنظیم شده با آنتروپی، روابط تابع ارزش کمی متفاوت است.

۱-۴-۴ یادگیری تقویتی تنظیم شده با آنتروپی

آنتروپی معیاری برای سنجش میزان عدم قطعیت یا تصادفی بودن یک متغیر تصادفی یا توزیع احتمال آن است. به عبارت دقیق تر، آنتروپی برای یک توزیع احتمال، میانگین اطلاعات حاصل از نمونه برداری از آن توزیع را اندازه گیری می کند. در زمینه یادگیری تقویتی، تنظیم با آنتروپی تکنیکی است که با افزودن یک ترم متناسب با آنتروپی سیاست به تابع هدف، عامل را تشویق به اکتشاف بیشتر و اتخاذ سیاست های تصادفی تر می کند. این امر می تواند به بهبود پایداری فرآیند یادگیری و جلوگیری از همگرایی زودهنگام به بهینه های محلی کمک کند. فرض کنید X یک متغیر تصادفی پیوسته با تابع چگالی احتمال $p(x)$ باشد. آنتروپی $H(X)$ این متغیر تصادفی به صورت امید ریاضی لگاریتم منفی چگالی احتمال آن تعریف می شود:

$$H(X) = \mathbb{E}_{x \sim p} [-\log p(x)] \quad (۲۸-۴)$$

۲-۴-۴ سیاست در SAC

در یادگیری تقویتی تنظیم شده با آنتروپی، عامل در هر مرحله زمانی متناسب با آنتروپی سیاست در آن مرحله زمانی پاداش دریافت می کند. بر اساس توضیحات اشاره شده روابط یادگیری تقویتی به صورت زیر می شود.

⁴⁵Soft Actor Critic (SAC)

⁴⁶Target Policy Smoothing

⁴⁷Entropy-Regularized Reinforcement Learning

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\tau \sim \pi} \sum_{t=0}^{\infty} \gamma^t \left(R(s_t, a_t, s_{t+1}) + \alpha H(\pi(\cdot|s_t)) \right) \quad (29-4)$$

که در آن $(\alpha > 0)$ ضریب مبادله^{۴۸} است.

۳-۴-۴ تابع ارزش در SAC

اکنون می‌توان تابع ارزش کمی متفاوت را بر اساس این مفهوم تعریف کرد. V^{π} به گونه‌ای تغییر می‌کند که پاداش‌های آنتروپی را از هر مرحله زمانی شامل می‌شود.

$$V^{\pi}(s) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t \left(R(s_t, a_t, s_{t+1}) + \alpha H(\pi(\cdot|s_t)) \right) \middle| s_0 = s \right] \quad (30-4)$$

۴-۴-۴ تابع Q در SAC

تابع Q^{π} به گونه‌ای تغییر می‌کند که پاداش‌های آنتروپی را از هر مرحله زمانی به جز مرحله اول شامل می‌شود.

$$Q^{\pi}(s, a) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t, s_{t+1}) + \alpha \sum_{t=1}^{\infty} \gamma^t H(\pi(\cdot|s_t)) \middle| s_0 = s, a_0 = a \right] \quad (31-4)$$

با این تعاریف رابطه V^{π} و Q^{π} به صورت زیر است.

$$V^{\pi}(s) = \mathbb{E}_{a \sim \pi} [Q^{\pi}(s, a)] + \alpha H(\pi(\cdot|s)) \quad (32-4)$$

۵-۴-۴ معادله بلمن در SAC

معادله بلمن در حالت تنظیم‌شده با آنتروپی به صورت زیر ارائه می‌شود.

$$Q^{\pi}(s, a) = \mathbb{E}_{\substack{s' \sim P \\ a' \sim \pi}} [R(s, a, s') + \gamma (Q^{\pi}(s', a') + \alpha H(\pi(\cdot|s')))] \quad (33-4)$$

$$= \mathbb{E}_{s' \sim P} [R(s, a, s') + \gamma V^{\pi}(s')] \quad (34-4)$$

⁴⁸Trade-Off

۶-۴-۴ یادگیری Q

با در نظر گرفتن موارد اشاره شده، یادگیری Q در SAC با کمینه کردن تابع خطای میانگین مربعات بلمن (MSBE) یعنی معادله (۳۵-۴) با استفاده از کاهش گرادیان انجام می شود.

$$L(\phi_i, \mathcal{D}) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} \left[\left(Q_{\phi_i}(s, a) - y(r, s', d) \right)^2 \right] \quad (۳۵-۴)$$

در معادله (۳۵-۴) تابع هدف برای روش یادگیری تقویتی SAC به صورت زیر تعریف می شود.

$$y(r, s', d) = r + \gamma(1 - d) \left(\min_{j=1,2} Q_{\phi_{\text{targ},j}}(s', \tilde{a}') - \alpha \log \pi_{\theta}(\tilde{a}'|s') \right), \quad \tilde{a}' \sim \pi_{\theta}(\cdot|s') \quad (۳۶-۴)$$

نماد عمل بعدی را به جای a' به \tilde{a}' تغییر داده شده تا مشخص شود که عمل های بعدی باید از آخرین سیاست نمونه برداری شوند در حالی که r و s باید از بافر تکرار بازی آمده باشند.

۷-۴-۴ سیاست در SAC

سیاست باید در هر وضعیت برای به حداکثر رساندن بازگشت مورد انتظار آینده به همراه آنتروپی مورد انتظار آینده عمل کند. یعنی باید $V^{\pi}(s)$ را به حداکثر برساند، بسط تابع ارزش در ادامه آمده است.

$$V^{\pi}(s) = \mathbb{E}_{a \sim \pi} [Q^{\pi}(s, a)] + \alpha H(\pi(\cdot|s)) \quad (۳۷-۴)$$

$$= \mathbb{E}_{a \sim \pi} [Q^{\pi}(s, a) - \alpha \log \pi(a|s)] \quad (۳۸-۴)$$

در بهینه سازی سیاست از ترفند پارامترسازی مجدد^{۴۹} استفاده می شود، که در آن نمونه ای از $\pi_{\theta}(\cdot|s)$ با محاسبه یک تابع قطعی از وضعیت، پارامترهای سیاست و نویز مستقل استخراج می شود. در این پژوهش مانند نویسندگان مقاله SAC [۶۱]، از یک سیاست گاوسی فشرده^{۵۰} استفاده شده است. بر اساس این روش نمونه ها مطابق با رابطه زیر بدست می آیند:

$$\tilde{a}_{\theta}(s, \xi) = \tanh(\mu_{\theta}(s) + \sigma_{\theta}(s) \odot \xi), \quad \xi \sim \mathcal{N} \quad (۳۹-۴)$$

در رابطه بالا \odot نماد ضرب داخلی است. تابع \tanh در سیاست SAC تضمین می کند که اعمال در یک محدوده متناهی محدود شوند. این مورد در سیاست های VPG، TRPO و PPO وجود ندارد. همچنین اعمال این تابع توزیع را از حالت گاوسی تغییر می دهد.

⁴⁹Reparameterization

⁵⁰Squashed Gaussian Policy

در الگوریتم SAC با استفاده از ترفند پارامتری‌سازی مجدد، عمل‌ها از یک توزیع نرمال به‌وسیله نویز تصادفی تولید شده و به این ترتیب امکان محاسبه مشتق‌ها به‌طور مستقیم از طریق تابع توزیع فراهم می‌شود، که باعث ثبات و کارایی بیشتر در آموزش می‌شود. اما در حالت بدون پارامتری‌سازی مجدد، عمل‌ها مستقیماً از توزیع سیاست نمونه‌برداری می‌شوند و محاسبه گرادیان نیازمند استفاده از ترفند نسبت احتمال^{۵۱} است که معمولاً باعث افزایش واریانس و ناپایداری در آموزش می‌شود.

$$\mathbb{E}_{a \sim \pi_\theta} [Q^{\pi_\theta}(s, a) - \alpha \log \pi_\theta(a|s)] = \mathbb{E}_{\xi \sim \mathcal{N}} [Q^{\pi_\theta}(s, \tilde{a}_\theta(s, \xi)) - \alpha \log \pi_\theta(\tilde{a}_\theta(s, \xi)|s)] \quad (۴۰-۴)$$

برای به‌دست آوردن تابع هزینه سیاست، گام نهایی این است که باید Q^{π_θ} را با یکی از تخمین‌زننده‌های تابع خود جایگزین کنیم. برخلاف TD3 که از Q_{ϕ_1} (فقط اولین تخمین‌زننده Q) استفاده می‌کند، SAC از $\min_{j=1,2} Q_{\phi_j}$ (کمینه‌ی دو تخمین‌زننده Q) استفاده می‌کند. بنابراین، سیاست طبق رابطه زیر بهینه می‌شود:

$$\max_{\theta} \mathbb{E}_{\substack{s \sim \mathcal{D} \\ \xi \sim \mathcal{N}}} \left[\min_{j=1,2} Q_{\phi_j}(s, \tilde{a}_\theta(s, \xi)) - \alpha \log \pi_\theta(\tilde{a}_\theta(s, \xi)|s) \right] \quad (۴۱-۴)$$

که تقریباً مشابه بهینه‌سازی سیاست در DDPG و TD3 است، به جز ترفند min-double-Q، تصادفی‌بودن و عبارت آنتروپی.

۸-۴-۴ اکتشاف و بهره‌برداری در SAC

الگوریتم SAC یک سیاست تصادفی با تنظیم‌سازی آنتروپی آموزش می‌دهد و به صورت سیاست محور به اکتشاف می‌پردازد. ضریب تنظیم آنتروپی α به طور صریح تعادل بین اکتشاف و بهره‌برداری را کنترل می‌کند، به‌طوری‌که مقادیر بالاتر α به اکتشاف بیشتر و مقادیر پایین‌تر α به بهره‌برداری بیشتر منجر می‌شود. مقدار بهینه α (که به یادگیری پایدارتر و پاداش بالاتر منجر می‌شود) ممکن است در محیط‌های مختلف متفاوت باشد و نیاز به تنظیم دقیق داشته باشد. در زمان آزمایش، برای ارزیابی میزان بهره‌برداری سیاست از آنچه یاد گرفته است، تصادفی بودن را حذف کرده و از عمل میانگین به جای نمونه‌برداری از توزیع استفاده می‌کنیم. این روش معمولاً عملکرد را نسبت به سیاست تصادفی بهبود می‌بخشد.

⁵¹Likelihood Ratio Trick

۹-۴-۴ شبکه‌د SAC

در این بخش الگوریتم SAC پیاده‌سازی شده آورده شده‌است. در این پژوهش الگوریتم ۳ در محیط پایتون با استفاده از کتابخانه PyTorch [۶۰] پیاده‌سازی شده است.

الگوریتم ۳ عامل عملگرد نقاد نرم

ورودی: پارامترهای اولیه سیاست (θ) ، پارامترهای تابع Q (ϕ_1, ϕ_2) ، بافر بازی خالی (\mathcal{D})

۱: پارامترهای هدف را برابر با پارامترهای اصلی قرار دهید $\theta_{\text{targ}} \leftarrow \theta$ ، $\phi_{\text{targ},1} \leftarrow \phi_1$ ، $\phi_{\text{targ},2} \leftarrow \phi_2$

۲: تا وقتی همگرایی رخ دهد:

۳: وضعیت (s) را مشاهده کرده و عمل $a \sim \pi_{\theta}(\cdot|s)$ را انتخاب کنید.

۴: عمل a را در محیط اجرا کنید.

۵: وضعیت بعدی s' ، پاداش r و سیگنال پایان d را مشاهده کنید تا نشان دهد آیا s' پایانی است یا

خیر.

۶: اگر s' پایانی است، وضعیت محیط را بازنشانی کنید.

۷: اگر زمان به‌روزرسانی فرا رسیده است:

۸: به ازای j در هر تعداد به‌روزرسانی:

۹: یک دسته تصادفی گذر از یک حالت به حالت دیگر، $B = \{(s, a, r, s', d)\}$ ، از \mathcal{D}

نمونه‌گیری شود.

۱۰: هدف را محاسبه کنید:

$$y(r, s', d) = r + \gamma(1 - d) \left(\min_{i=1,2} Q_{\phi_{\text{targ},i}}(s', \tilde{a}') - \alpha \log \pi_{\theta}(\tilde{a}'|s') \right), \quad \tilde{a}' \sim \pi_{\theta}(\cdot|s')$$

۱۱: تابع Q را با یک مرحله از نزول گرادیان با استفاده از رابطه زیر به‌روزرسانی کنید:

$$\nabla_{\phi_i} \frac{1}{|B|} \sum_{(s,a,r,s',d) \in B} (Q_{\phi_i}(s, a) - y(r, s', d))^2 \quad \text{for } i = 1, 2$$

۱۲: سیاست را با یک مرحله از صعود گرادیان با استفاده از رابطه زیر به‌روزرسانی کنید:

$$\nabla_{\theta} \frac{1}{|B|} \sum_{s \in B} \left(\min_{i=1,2} Q_{\phi_i}(s, \tilde{a}_{\theta}(s)) - \alpha \log \pi_{\theta}(\tilde{a}_{\theta}(s)|s) \right)$$

۱۳: شبکه‌های هدف را با استفاده از معادلات زیر به‌روزرسانی کنید:

$$\phi_{\text{targ},i} \leftarrow \rho \phi_{\text{targ},i} + (1 - \rho) \phi_i \quad \text{for } i = 1, 2$$

۵-۴ عامل بهینه‌سازی سیاست مجاور

الگوریتم بهینه‌سازی سیاست مجاور^{۵۲} یک الگوریتم بهینه‌سازی سیاست مبتنی بر گرادینان است که برای حل مسائل کنترل مسئله‌های یادگیری تقویتی استفاده می‌شود. این الگوریتم از الگوریتم TRPO^{۵۳} الهام گرفته شده است و با اعمال تغییراتی بر روی آن، سرعت و کارایی آن را افزایش داده است. در این بخش به بررسی این الگوریتم و نحوه عملکرد آن می‌پردازیم. الگوریتم PPO همانند سایر الگوریتم‌های یادگیری تقویتی، به دنبال یافتن بهترین گام ممکن برای بهبود عملکرد سیاست با استفاده از داده‌های موجود است. این الگوریتم تلاش می‌کند تا از گام‌های بزرگ که می‌توانند منجر به افت ناگهانی عملکرد شوند، اجتناب کند. برخلاف روش‌های پیچیده‌تر مرتبه دوم مانند TRPO، PPO از مجموعه‌ای از روش‌های مرتبه اول ساده‌تر برای حفظ نزدیکی سیاست‌های جدید به سیاست‌های قبلی استفاده می‌کند. این سادگی در پیاده‌سازی، PPO را به روشی کارآمدتر تبدیل می‌کند، در حالی که از نظر تجربی نشان داده شده است که عملکردی حداقل به اندازه TRPO دارد. از جمله ویژگی‌های مهم این الگوریتم می‌توان به سیاست محور بودن آن اشاره کرد. این الگوریتم برای عامل‌های یادگیری تقویتی که سیاست‌های پیوسته و گسسته دارند، مناسب است.

الگوریتم PPO دارای دو گونه اصلی PPO-Clip و PPO-Penalty است. در ادامه به بررسی هر یک از این دو گونه پرداخته شده است.

- **روش PPO-Penalty:** روش PPO-Penalty به دنبال حل تقریبی و به‌روزرسانی با محدودیت واگرایی کولباک-لیبلر^{۵۴} است، مشابه روشی که در الگوریتم TRPO استفاده شده است. با این حال، به جای اعمال یک محدودیت سخت^{۵۵}، PPO-Penalty واگرایی KL را در تابع هدف جریمه می‌کند. این جریمه به طور خودکار در طول آموزش تنظیم می‌شود تا از افت ناگهانی عملکرد جلوگیری کند.

- **روش PPO-Clip:** در این روش، هیچ عبارت واگرایی KL در تابع هدف وجود ندارد و هیچ محدودیتی اعمال نمی‌شود. در عوض، PPO-Clip از یک عملیات بریدن^{۵۶} خاص در تابع هدف استفاده می‌کند تا انگیزه سیاست جدید برای دور شدن از سیاست قبلی را از بین ببرد.

در این پژوهش از روش PPO-Clip برای آموزش عامل‌های یادگیری تقویتی استفاده شده است.

⁵²Proximal Policy Optimization (PPO)

⁵³Trust Region Policy Optimization

⁵⁴Kullback-Leibler (KL) Divergence

⁵⁵Hard Constraint

⁵⁶Clipping

۴-۵-۱ سیاست در الگوریتم PPO

تابع سیاست در الگوریتم PPO به صورت یک شبکه عصبی پیاده‌سازی شده‌است. این شبکه عصبی ورودی‌های محیط را دریافت کرده و اقدامی را که باید عامل انجام دهد را تولید می‌کند. این شبکه عصبی می‌تواند شامل چندین لایه پنهان با توابع فعال‌سازی مختلف باشد. در این پژوهش از یک شبکه عصبی با سه لایه پنهان و تابع فعال‌سازی ReLu استفاده شده‌است. تابع سیاست در الگوریتم PPO به صورت زیر به‌روزرسانی می‌شود:

$$\theta_{k+1} = \arg \max_{\theta} E_{s,a \sim \pi_{\theta_k}} [L(s, a, \theta_k, \theta)] \quad (42-4)$$

در این پژوهش برای به حداکثر رساندن تابع هدف، چندین گام بهینه‌سازی گرادیان کاهشی تصادفی^{۵۷} اجرا شده‌است. در معادله بالا L به‌صورت زیر تعریف شده‌است:

$$L(s, a, \theta_k, \theta) = \min \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s, a), \text{clip} \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)}, 1 - \epsilon, 1 + \epsilon \right) A^{\pi_{\theta_k}}(s, a) \right) \quad (43-4)$$

که در آن ϵ یک ابرپارامتر است که مقدار آن معمولاً کوچک است. این ابرپارامتر مشخص می‌کند که چقدر اندازه گام بهینه‌سازی باید محدود شود. در این پژوهش مقدار $\epsilon = 0.2$ انتخاب شده‌است. جهت سادگی در پیاده‌سازی معادله (۴۳-۴) به معادله تغییر داده شده‌است.

$$L(s, a, \theta_k, \theta) = \min \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}(s, a), g(\epsilon, A^{\pi_{\theta_k}}(s, a)) \right) \quad (44-4)$$

که تابع g به صورت زیر تعریف شده‌است.

$$g(\epsilon, A) = \begin{cases} (1 + \epsilon)A & A \geq 0 \\ (1 - \epsilon)A & A < 0 \end{cases} \quad (45-4)$$

در حالی که این نوع محدود کردن (PPO-Clip) تا حد زیادی به اطمینان از به‌روزرسانی‌های معقول سیاست کمک می‌کند، همچنان ممکن است سیاستی به‌دست آید که بیش از حد از سیاست قدیمی دور باشد. برای جلوگیری از این امر، پیاده‌سازی‌های مختلف PPO از مجموعه‌ای از ترفندها استفاده می‌کنند. در پیاده‌سازی این پژوهش، از روشی ساده به نام توقف زودهنگام^{۵۸} استفاده شده‌است. اگر میانگین واگرایی کولباک-لیبلر (KL) خط‌مشی جدید از خط‌مشی قدیمی از یک آستانه فراتر رود، گام‌های گرادیان (بهینه‌سازی) را متوقف می‌شوند.

⁵⁷Stochastic Gradient Descent (SGD)

⁵⁸Early Stopping

۲-۵-۴ اکتشاف و بهره‌برداری در PPO

الگوریتم PPO از یک سیاست تصادفی به صورت سیاست‌محور برای آموزش استفاده می‌کند. این به این معنی است که اکتشاف محیط با نمونه‌گیری عمل‌ها بر اساس آخرین نسخه از این سیاست تصادفی انجام می‌شود. میزان تصادفی بودن انتخاب عمل به شرایط اولیه و فرآیند آموزش بستگی دارد.

در طول آموزش، سیاست به طور کلی به تدریج کمتر تصادفی می‌شود، زیرا قانون به‌روزرسانی آن را تشویق می‌کند تا از پاداش‌هایی که قبلاً پیدا کرده است، بهره‌برداری کند. البته این موضوع می‌تواند منجر به رسیدن سیاست به بهینه‌های محلی^{۵۹} شود.

۳-۵-۴ شبه‌کد PPO

در این بخش الگوریتم PPO پیاده‌سازی شده آورده شده است. در این پژوهش الگوریتم^۴ در محیط پایتون با استفاده از کتابخانه PyTorch [۶۰] پیاده‌سازی شده است.

⁵⁹Local Optima

الگوریتم ۴ بهینه‌سازی سیاست مجاور (PPO-Clip)

ورودی: پارامترهای اولیه سیاست (θ_0) ، پارامترهای تابع ارزش (ϕ_0)

۱: به ازای $k = 0, 1, 2, \dots$:

۲: مجموعه‌ای از مسیرها به نام $\mathcal{D}_k = \{\tau_i\}$ با اجرای سیاست $\pi_k = \pi(\theta_k)$ در محیط جمع‌آوری شود.

۳: پاداش‌های باقی‌مانده (\hat{R}_t) محاسبه شود.

۴: برآوردهای مزیت را محاسبه کنید، \hat{A}_t (با استفاده از هر روش تخمین مزیت) بر اساس تابع ارزش فعلی V_{ϕ_k} .

۵: سیاست را با به حداکثر رساندن تابع هدف PPO-Clip به‌روزرسانی کنید:

$$\theta_{k+1} = \arg \max_{\theta} \frac{1}{|\mathcal{D}_k|T} \sum_{\tau \in \mathcal{D}_k} \sum_{t=0}^T \min \left(\frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_k}(a_t|s_t)} A^{\pi_{\theta_k}}(s_t, a_t), g(\epsilon, A^{\pi_{\theta_k}}(s_t, a_t)) \right)$$

معمولاً از طریق گرادیان افزایشی تصادفی Adam.

۶: برازش تابع ارزش با رگرسیون بر روی میانگین مربعات خطا:

$$\phi_{k+1} = \arg \min_{\phi} \frac{1}{|\mathcal{D}_k|T} \sum_{\tau \in \mathcal{D}_k} \sum_{t=0}^T \left(V_{\phi}(s_t) - \hat{R}_t \right)^2$$

معمولاً از طریق برخی از الگوریتم‌های کاهشی گرادیان.

فصل ۵

شبیه‌سازی عامل در محیط سه جسمی

در این فصل، فرآیند شبیه‌سازی عامل هوشمند کنترل‌کننده فضاپیما در محیط دینامیکی سه جسمی بررسی شده است. در بخش ۱-۵ به طراحی و در بخش ۲-۵ به شبیه‌سازی عامل هدایت‌کننده مبتنی بر یادگیری تقویتی است پرداخته شده است. این عامل طراحی و شبیه‌سازی شده باید توانایی این را داشته باشد که فضاپیما را به‌طور مؤثر به سمت اهداف تعیین‌شده هدایت کند، در حالی که محدودیت‌هایی نظیر مصرف سوخت و وجود اغتشاش دارد.

۱-۵ طراحی عامل

در این زیربخش، معماری عامل هوشمند کنترل‌کننده فضاپیما در محیط سه‌جسمی شرح داده شده است. این معماری شامل تعریف فضای حالت، عمل و تابع پاداش است.

۱-۱-۵ فضای حالت

فضای حالت^۱ در این پژوهش به‌گونه‌ای طراحی شده است که وضعیت دینامیکی فضاپیما را نسبت به یک مسیر و سرعت مرجع مشخص می‌کند. این فضا شامل اختلاف‌های موقعیت و سرعت از مسیر و سرعت مرجع است و به‌صورت زیر تعریف شده است:

$$S = \{\delta x, \delta y, \delta \dot{x}, \delta \dot{y}\}$$

که در آن:

¹State Space

- $\delta x, \delta y$: اختلاف موقعیت فضایی نسبت به مسیر مرجع در محورهای x, y .
- $\delta \dot{x}, \delta \dot{y}$: اختلاف سرعت فضایی نسبت به سرعت مرجع در محورهای x, y .

هر یک از این متغیرها به طور مستقل وضعیت فضایی را در یک جهت خاص توصیف می‌کنند و امکان تحلیل دقیق انحرافات را فراهم می‌سازند. استفاده از اختلاف‌های موقعیت و سرعت به جای مقادیر مطلق، به دلایل زیر انجام شده است:

- **تمرکز بر انحرافات:** هدف اصلی سیستم کنترلی، کاهش انحرافات از مسیر و سرعت مطلوب است. با استفاده از اختلاف‌ها، کنترلر می‌تواند به طور مستقیم بر این انحرافات اثر بگذارد و نیازی به محاسبه مقادیر مطلق موقعیت و سرعت ندارد.
- **سازگاری با یادگیری تقویتی:** در الگوریتم‌های یادگیری تقویتی، فضاهای حالت مبتنی بر اختلاف معمولاً دامنه محدودتری دارند که فرآیند یادگیری را سریع‌تر و پایدارتر می‌کند.

۵-۱-۲ فضای عمل

فضای عمل^۲ فضایی با پیشران کم مجموعه‌ای از عمل‌های پیوسته است که فضایی می‌تواند در محیط شبیه‌سازی انجام دهد. این فضا به گونه‌ای طراحی شده که امکان اعمال نیرو در جهت‌های مشخص و با مقادیر متناسب با توان واقعی فضاییها فراهم شود. به طور خاص، فضای اقدام شامل موارد زیر است:

- **نیروی اعمال شده در جهت x :** این متغیر پیوسته، مقدار نیرویی را که در جهت محور x به فضایی وارد می‌شود، تعیین می‌کند. دامنه این نیرو بر اساس توان پیشران‌های موجود در فضاییها و واقعی انتخاب شده است. به عبارت دیگر، اگر حداکثر نیروی قابل اعمال در جهت x برابر با $f_{x,\max}$ باشد، این متغیر می‌تواند مقادیری در بازه $[-f_{x,\max}, f_{x,\max}]$ داشته باشد.

- **نیروی اعمال شده در جهت y :** این متغیر پیوسته، مقدار نیرویی را که در جهت محور y به فضایی وارد می‌شود، مشخص می‌کند. مشابه جهت x ، دامنه این نیرو نیز بر اساس توان پیشران‌های موجود تعیین شده و می‌تواند در بازه $[-f_{y,\max}, f_{y,\max}]$ قرار گیرد.

انتخاب این نیروها بر اساس ویژگی‌های واقعی فضاییها، به ویژه توان و محدودیت‌های پیشران‌های آنها، صورت گرفته است. این امر اطمینان می‌دهد که شبیه‌سازی تا حد ممکن به شرایط واقعی نزدیک باشد و نتایج

²Action Space

به دست آمده قابلیت تعمیم به کاربردهای عملی را داشته باشند. همچنین، تعریف فضای اقدام به صورت پیوسته، امکان کنترل دقیق و انعطاف پذیر بر حرکت فضاپیما را فراهم می کند، که برای دستیابی به اهداف کنترلی در محیط های دینامیکی پیچیده ضروری است. به طور خلاصه، فضای اقدام به صورت زیر تعریف می شود:

$$a = \{f_x, f_y \mid f_x \in [-f_{x,\max}, f_{x,\max}], f_y \in [-f_{y,\max}, f_{y,\max}]\}$$

انطباق بازه‌ی فضای عمل با داده‌های واقعی

برای هم تراز کردن شبیه سازی با سخت افزارهای واقعی، از بیشینه‌ی نیروی بی بُعد پیشران‌ها استفاده می شود. جدول زیر نمونه هایی از فضاپیماهای مجهز به پیشران های یونی/الکتریکی را نشان می دهد که مبنای انتخاب بازه‌ی نیروی عمل قرار گرفته شده اند. با توجه به برداری بودن عمل $a = [f_x \ f_y]$ ، کران ها را به دو صورت اعمال شده است:

$$|a| \leq f_{\text{nondim max}}, \quad \text{یا} \quad f_{x,\max} = f_{y,\max} = f_{\text{nondim max}}.$$

با استناد به جدول ۱-۵، مقدار نمونه‌ی 4×10^{-2} شبیه سازی شده با Psyche هم مرتبه و کمتر از DS1 است که باعث شده است بازه‌ی عمل را در چارچوب پیشران های کم تراست واقع گرایانه نگه داشته شود.

جدول ۱-۵: قابلیت های بی بعد پیشران کم تراست فضاپیماهای مختلف در سامانه‌ی زمین-ماه [۵۵].

نام اختصار	نام فضاپیما	$f_{\max, \text{nondim}}$	$M_{3,0}$ (kg)	F_{\max} (mN)
DS1	Deep Space 1	$6.940 \cdot 10^{-2}$	486.3	92.0
Psyche	Psyche	$4.158 \cdot 10^{-2}$	2464	279.3
Dawn	Dawn	$2.741 \cdot 10^{-2}$	1217.8	91.0
LIC	Lunar IceCube	$3.276 \cdot 10^{-2}$	14	1.25
H1	Hayabusa 1	$1.640 \cdot 10^{-2}$	510	22.8
H2	Hayabusa 2	$1.628 \cdot 10^{-2}$	608.6	27.0
s/c	فضاپیمای نمونه	$4 \cdot 10^{-2}$	—	—

۳-۱-۵ تابع پاداش

تابع پاداش^۳ به منظور هدایت رفتار عامل طراحی شده و شامل سه بخش اصلی در طول شبیه‌سازی و یک پاداش نهایی در هنگام پایان است:

- پاداش نهایی برای دستیابی به هدف: در صورت وارد شدن وضعیت سامانه به مجموعه‌ی هدف، شبیه‌سازی بلافاصله خاتمه یافته و یک پاداش بزرگ مثبت به عامل تخصیص داده می‌شود تا ارزشیابی فرایند همگرایی را تقویت کند.
- جریمه نهایی برای دور شدن بیش‌ازحد: اگر وضعیت سامانه از حدود ایمنی تعریف‌شده فراتر رود، اپیزود متوقف شده و یک جریمه بزرگ منفی به عامل تعلق می‌گیرد تا ناپایداری یا گریز از ناحیه‌ی قابل قبول را منعکس کند.
- جریمه برای مصرف سوخت: در طول مسیر، استفاده بیش‌ازحد از پیش‌رانه با جریمه همراه است.
- جریمه برای انحراف از مسیر مرجع: در طول مسیر، انحراف از مسیر مرجع باعث دریافت جریمه متناسب می‌شود.

این دو مؤلفه‌ی ترمینال با هدف تضمین همگرایی سیاست کنترلی به سمت مدار مطلوب طراحی شده‌اند. پاداش مثبت پایان، طیف مسیرهای موفق را برجسته کرده و عامل را به سمت سیاست‌های پایدار هدایت می‌کند؛ در مقابل، جریمه‌ی منفی پایان با ایجاد گرادیان تنبیهی، از انتخاب راهبردهایی که منجر به خروج خطرناک از ناحیه‌ی عملیاتی می‌شوند جلوگیری می‌نماید. تابع پاداش به صورت زیر تعریف می‌شود:

$$r(s, a) = r_{\text{thrust}}(a) + r_{\text{reference}}(s) + r_{\text{terminal}}(s)$$

که در آن مؤلفه‌ها عبارتند از:

$$r_{\text{thrust}}(a) = -k_1 \cdot |a| \quad (۱-۵)$$

$$r_{\text{reference}}(s) = -k_2 \cdot d(s, s_{\text{reference}}) \quad (۲-۵)$$

$$r_{\text{terminal}}(s) = \begin{cases} +R_{\text{goal}} & \text{if } s \in S_{\text{goal}} \\ -R_{\text{fail}} & \text{if } d(s, s_{\text{reference}}) > \epsilon \\ 0 & \text{otherwise} \end{cases} \quad (۳-۵)$$

^۳Reward Function

در این رابطه:

۱. R_{goal} : یک پاداش بزرگ مثبت برای دستیابی به هدف است.

۲. R_{fail} : یک جریمه بزرگ منفی برای خروج از محدوده مجاز است که رفتارهای ناپایدار را به شدت سرکوب می‌کند.

۳. $d(s, s')$: فاصله بین دو وضعیت بوده و به صورت فاصله اقلیدسی محاسبه می‌شود.

ضرایب k_1, k_2 برای تنظیم تعادل بین بهینه‌سازی مصرف سوخت و حفظ نزدیکی به مسیر مرجع استفاده می‌شوند. انتخاب مناسب مقادیر این ضرایب نقش کلیدی در سرعت همگرایی و پایداری الگوریتم یادگیری تقویتی دارد.

۲-۵ شبیه‌سازی عامل

در این زیربخش، فرآیند شبیه‌سازی و آموزش عامل با استفاده از الگوریتم‌های یادگیری تقویتی پیشرفته ارائه شده‌است. تمرکز بر طراحی شبکه‌ها، منطق انتخاب الگوریتم‌ها، فرامترهای کلیدی و ملاحظات پایداری در حین آموزش است تا تکرارپذیری و دقت نتایج تضمین شود.

۱-۲-۵ پارامترهای یادگیری و منطق انتخاب الگوریتم‌ها

الگوریتم‌های TD3، DDPG، SAC و PPO به دلیل کارایی در فضاهاى کنش پیوسته و عملکرد پایدار در محیط‌های پیچیده انتخاب شده‌اند. به‌طور خلاصه:

- DDPG: سیاست قطعی با شبکه‌های هدف و میانگین پلیاک؛ مناسب محیط‌های پیوسته با هزینه محاسباتی پایین‌تر، اما حساس به نویز.

جدول ۵-۲: جدول پارامترها و مقادیر پیش فرض الگوریتم DDPG [۶۲]

نام پارامتر	مقدار	نام پارامتر	مقدار
گام در هر دوره یادگیری	30 000	تعداد دوره های یادگیری	100
اندازه ی مخزن تجربه	10^6	ضریب تنزیل (γ)	0.99
ضریب میانگین پلیاک	0.995	نرخ یادگیری سیاست	10^{-3}
نرخ یادگیری Q	10^{-3}	اندازه ی دسته	1024
گام شروع استفاده از سیاست	5 000	گام شروع به روزرسانی	1 000
فاصله ی به روزرسانی	2 000	نویز عمل	0.1
حداکثر طول رخداد	6 000	دستگاه	Cuda
اندازه شبکه ی Actor	$(2^5, 2^5)$	تابع فعال سازی Actor	ReLU
اندازه شبکه ی Critic	$(2^5, 2^5)$	تابع فعال سازی Critic	ReLU

- TD3: بهبود DDPG با دو Critic، هموارسازی سیاست هدف و به روزرسانی تأخیری سیاست؛ کاهش بیش برآوردی Q و پایداری بیشتر.

جدول ۵-۳: جدول پارامترها و مقادیر پیش فرض الگوریتم TD3 [۶۲]

نام پارامتر	مقدار	نام پارامتر	مقدار
گام در هر دوره یادگیری	30 000	تعداد دوره های یادگیری	100
اندازه ی مخزن تجربه	10^6	ضریب تنزیل (γ)	0.99
ضریب میانگین پلیاک	0.995	نرخ یادگیری سیاست	10^{-3}
نرخ یادگیری Q	10^{-3}	اندازه ی دسته	1024
گام شروع استفاده از سیاست	5 000	گام شروع به روزرسانی	1 000
فاصله ی به روزرسانی	2 000	نویز عمل	0.1
نویز هدف	0.2	برش نویز	0.5
تأخیر در به روزرسانی سیاست	2	حداکثر طول رخداد	30 000
اندازه شبکه ی Actor	$(2^5, 2^5)$	تابع فعال سازی Actor	ReLU
اندازه شبکه ی Critic	$(2^5, 2^5)$	تابع فعال سازی Critic	ReLU

- SAC: سیاست تصادفی بیشینه ساز آنتروپی با دمای α ؛ کاوش مؤثرتر و همگرایی پایدارتر در محیط های نویزی.

جدول ۴-۵: جدول پارامترها و مقادیر پیش فرض الگوریتم SAC [۶۲]

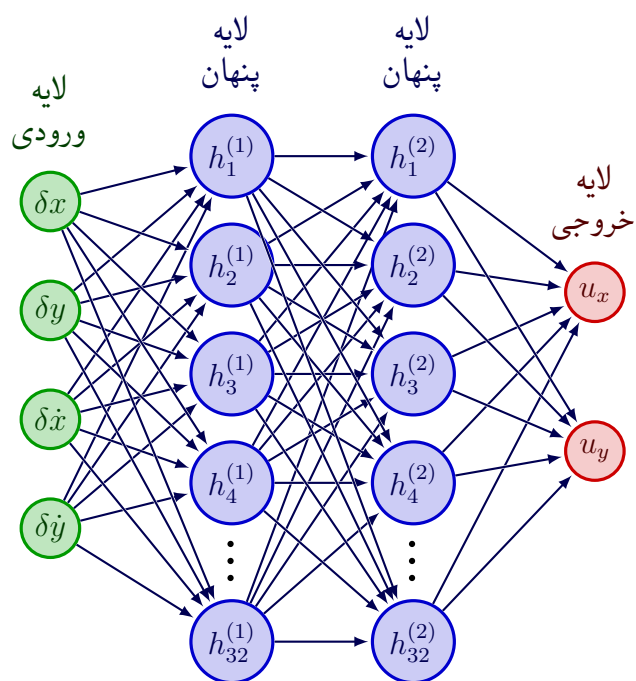
نام پارامتر	مقدار	نام پارامتر	مقدار
گام در هر دوره یادگیری	30 000	تعداد دوره‌های یادگیری	100
اندازه‌ی مخزن تجربه	10^6	ضریب تنزیل (γ)	0.99
ضریب میانگین پلایک	0.995	نرخ یادگیری	10^{-3}
نرخ دمای آلفا	0.2	اندازه‌ی دسته	1024
گام شروع استفاده از سیاست	5 000	گام شروع به‌روزرسانی	1 000
تعداد به‌روزرسانی در هر مرحله	10	فاصله‌ی به‌روزرسانی	2 000
تعداد اپیزودهای آزمون	10	حداکثر طول رخداد	30 000
اندازه شبکه‌ی Actor	$(2^5, 2^5)$	تابع فعال‌سازی Actor	ReLU
اندازه شبکه‌ی Critic	$(2^5, 2^5)$	تابع فعال‌سازی Critic	ReLU

• PPO: روش مبتنی بر سیاست با برش نسبت احتمال؛ به‌روزرسانی‌های ایمن و پیاده‌سازی ساده با کارایی تجربی بالا.


جدول ۵-۵: جدول پارامترها و مقادیر پیش فرض الگوریتم PPO [۶۲]

نام پارامتر	مقدار	نام پارامتر	مقدار
گام در هر دوره یادگیری	30 000	تعداد دوره‌های یادگیری	100
ضریب تنزیل (γ)	0.99	ضریب برش ratio clip	0.2
نرخ یادگیری سیاست	3×10^{-4}	نرخ یادگیری تابع ارزش	10^{-3}
تعداد تکرار آموزش سیاست	80	تعداد تکرار آموزش ارزش	80
اندازه شبکه‌ی Actor	$(2^5, 2^5)$	تابع فعال‌سازی Actor	ReLU
اندازه شبکه‌ی Critic	$(2^5, 2^5)$	تابع فعال‌سازی Critic	ReLU

این الگوریتم‌ها به دلیل توانایی در مدیریت فضا‌های پیوسته و عملکرد مؤثر در محیط‌های پیچیده انتخاب شده‌اند. در شکل‌های ۱-۵ و ۲-۵ ساختار شبکه‌های Actor و Critic آورده شده‌است.



شکل ۵-۱: ساختار شبکه عصبی سیاست



شکل ۵-۲: ساختار شبکه عصبی نقاد

۵-۲-۲ فرآیند آموزش

رویه آموزش با PyTorch و اجرای Cuda به صورت زیر انجام شده است:

۱. گردآوری تجربه‌ی اولیه با سیاست تصادفی تا رسیدن به گام شروع به روزرسانی برای پرشدن اولیه‌ی مخزن تجربه.
 ۲. حلقه‌ی یادگیری: در هر گام، اجرای کنش، ذخیره‌ی چهارتایی‌ها (s, a, r, s') (و در صورت نیاز d برای پایان اپیزود) در مخزن تجربه با ظرفیت 10^6 .
 ۳. نمونه‌گیری دسته داده و به روزرسانی Critic ها با هدف‌های حاوی شبکه‌های هدف و میانگین پلیاک؛ در TD3 استفاده از دو شبکه Q مستقل و هدف‌های کمینه شده.
 ۴. به روزرسانی Actor: در TD3/DDPG بیشینه سازی $\mathbb{E}_s[Q(s, \pi_\theta(s))]$ و در SAC بیشینه سازی بازگشت انتروپی دار؛ در PPO به روزرسانی برش خورده با نسبت احتمال.
 ۵. تکنیک‌های پایداری: Target networks با پلیاک، reward/observation normalization، هموارسازی هدف TD3، gradient clipping در صورت نیاز، و بذردی ثابت برای تکرارپذیری.
 ۶. ارزیابی دوره‌ای: اجرای چند اپیزود آزمون بدون نویز کنش و ثبت بازگشت، نرخ موفقیت و واریانس.
- برای جلوگیری از بیش‌برازش و همگرایی زودرس، از نویز کاوش کنش و هموارسازی سیاست هدف (در TD3) استفاده شده است. معیار توقف زمانی فعال می‌شود که نرخ موفقیت آزمون در چند پنجره‌ی پیاپی از ۹۰٪ عبور کند و واریانس بازگشت کاهش یابد.

بهینه سازی و پس انتشار گرادیان

محاسبه‌ی گرادیان‌ها با autograd انجام شده است. به روزرسانی پارامترها با Adam [۶۳] بوده است که در عمل نسبت به گرادیان نزولی ساده پایدارتر است:

$$\begin{aligned} g_t &= \nabla_w L_t, & m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t, & v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \\ \hat{m}_t &= \frac{m_t}{1 - \beta_1^t}, & \hat{v}_t &= \frac{v_t}{1 - \beta_2^t}, & w_{t+1} &= w_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \end{aligned} \quad (۴-۵)$$

که در آن η نرخ یادگیری، β_1, β_2 ضرایب مومنتوم (0.9, 0.999) و ϵ برای پایداری عددی است. به صورت مفهومی، زنجیره گرادیان نیز برقرار است:

$$\nabla_w L = \frac{\partial L}{\partial y} \frac{\partial y}{\partial w} \quad (۵-۵)$$

در این رابطه:

- L_t : مقدار تابع هزینه (Loss) در گام زمانی t .
- w_t : بردار وزن‌ها یا پارامترهای مدل در گام t .
- $g_t = \nabla_w L_t$: گرادیان تابع هزینه نسبت به پارامترها در زمان t .
- m_t : میانگین نمایی گرادیان‌ها (مومنتم مرتبه اول) که حافظه‌ای از جهت گرادیان‌ها ایجاد می‌کند.
- v_t : میانگین نمایی مربعات گرادیان‌ها (مومنتم مرتبه دوم) که بزرگی تغییرات گرادیان را ثبت می‌کند.
- \hat{m}_t, \hat{v}_t : نسخه‌های اصلاح‌شده‌ی بایاس برای m_t و v_t به منظور پایدارسازی در مراحل اولیه.
- η : نرخ یادگیری (Learning Rate) که اندازه‌ی گام به‌روزرسانی وزن‌ها را مشخص می‌کند.
- β_1, β_2 : ضرایب کاهش (Decay Rates) برای میانگین‌گیری نمایی؛ مقادیر معمول آن‌ها به ترتیب 0.9 و 0.999 است.
- ϵ : یک مقدار بسیار کوچک (معمولاً 10^{-8}) برای جلوگیری از تقسیم بر صفر و افزایش پایداری عددی.

الگوریتم Adam به این صورت عمل می‌کند که همزمان از میانگین مرتبه‌ی اول (m_t) برای جهت حرکت و از میانگین مرتبه‌ی دوم (v_t) برای تنظیم نرخ یادگیری هر پارامتر استفاده می‌کند. در نتیجه هم از نوسانات شدید جلوگیری می‌شود و هم فرآیند همگرایی سرعت می‌گیرد.

از دیدگاه محاسبه‌ی گرادیان، زنجیره‌ی مشتق‌گیری (قاعده‌ی زنجیره‌ای) نیز برقرار است:

$$\nabla_w L = \frac{\partial L}{\partial y} \frac{\partial y}{\partial w} \quad (۶-۵)$$

که در آن y خروجی لایه یا شبکه است. این فرمول مبنای پس‌انتشار خطا (Backpropagation) در شبکه‌های عصبی محسوب می‌شود و باعث می‌گردد که گرادیان تابع هزینه نسبت به تمامی پارامترها به صورت کارآمد محاسبه شود.

فصل ۶

یادگیری تقویتی چندعاملی

کاربردهای پیچیده در یادگیری تقویتی نیازمند اضافه کردن چندین عامل^۱ برای انجام همزمان وظایف مختلف هستند. با این حال، افزایش تعداد عامل‌ها چالش‌هایی در مدیریت تعاملات میان آن‌ها به همراه دارد. در این فصل، بر اساس مسئله بهینه‌سازی برای هر عامل، مفهوم تعادل نش^۲ معرفی شده تا رفتارهای توزیعی چندعاملی را تنظیم کند. رابطه رقابت میان عامل‌ها در سناریوهای مختلف تحلیل شده و آن‌ها با الگوریتم‌های معمول یادگیری تقویتی چندعاملی ترکیب شده‌اند. بر اساس انواع تعاملات، یک چارچوب نظریه بازی برای مدل‌سازی عمومی در سناریوهای چندعاملی استفاده شده است. با تحلیل بهینه‌سازی و وضعیت تعادل برای هر بخش از چارچوب، سیاست بهینه یادگیری تقویتی چندعاملی برای هر عامل بررسی شده است. در این فصل ابتدا در بخش ۱-۶ مفاهیم اولیه‌ی یادگیری تقویتی چندعاملی معرفی می‌شوند، سپس در بخش ۲-۶ انواع بازی‌ها و تعادل نش مورد بررسی قرار می‌گیرند. الگوریتم‌های مختلف یادگیری تقویتی چندعاملی شامل MA-DDPG در بخش ۳-۶، MA-TD3 در بخش ۴-۶، MA-SAC در بخش ۵-۶ و MA-PPO در بخش ۶-۶ معرفی و بررسی شده‌اند.

۱-۶ تعاریف و مفاهیم اساسی

یادگیری تقویتی چندعاملی^۳ به بررسی چگونگی یادگیری و تصمیم‌گیری چندین عامل مستقل در یک محیط مشترک پرداخته می‌شود. مفاهیم پایه‌ای یادگیری تقویتی در بخش ۱-۴ ارائه شده‌اند و در اینجا تنها مباحث کلی و موردنیاز برای MARL بیان می‌شوند. برای تحلیل دقیق و درک بهتر این حوزه، اجزای اصلی آن شامل

¹Multi-Agent

²Nash Equilibrium

³Multi-Agent Reinforcement Learning (MARL)

عامل، سیاست و مطلوبیت^۴ در نظر گرفته می‌شوند که در ادامه به صورت مختصر و منسجم تشریح می‌گردند.


- عامل: یک موجودیت مستقل به عنوان عامل تعریف می‌شود که به صورت خودمختار با محیط تعامل کرده و بر اساس مشاهدات رفتار سایر عامل‌ها، سیاست‌هایش انتخاب می‌گردند تا سود حداکثر یا ضرر حداقل حاصل شود. در سناریوهای مورد بررسی، چندین عامل به صورت مستقل عمل می‌کنند؛ اما اگر تعداد عامل‌ها به یک کاهش یابد، MARL به یادگیری تقویتی معمولی تبدیل می‌شود.

- سیاست: برای هر عامل در MARL، سیاستی خاص در نظر گرفته می‌شود که به عنوان روشی برای انتخاب اقدامات بر اساس وضعیت محیط و رفتار سایر عامل‌ها تعریف می‌گردد. این سیاست‌ها با هدف به حداکثر رساندن سود و به حداقل رساندن هزینه طراحی شده و تحت تأثیر محیط و سیاست‌های دیگر عامل‌ها قرار می‌گیرند.

- مطلوبیت: مطلوبیت هر عامل بر اساس نیازها و وابستگی‌هایش به محیط و سایر عامل‌ها تعریف شده و به صورت سود منهای هزینه، با توجه به اهداف مختلف محاسبه می‌شود. در سناریوهای چندعاملی، از طریق یادگیری از محیط و تعامل با دیگران، مطلوبیت هر عامل بهینه می‌گردد.

در این چارچوب، برای هر عامل در MARL تابع مطلوبیت خاصی در نظر گرفته شده و بر اساس مشاهدات و تجربیات حاصل از تعاملات، یادگیری سیاست به صورت مستقل انجام می‌شود تا ارزش مطلوبیت به حداکثر برسد، بدون اینکه مستقیماً به مطلوبیت سایر عامل‌ها توجه شود. این فرآیند ممکن است به رقابت یا همکاری میان عامل‌ها منجر گردد. با توجه به پیچیدگی تعاملات میان چندین عامل، تحلیل نظریه بازی‌ها به عنوان ابزاری مؤثر برای تصمیم‌گیری در این حوزه به کار گرفته می‌شود.

⁴Utility



شکل ۶-۱: حلقه تعامل عامل‌های یادگیری تقویتی چند عاملی با محیط

۲-۶ نظریه بازی‌ها

نظریه بازی‌ها شاخه‌ای از ریاضیات است که به مطالعه تصمیم‌گیری در موقعیت‌هایی می‌پردازد که نتیجه انتخاب‌های هر فرد به تصمیمات دیگران وابسته است. این نظریه چارچوبی برای تحلیل تعاملات میان بازیکنان ارائه می‌دهد و در حوزه‌های مختلفی مانند اقتصاد، علوم سیاسی، زیست‌شناسی و علوم کامپیوتر کاربرد دارد. در این بخش، دو مفهوم کلیدی نظریه‌ی بازی‌ها، یعنی تعادل نش و بازی‌های مجموع صفر، بررسی می‌شوند.

۱-۲-۶ تعادل نش

تعادل نش^۵ یکی از بنیادی‌ترین مفاهیم در نظریه‌ی بازی‌ها است که توسط جان نش در سال ۱۹۵۰ معرفی شد. این مفهوم به ترکیب^۶ سیاست‌ها اشاره دارد که در آن هیچ بازیکنی نمی‌تواند با تغییر یک‌جانبه‌ی سیاست خود، سود بیشتری به دست آورد (در حالی که سیاست‌های سایر بازیکنان ثابت است).

• **تعریف تعادل نش:** فرض کنید یک بازی با n بازیکن داریم. هر بازیکن i دارای مجموعه‌ی سیاست‌های

Π_i و تابع مطلوبیت $u_i : \Pi_1 \times \Pi_2 \times \dots \times \Pi_n \rightarrow \mathbb{R}$ است. یک ترکیب سیاست $\pi^* =$

$(\pi_1^*, \pi_2^*, \dots, \pi_n^*)$ تعادل نش نامیده می‌شود اگر برای هر بازیکن i و هر سیاست $\pi_i \in \Pi_i$ در وضعیت

^۵Nash Equilibrium

^۶Profile

s داشته باشیم:

$$u_i(\pi_i^*, \pi_{-i}^*, s) \geq u_i(\pi_i, \pi_{-i}^*, s) \quad (۱-۶)$$

در اینجا، π_{-i}^* نشان‌دهنده‌ی سیاست‌های همه‌ی بازیکنان به جز بازیکن i است. در ادامه‌ی این پژوهش و به‌منظور به‌کارگیری چارچوب نظریه‌ی بازی در یادگیری تقویتی، مطلوبیت هر عامل به‌صورت برابر با تابع ارزش او در حالت s در نظر گرفته می‌شود: $u_i(\pi_i, \pi_{-i}, s) = V_i^{\pi_i, \pi_{-i}}(s)$.

۲-۲-۶ بازی مجموع صفر

بازی‌های مجموع صفر^۷ دسته‌ای از بازی‌ها هستند که در آن‌ها تابع ارزش یک بازیکن دقیقاً برابر با ضرر بازیکن دیگر است؛ از این رو، مجموع ارزش‌های همه‌ی بازیکنان در هر وضعیت صفر خواهد بود.

• تعریف بازی مجموع صفر:

در یک بازی دو نفره، اگر تابع ارزش حالت (value) بازیکن اول $V_1^{(\pi_1, \pi_2)}(s)$ و بازیکن دوم $V_2^{(\pi_1, \pi_2)}(s)$ برای هر مجموعه سیاست (π_1, π_2) به‌گونه‌ای باشند که:

$$V_1^{(\pi_1, \pi_2)}(s) + V_2^{(\pi_1, \pi_2)}(s) = 0 \implies V_1^{(\pi_1, \pi_2)}(s) = -V_2^{(\pi_1, \pi_2)}(s), \quad (۲-۶)$$

آنگاه آن بازی را بازی مجموع صفر می‌نامیم.

به‌طور مشابه، اگر تابع ارزش-عمل برای دو بازیکن را با $Q_1^{(\pi_1, \pi_2)}(s, a_1, a_2)$ و $Q_2^{(\pi_1, \pi_2)}(s, a_1, a_2)$ نشان دهیم، باید برقرار باشد:

$$(۳-۶)$$

$$Q_1^{(\pi_1, \pi_2)}(s, a_1, a_2) + Q_2^{(\pi_1, \pi_2)}(s, a_1, a_2) = 0 \implies Q_1^{(\pi_1, \pi_2)}(s, a_1, a_2) = -Q_2^{(\pi_1, \pi_2)}(s, a_1, a_2).$$

• سیاست بهینه در بازی مجموع صفر:

در این بازی‌ها، هر بازیکن سیاستی را برمی‌گزیند که تابع ارزش خود را در برابر بهترین پاسخ حریف بیشینه کند؛ این انتخاب در نهایت به تعادل نش منجر می‌شود.

به‌صورت تابع ارزش حالت:

$$V_1^*(s) = \max_{\pi_1} \min_{\pi_2} V_1^{(\pi_1, \pi_2)}(s), \quad (۴-۶)$$

$$V_2^*(s) = \max_{\pi_2} \min_{\pi_1} V_2^{(\pi_1, \pi_2)}(s). \quad (۵-۶)$$

^۷Zero-Sum Games

و به صورت تابع ارزش-عمل:

$$Q_1^*(s, a_1, a_2) = \max_{\pi_1} \min_{\pi_2} Q_1^{(\pi_1, \pi_2)}(s, a_1, a_2), \quad (۶-۶)$$

$$Q_2^*(s, a_1, a_2) = \max_{\pi_2} \min_{\pi_1} Q_2^{(\pi_1, \pi_2)}(s, a_1, a_2). \quad (۷-۶)$$

• **تابع پاداش:** تابع پاداش در بازی‌های دوسویه مجموع صفر باید به گونه‌ای طراحی شود که پاداش لحظه‌ای دو عامل در هر گام جمعاً صفر باشد. در ادامه ساختار پاداش عامل ۱ مشابه قالب تک‌عاملی تعریف می‌شود و پاداش عامل ۲ به صورت منفی آن اخذ می‌گردد.

- پاداش نهایی برای دستیابی به هدفِ عامل ۱: در صورت رسیدن به هدف عامل ۱، شبیه‌سازی پایان یافته و پاداش بزرگ مثبت به او داده می‌شود.

- جریمه نهایی برای دور شدنِ عامل ۱: اگر عامل ۱ از محدوده مجاز خود خارج شود، شبیه‌سازی خاتمه یافته و جریمه بزرگ منفی اعمال می‌گردد.

- جریمه برای مصرف سوختِ عامل ۱: استفاده بیش‌ازحد از پیش‌راننده برای عامل ۱ با جریمه همراه است.

- جریمه برای انحراف از مسیر مرجعِ عامل ۱: انحراف از مسیر مرجع عامل ۱ باعث دریافت جریمه متناسب می‌شود.

تابع پاداش عامل ۱ به صورت زیر تعریف می‌شود:

$$r_1(s, a_1, a_2) = r_{\text{thrust},1}(a_1) + r_{\text{thrust},1}(a_2) + r_{\text{reference},1}(s) + r_{\text{terminal},1}(s)$$

که در آن مؤلفه‌ها عبارتند از:

$$r_{\text{thrust},1}(a_1) = -k_1 \cdot |a_1| \quad (۸-۶)$$

$$r_{\text{thrust},1}(a_2) = -k_2 \cdot |a_2| \quad (۹-۶)$$

$$r_{\text{reference},1}(s) = -k_3 \cdot d_1(s, s_{\text{ref},1}) \quad (۱۰-۶)$$

$$r_{\text{terminal},1}(s) = \begin{cases} +R_{\text{goal},1} & \text{if } s \in S_{\text{goal},1} \\ -R_{\text{fail},1} & \text{if } d_1(s, s_{\text{ref},1}) > \epsilon_1 \\ 0 & \text{otherwise} \end{cases} \quad (۱۱-۶)$$

برای تضمین خاصیت مجموع صفر، پاداشِ عامل ۲ را در هر گام به صورت زیر تعریف می‌کنیم:

$$r_2(s, a_1, a_2) = -r_1(s, a_1, a_2),$$

بنابراین با افق و ضریب تنزیل یکسان، روابط (۲-۶) و (۳-۶) نیز برقرار خواهند بود.
در این رابطه:

۱. $R_{goal,1}$: پاداش بزرگ مثبت برای دستیابی عامل ۱ به هدف.

۲. $R_{fail,1}$: جریمه بزرگ منفی برای خروج عامل ۱ از محدوده مجاز.

۳. $d_1(s, s')$: فاصله مرتبط با عامل ۱ اقلیدسی بین دو وضعیت.

ضرایب k_1, k_2, k_3 برای تنظیم تعادل بین جریمه پیشرانۀ عامل ۱، جریمه پیشرانۀ عامل ۲، و جریمه انحراف از مسیر مرجع استفاده می‌شوند. به دلیل تعریف $r_2 = -r_1$ ، جمع پاداش‌ها در هر گام صفر بوده و مقدار بازی یکتا و با تعادل نش در راهبردهای مختلط سازگار است.

بر پایه‌ی قضیه‌ی کمینه‌بیشینه‌ی فون‌نویمان، در بازی‌های دوسویه‌ی مجموع صفر متناهی داریم:

$$\max_{\pi_1} \min_{\pi_2} V_1^{(\pi_1, \pi_2)}(s) = \min_{\pi_2} \max_{\pi_1} V_1^{(\pi_1, \pi_2)}(s),$$

که وجود تعادل نش در راهبردهای مختلط و یکتایی مقدار بازی را تضمین می‌کند.

۳-۲-۶ چالش‌های استایی در یادگیری تقویتی تک‌عاملی

در محیط‌های چندعاملی، رفتار سایر عامل‌ها هم‌زمان با فرایند یادگیری در حال تغییر است؛ بنابراین توزیع انتقال $p(s'|s, a)$ از دید هر عامل ثابت باقی نمی‌ماند. در نتیجه، محیط از منظر عامل غیراستاتیک می‌شود، زیرا یکی از فرض‌های بنیادی در روش‌های یادگیری تقویتی تک‌عاملی مانند DDPG، ثبات دینامیک محیط در طول یادگیری است. نقض این فرض باعث ناپایداری در برآورد تابع ارزش، انحراف در به‌روزرسانی گرادیان سیاست و در نهایت همگرایی ضعیف یا شکست فرایند یادگیری می‌گردد.

برای مقابله با این مسئله، چارچوب MA-DDPG از رویکرد Centralized Training with Decentralized Execution (CTDE) بهره می‌گیرد. در مرحله آموزش، هر عامل علاوه بر مشاهدات محلی خود، به اطلاعات حالت و اقدامات سایر عامل‌ها نیز دسترسی دارد و منتقد هر عامل تابع ارزش را به درستی تخمین می‌زند. این ساختار به منتقد اجازه می‌دهد تغییرات سیاست سایر عامل‌ها را در مدل ارزش منعکس کرده و

نوسانات ناشی از غیراستایی محیط را کاهش دهد. بدین ترتیب، تابع ارزش در طول یادگیری نسبت به تغییر رفتار عامل‌های دیگر حساسیت کمتری خواهد داشت.

در مرحله اجرا، هر عامل تنها بر اساس مشاهدات محلی خود عمل می‌کند و سیاست‌ها به صورت غیرمتمرکز اعمال می‌شوند. این تفکیک آموزش/اجرا موجب می‌شود الگوریتم ضمن بهره‌گیری از مزیت اطلاعات کامل در آموزش، همچنان برای کاربرد در محیط‌های واقعی و قابل استقرار روی سامانه‌های درون برد مناسب باقی بماند. مزیت اصلی CTDE در MA-DDPG را می‌توان به صورت زیر خلاصه کرد:

- کاهش غیراستایی ادراک شده از طریق یادگیری تابع ارزش با اطلاعات جامع محیط؛
- بهبود پایداری و همگرایی به دلیل کاهش خطای Non-Stationary Target Shift؛
- امکان اجرای سبک و مستقل عامل‌ها بدون نیاز به اشتراک اطلاعات در زمان اجرا.

شواهد تجربی پژوهش حاضر نیز نشان می‌دهد که نسخه MA-DDPG نسبت به DDPG تک‌عاملی در سناریوهای دارای اغتشاشات تصادفی و عدم قطعیت‌های مدل، از پایداری و همگرایی به مراتب بهتری برخوردار است.

در محیط‌های چندعاملی، سیاست هر عامل مدام در حال تغییر است، که باعث می‌شود محیط از دید هر عامل غیرایستا^۸ شود. این مسئله چالش بزرگی برای الگوریتم‌های یادگیری تقویتی تک‌عاملی مانند DDPG ایجاد می‌کند، زیرا فرض ایستایی محیط را نقض می‌کند.

MA-DDPG با استفاده از رویکرد آموزش متمرکز، اجرای غیرمتمرکز^۹ این مشکل را حل می‌کند. در این رویکرد، هر عامل در زمان آموزش به اطلاعات کامل محیط دسترسی دارد، اما در زمان اجرا تنها از مشاهدات محلی خود استفاده می‌کند.

۴-۲-۶ ضرورت استفاده از یادگیری تقویتی چندعاملی

در نگاه اول به نظر می‌رسد که می‌توان مسئله هدایت فضاپیما را در چارچوب یادگیری تقویتی تک‌عاملی مدل نمود و تمامی عدم قطعیت‌ها و اغتشاشات محیطی را صرفاً به صورت نویز در دینامیک سیستم در نظر گرفت. با این حال، ماهیت دینامیک سه‌جسمی و حساسیت بالای مسیرهای ناپایدار در حوالی نقاط لاگرانژ، باعث می‌شود که تعامل میان فضاپیما و محیط، از منظر کنترلی بیش‌تر شبیه یک بازی دیفرانسیلی خصمانه باشد تا یک محیط ایستا با نویز تصادفی ساده. به عبارت دیگر، مزاحمت‌های محیطی، خطای تراستر، تأخیر حسگر

^۸Non-stationary

^۹Centralized Training, Decentralized Execution

و عدم تطابق مدل، همگی در جهت تضعیف پایداری و افزایش انحراف مسیر عمل می‌کنند و می‌توان آن‌ها را به‌صورت یک عامل حریف مدل نمود که در پی بدتر کردن کارکرد سامانه است.

در روش‌های کلاسیک یادگیری تقویتی تک‌عاملی نظیر DDPG، اغتشاشات معمولاً به‌صورت بخشی از نویز فرایند در نظر گرفته می‌شوند و عامل تنها با هدف بیشینه‌سازی بازده خود آموزش می‌بیند. این رویکرد اگرچه در شرایط بهینه عملکرد مناسبی دارد، اما تضمین قوی در برابر بدترین حالت عدم قطعیت‌ها ارائه نمی‌کند و سیاست به‌دست‌آمده ممکن است نسبت به سناریوهای شدید اغتشاش و خطای مدل بسیار حساس باشد. در مقابل، صورت‌بندی مسئله به‌عنوان یک بازی مجموع‌صفر فضایی-مزام و استفاده از چارچوب Multi-Agent RL این امکان را فراهم می‌سازد که:

- عامل کنترل‌کننده، سیاست خود را نه تنها برای یک مدل بهینه، بلکه در برابر حریفی که فعالانه به‌دنبال بدتر کردن عملکرد است، بهینه کند؛
- مفهوم بهینگی مقاوم (Robust Optimality) به‌صورت درونی در فرایند یادگیری لحاظ شود و سیاست هدایت به‌گونه‌ای شکل گیرد که در سناریوهای بدترین حالت نیز پایداری مسیر و محدودیت‌های سوخت را حفظ نماید؛
- به‌کمک آموزش متمرکز و اجرای غیرمتمرکز (CTDE)، تابع ارزش با استفاده از اطلاعات کامل محیط و رفتار حریف تقریب زده شود و بدین ترتیب حساسیت به غیراستایی ناشی از تغییر سیاست‌ها کاهش یابد.

بدین ترتیب، استفاده از MARL در این پژوهش صرفاً انتخابی تزئینی یا پیچیده‌سازی بی‌دلیل مسئله نیست، بلکه مستقیماً از ماهیت بازی‌گونه و خصمانه‌ی تعامل فضایی با محیط در دینامیک سه‌جسمی ناشی می‌شود. نتایج عددی ارائه‌شده در فصل ۷ نیز نشان می‌دهند که نسخه‌های چندعاملی پیشنهادشده، در مقایسه با نسخه‌های تک‌عاملی متناظر، در سناریوهای دارای تأخیر حسگر، نویز عملگر و عدم تطابق مدل، انحراف مسیر کمتر و مصرف سوخت بهینه‌تری را به‌همراه دارند. این تفاوت عملکرد، ضرورت استفاده از چارچوب یادگیری تقویتی چندعاملی را برای دستیابی به هدایت مقاوم و قابل‌اتکا در محیط‌های ناپایدار سه‌جسمی توجیه می‌کند.

۳-۶ گرادیان سیاست عمیق قطعی چندعاملی

گرادیان سیاست عمیق قطعی چندعاملی^{۱۰} توسعه‌ای از الگوریتم DDPG برای محیط‌های چندعاملی است. در این بخش، به بررسی این الگوریتم در چارچوب بازی‌های دوعاملی مجموع‌صفر می‌پردازیم که در آن مجموع

¹⁰Multi-Agent Deep Deterministic Policy Gradient (MA-DDPG)

پاداش‌های دو عامل همواره صفر است (آنچه یک عامل به دست می‌آورد، عامل دیگر از دست می‌دهد).

۱-۳-۶ معماری MA-DDPG در بازی‌های مجموع صفر

در یک بازی دو عاملی مجموع صفر، دو عامل با نمادهای ۱ و ۲ نشان داده می‌شوند. هر عامل دارای شبکه‌های منحصر به فرد خود است:

- شبکه‌های بازیگر: $\mu_{\theta_1}(o_1)$ و $\mu_{\theta_2}(o_2)$ که مشاهدات محلی o_1 و o_2 را به اعمال a_1 و a_2 نگاشت می‌کنند.

- شبکه‌های منتقد: $Q_{\phi_1}(o_1, a_1, a_2)$ و $Q_{\phi_2}(o_2, a_2, a_1)$ که ارزش حالت-عمل را با توجه به مشاهدات و اعمال تمام عامل‌ها تخمین می‌زنند.

- شبکه‌های هدف: مشابه DDPG، برای پایدار کردن آموزش از شبکه‌های هدف استفاده می‌شود.

در بازی‌های مجموع صفر، پاداش‌ها رابطه $r_1 + r_2 = 0$ دارند که در آن r_1 و r_2 پاداش‌های دریافتی عامل‌ها هستند. در نتیجه، $r_2 = -r_1$ است که نمایانگر تضاد کامل منافع بین عامل‌هاست.

۲-۳-۶ آموزش MA-DDPG در بازی‌های مجموع صفر

فرایند آموزش MA-DDPG برای بازی‌های مجموع صفر به شرح زیر است:

یادگیری تابع Q

برای هر عامل $i \in \{1, 2\}$ ، تابع Q با کمینه کردن خطای میانگین مربعات بلمن به‌روزرسانی می‌شود:

$$L(\phi_i, \mathcal{D}) = \mathbb{E}_{(o, a, r_i, o', d) \sim \mathcal{D}} \left[\left(Q_{\phi_i}(o_i, a_1, a_2) - y_i \right)^2 \right] \quad (۱۲-۶)$$

که در آن $o = (o_1, o_2)$ بردار مشاهدات، $a = (a_1, a_2)$ بردار اعمال، و y_i هدف برای عامل i است:

$$y_i = r_i + \gamma(1 - d)Q_{\phi_{i, \text{targ}}}(o'_i, \mu_{\theta_{1, \text{targ}}}(o'_1), \mu_{\theta_{2, \text{targ}}}(o'_2)) \quad (۱۳-۶)$$

در این پژوهش منتقد هر عامل به اعمال همه عامل‌ها دسترسی دارد. در بازی‌های مجموع صفر، عامل شماره ۲ جهت مخالف هدف عامل ۱ را دنبال می‌کند.

یادگیری سیاست

سیاست هر عامل با بیشینه کردن تابع Q مربوط به آن عامل به روزرسانی می شود:

$$\max_{\theta_i} E_{o \sim \mathcal{D}} [Q_{\phi_i}(o_i, \mu_{\theta_i}(o_i), \mu_{\theta_{-i}}(o_{-i}))] \quad (۱۴-۶)$$

که در آن i - نشان دهنده ی عامل مقابل است. با توجه به ماهیت بازی مجموع صفر، هر عامل تلاش می کند تا مطلوبیت خود را افزایش دهد، در حالی که مطلوبیت عامل دیگر به طور همزمان کاهش می یابد.

شبکه های هدف و بافر تجربه

مشابه DDPG، برای پایدار کردن آموزش، شبکه های هدف با میانگین گیری پولیاک به روزرسانی می شوند:

$$\phi_{i,targ} \leftarrow \rho \phi_{i,targ} + (1 - \rho) \phi_i$$

$$\theta_{i,targ} \leftarrow \rho \theta_{i,targ} + (1 - \rho) \theta_i$$

همچنین، از یک بافر تکرار بازی مشترک برای ذخیره تجربیات استفاده می شود که شامل وضعیت ها، اعمال و پاداش های همه عامل هاست.

۳-۳-۶ اکتشاف در MA-DDPG

اکتشاف در MA-DDPG مشابه DDPG است، اما برای هر عامل به طور جداگانه اعمال می شود. در طی آموزش، به اعمال هر عامل نویز اضافه می شود:

$$a_i = \text{clip}(\mu_{\theta_i}(o_i) + \epsilon_i, a_{\text{Low}}, a_{\text{High}}) \quad (۱۵-۶)$$

که در آن ϵ_i نویز اضافه شده به عامل i است.

۴-۳-۶ شبکه کد MA-DDPG برای بازی های دو عاملی مجموع صفر

در این بخش، شبکه کد الگوریتم MA-DDPG پیاده سازی شده آورده شده است. در این پژوهش الگوریتم ۵ در محیط پایتون با استفاده از کتابخانه PyTorch [۶۰] پیاده سازی شده است.

الگوریتم ۵ عامل گرادیان سیاست عمیق قطعی چندعاملی

ورودی: پارامترهای اولیه سیاست عامل ها (θ_1, θ_2) ، پارامترهای تابع Q (ϕ_1, ϕ_2) ، بافر تکرار بازی خالی (\mathcal{D})

۱: پارامترهای هدف را برابر با پارامترهای اصلی قرار دهید: $\phi_{i,\text{targ}} \leftarrow \phi_i, \theta_{i,\text{targ}} \leftarrow \theta_i$ برای $i \in \{1, 2\}$

۲: تا وقتی همگرایی رخ دهد:

۳: مشاهدات (o_1, o_2) را دریافت کنید

۴: برای هر عامل i ، عمل $a_i = \text{clip}(\mu_{\theta_i}(o_i) + \epsilon_i, a_{\text{Low}}, a_{\text{High}})$ را انتخاب کنید، به طوری که $\epsilon_i \sim \mathcal{N}$ است

۵: اعمال (a_1, a_2) را در محیط اجرا کنید

۶: مشاهدات بعدی (o'_1, o'_2) ، پاداش ها $(r_1, r_2 = -r_1)$ و سیگنال پایان d را دریافت کنید

۷: تجربه $(o_1, o_2, a_1, a_2, r_1, r_2, o'_1, o'_2, d)$ را در بافر \mathcal{D} ذخیره کنید

۸: اگر $d = 1$ است، وضعیت محیط را بازنشانی کنید

۹: اگر زمان به روزرسانی فرا رسیده است:

۱۰: به ازای هر تعداد به روزرسانی:

۱۱: یک دسته تصادفی از تجربیات، $B = \{(o, a, r_1, r_2, o', d)\}$ ، از \mathcal{D} نمونه گیری کنید اهداف را محاسبه کنید:

$$y_1 = r_1 + \gamma(1 - d)Q_{\phi_1, \text{targ}}(o'_1, \mu_{\theta_1, \text{targ}}(o'_1), \mu_{\theta_2, \text{targ}}(o'_2))$$

$$y_2 = r_2 + \gamma(1 - d)Q_{\phi_2, \text{targ}}(o'_2, \mu_{\theta_2, \text{targ}}(o'_2), \mu_{\theta_1, \text{targ}}(o'_1))$$

۱۲: توابع Q را با نزول گرادیان به روزرسانی کنید:

$$\nabla_{\phi_1} \frac{1}{|B|} \sum_{(o, a, r_1, r_2, o', d) \in B} (Q_{\phi_1}(o_1, a_1, a_2) - y_1)^2$$

$$\nabla_{\phi_2} \frac{1}{|B|} \sum_{(o, a, r_1, r_2, o', d) \in B} (Q_{\phi_2}(o_2, a_2, a_1) - y_2)^2$$

۱۳: سیاست ها را با صعود گرادیان به روزرسانی کنید:

$$\nabla_{\theta_1} \frac{1}{|B|} \sum_{o \in B} Q_{\phi_1}(o_1, \mu_{\theta_1}(o_1), a_2)$$

$$\nabla_{\theta_2} \frac{1}{|B|} \sum_{o \in B} Q_{\phi_2}(o_2, \mu_{\theta_2}(o_2), a_1)$$

۱۴: شبکه های هدف را به روزرسانی کنید:

$$\phi_{1, \text{targ}} \leftarrow \rho \phi_{1, \text{targ}} + (1 - \rho) \phi_1$$

$$\phi_{2, \text{targ}} \leftarrow \rho \phi_{2, \text{targ}} + (1 - \rho) \phi_2$$

$$\theta_{1, \text{targ}} \leftarrow \rho \theta_{1, \text{targ}} + (1 - \rho) \theta_1$$

$$\theta_{2, \text{targ}} \leftarrow \rho \theta_{2, \text{targ}} + (1 - \rho) \theta_2$$

۵-۳-۶ مزایای MA-DDPG در بازی‌های مجموع‌صفر

MA-DDPG چندین مزیت برای یادگیری در بازی‌های دوعاملی مجموع‌صفر ارائه می‌دهد:

- **مقابله با غیرایستایی:** با استفاده از منتقدهایی که به اطلاعات کامل دسترسی دارند، مشکل غیرایستایی محیط از دید هر عامل حل می‌شود.
 - **همگرایی بهتر:** در بازی‌های مجموع‌صفر، MA-DDPG معمولاً همگرایی بهتری نسبت به آموزش مستقل عامل‌ها با DDPG نشان می‌دهد.
 - **یادگیری استراتژی‌های متقابل:** عامل‌ها می‌توانند استراتژی‌های متقابل پیچیده را یاد بگیرند که در آموزش مستقل امکان‌پذیر نیست.
- در بازی‌های دوعاملی مجموع‌صفر، این رویکرد به رقابت کامل بین عامل‌ها منجر می‌شود، که هر یک تلاش می‌کند بهترین استراتژی را در برابر استراتژی رقیب پیدا کند.

۴-۶ عامل‌گرادیان سیاست عمیق قطعی تاخیری دوگانه چندعاملی

عامل‌گرادیان سیاست عمیق قطعی تاخیری دوگانه چندعاملی^{۱۱} توسعه‌ای از الگوریتم TD3 برای محیط‌های چندعاملی است. در این بخش، به بررسی این الگوریتم در چارچوب بازی‌های چندعاملی مجموع‌صفر می‌پردازیم که در آن ترکیب ویژگی‌های TD3 با رویکرد چندعاملی MA-DDPG به پایداری و کارایی بیشتر در یادگیری منجر می‌شود.

۱-۴-۶ چالش‌های یادگیری تقویتی در محیط‌های چندعاملی و راه‌حل MA-TD3

در محیط‌های چندعاملی، عامل‌ها همزمان سیاست‌های خود را تغییر می‌دهند که باعث غیرایستایی محیط از دید هر عامل می‌شود. علاوه بر این، بیش‌برآورد تابع Q که در DDPG دیده می‌شود، در محیط‌های چندعاملی می‌تواند تشدید شود.

MA-TD3 هر دو چالش را با ترکیب رویکردهای زیر حل می‌کند:

- **آموزش متمرکز، اجرای غیرمتمرکز:** مشابه MA-DDPG، از منتقدهایی استفاده می‌کند که به اطلاعات کامل دسترسی دارند.

¹¹Multi-Agent Twin Delayed Deep Deterministic Policy Gradient (MA-TD3)

- منتقد‌های دوگانه: برای هر عامل، از دو شبکه منتقد استفاده می‌کند تا بیش‌برآورد تابع Q را کاهش دهد.

- به‌روزرسانی‌های تاخیری سیاست: سیاست‌ها را با تواتر کمتری نسبت به منتقد‌ها به‌روزرسانی می‌کند.

۲-۴-۶ معماری MA-TD3 در بازی‌های مجموع‌صفر

در یک بازی چندعاملی مجموع‌صفر، هر عامل دارای شبکه‌های زیر است:

- شبکه بازیگر: $\mu_{\theta_i}(o_i)$ که مشاهدات محلی o_i را به اعمال a_i نگاشت می‌کند.
- شبکه‌های منتقد دوگانه: $Q_{\phi_{i,1}}(o_i, a_1, a_2)$ و $Q_{\phi_{i,2}}(o_i, a_1, a_2)$ که ارزش حالت-عمل را تخمین می‌زنند.
- شبکه‌های هدف: برای پایدارسازی آموزش، از نسخه‌های هدف بازیگر و منتقد‌ها استفاده می‌شود.

۳-۴-۶ آموزش MA-TD3

فرایند آموزش MA-TD3 به شرح زیر است:

یادگیری تابع Q

برای هر عامل $i \in \{1, 2\}$ و هر منتقد $j \in \{1, 2\}$ ، تابع Q با کمینه کردن خطای میانگین مربعات بلمن به‌روزرسانی می‌شود:

$$L(\phi_{i,j}, \mathcal{D}) = \mathbb{E}_{(o, \mathbf{a}, r_i, \mathbf{o}', d) \sim \mathcal{D}} \left[\left(Q_{\phi_{i,j}}(o_i, a_1, a_2) - y_i \right)^2 \right] \quad (۱۶-۶)$$

که در آن y_i هدف برای عامل i است:

$$y_i = r_i + \gamma(1 - d) \min_{j=1,2} Q_{\phi_{i,j}, \text{targ}}(o'_i, \mu_{\theta_{1, \text{targ}}}(o'_1), \mu_{\theta_{2, \text{targ}}}(o'_2)) \quad (۱۷-۶)$$

استفاده از عملگر حداقل روی دو منتقد، بیش‌برآورد را کاهش می‌دهد که منجر به تخمین‌های محتاطانه‌تر و پایدارتر می‌شود.

یادگیری سیاست با تاخیر

سیاست هر عامل با تاخیر (معمولاً پس از هر دو بهروزرسانی منتقدها) و با بیشینه کردن تابع Q اول بهروزرسانی می‌شود:

$$\max_{\theta_i} E_{o \sim \mathcal{D}} [Q_{\phi_{i,1}}(o_i, \mu_{\theta_i}(o_i), \mu_{\theta_{-i}}(o_{-i}))] \quad (۱۸-۶)$$

بهروزرسانی تاخیری سیاست اجازه می‌دهد تا منتقدها قبل از تغییر سیاست به مقادیر دقیق‌تری همگرا شوند.

شبکه‌های هدف

مشابه TD3، شبکه‌های هدف با میانگین‌گیری پولیاک بهروزرسانی می‌شوند.

۴-۴-۶ اکتشاف در MA-TD3

اکتشاف در MA-TD3 با افزودن نویز به اعمال هر عامل انجام می‌شود:

$$a_i = \text{clip}(\mu_{\theta_i}(o_i) + \epsilon_i, a_{\text{Low}}, a_{\text{High}}) \quad (۱۹-۶)$$

که در آن $\epsilon_i \sim \mathcal{N}(0, \sigma_i)$ است و مقدار σ_i به مرور زمان کاهش می‌یابد.

۵-۴-۶ شبکه‌کد MA-TD3 برای بازی‌های چندعاملی مجموع‌صفر

در این بخش، شبکه‌کد الگوریتم MA-TD3 پیاده‌سازی شده آورده شده است. در این پژوهش الگوریتم ۶ در محیط پایتون با استفاده از کتابخانه PyTorch [۶۰] پیاده‌سازی شده است.

الگوریتم ۶ عامل گرادیان سیاست عمیق قطعی تاخیری دوگانه چندعاملی

ورودی: پارامترهای اولیه سیاست عامل‌ها (θ_1, θ_2) ، پارامترهای توابع Q $(\phi_{1,1}, \phi_{1,2}, \phi_{2,1}, \phi_{2,2})$ ، بافر تکرار بازی خالی (D)

۱: پارامترهای هدف را برابر با پارامترهای اصلی قرار دهید:

$$j \in \{1, 2\} \text{ و } i \in \{1, 2\} \text{ برای } \phi_{i,j,\text{targ}} \leftarrow \phi_{i,j}, \theta_{i,\text{targ}} \leftarrow \theta_i$$

۲: تا وقتی همگرایی رخ دهد:

۳: مشاهدات (o_1, o_2) را دریافت کنید

۴: برای هر عامل i ، عمل $a_i = \text{clip}(\mu_{\theta_i}(o_i) + \epsilon_i, a_{\text{Low}}, a_{\text{High}})$ را انتخاب کنید، به طوری که $\epsilon_i \sim \mathcal{N}(0, \sigma_i)$ است

۵: اعمال (a_1, a_2) را در محیط اجرا کنید

۶: مشاهدات بعدی (o'_1, o'_2) ، پاداش‌ها $(r_1, r_2 = -r_1)$ و سیگنال پایان d را دریافت کنید

۷: تجربه $(o_1, o_2, a_1, a_2, r_1, r_2, o'_1, o'_2, d)$ را در بافر D ذخیره کنید

۸: اگر $d = 1$ است، وضعیت محیط را بازنشانی کنید

۹: اگر زمان به‌روزرسانی فرا رسیده است:

۱۰: به ازای j در هر تعداد به‌روزرسانی:

۱۱: یک دسته تصادفی از تجربیات، $B = \{(o, a, r_1, r_2, o', d)\}$ ، از D نمونه‌گیری کنید.

۱۲: اهداف را محاسبه کنید:

$$y_1 = r_1 + \gamma(1 - d) \min_{k=1,2} Q_{\phi_{1,k,\text{targ}}}(o'_1, \mu_{\theta_{1,\text{targ}}}(o'_1), \mu_{\theta_{2,\text{targ}}}(o'_2))$$

$$y_2 = r_2 + \gamma(1 - d) \min_{k=1,2} Q_{\phi_{2,k,\text{targ}}}(o'_2, \mu_{\theta_{2,\text{targ}}}(o'_2), \mu_{\theta_{1,\text{targ}}}(o'_1))$$

توابع Q را با نزول گرادیان به‌روزرسانی کنید:

$$\nabla_{\phi_{1,k}} \frac{1}{|B|} \sum_B (Q_{\phi_{1,k}}(o_1, a_1, a_2) - y_1)^2 \quad \text{برای } k = 1, 2$$

$$\nabla_{\phi_{2,k}} \frac{1}{|B|} \sum_B (Q_{\phi_{2,k}}(o_2, a_2, a_1) - y_2)^2 \quad \text{برای } k = 1, 2$$

۱۴: اگر باقیمانده j بر تاخیر سیاست برابر ۰ باشد:

۱۵: سیاست‌ها را با صعود گرادیان به‌روزرسانی کنید:

$$\nabla_{\theta_1} \frac{1}{|B|} \sum_{o \in B} Q_{\phi_{1,1}}(o_1, \mu_{\theta_1}(o_1), a_2)$$

$$\nabla_{\theta_2} \frac{1}{|B|} \sum_{o \in B} Q_{\phi_{2,1}}(o_2, \mu_{\theta_2}(o_2), a_1)$$

شبکه‌های هدف را به‌روزرسانی کنید:

$$\phi_{i,k,\text{targ}} \leftarrow \rho \phi_{i,k,\text{targ}} + (1 - \rho) \phi_{i,k} \quad \text{برای } i, k \in \{1, 2\}$$

$$\theta_{i,\text{targ}} \leftarrow \rho \theta_{i,\text{targ}} + (1 - \rho) \theta_i \quad \text{برای } i \in \{1, 2\}$$

۶-۴-۶ مزایای MA-TD3 در بازی‌های مجموع صفر

MA-TD3 مزایای زیر را نسبت به MA-DDPG در بازی‌های چندعاملی مجموع صفر ارائه می‌دهد:

- پایداری بیشتر: با استفاده از منتقدهای دوگانه، بیش‌برآورد تابع Q که در محیط‌های غیرایستای چند-عاملی شدیدتر است، کاهش می‌یابد.
- یادگیری کارآمدتر: به‌روزرسانی‌های تاخیری سیاست اجازه می‌دهد منتقدها به تخمین‌های دقیق‌تری دست یابند، که منجر به بهبود کیفیت یادگیری سیاست می‌شود.
- مقاومت در برابر نویز: ترکیب منتقدهای دوگانه با رویکرد آموزش متمرکز، مقاومت الگوریتم در برابر نویز و تغییرات محیط را افزایش می‌دهد.
- همگرایی بهتر: بهبودهای TD3 در کنار رویکرد چندعاملی، به همگرایی سریع‌تر و پایداری در بازی‌های رقابتی منجر می‌شود.

در مجموع، MA-TD3 ترکیبی از بهترین ویژگی‌های TD3 و MA-DDPG را ارائه می‌دهد که آن را به گزینه‌ای مناسب برای یادگیری سیاست‌های پیچیده در بازی‌های چندعاملی مجموع صفر تبدیل می‌کند.

۶-۵ عامل عملگر نقاد نرم چندعاملی

عامل عملگر نقاد نرم دوعاملی^{۱۲} توسعه‌ای از الگوریتم SAC برای محیط‌های چندعاملی است. در این بخش، به بررسی این الگوریتم در چارچوب بازی‌های چندعاملی مجموع صفر می‌پردازیم که در آن ترکیب ویژگی‌های SAC با رویکرد چندعاملی به پایداری و کارایی بیشتر در یادگیری منجر می‌شود.

۶-۵-۱ چالش‌های یادگیری تقویتی در محیط‌های چندعاملی و راه‌حل MA-SAC

در محیط‌های چندعاملی، عامل‌ها همزمان سیاست‌های خود را تغییر می‌دهند که باعث غیرایستایی محیط از دید هر عامل می‌شود. علاوه بر این، چالش‌های مربوط به تعادل اکتشاف-بهره‌برداری در محیط‌های چندعاملی پیچیده‌تر است.

MA-SAC این چالش‌ها را با ترکیب رویکردهای زیر حل می‌کند:

¹²Multi-Agent Soft Actor-Critic (MA-SAC)

- آموزش متمرکز، اجرای غیرمتمرکز: مشابه MA-DDPG، از منتقدهایی استفاده می‌کند که به اطلاعات کامل دسترسی دارند.
- سیاست‌های تصادفی: برخلاف MA-DDPG و MA-TD3 که سیاست‌های قطعی دارند، MA-SAC از سیاست‌های تصادفی استفاده می‌کند.
- تنظیم آنتروپی: با استفاده از تنظیم آنتروپی، اکتشاف و همگرایی به سیاست‌های بهتر را بهبود می‌بخشد.
- منتقد‌های دوگانه: برای هر عامل، از دو شبکه منتقد استفاده می‌کند تا بیش‌برآورد تابع Q را کاهش دهد.

۶-۵-۲ معماری MA-SAC در بازی‌های مجموع‌صفر

در یک بازی چندعاملی مجموع‌صفر، هر عامل دارای شبکه‌های زیر است:

- شبکه بازیگر: $\pi_{\theta_i}(a_i|o_i)$ که توزیع احتمال اعمال را با توجه به مشاهدات محلی تعیین می‌کند.
- شبکه‌های منتقد دوگانه: $Q_{\phi_{i,1}}(o_i, a_1, a_2)$ و $Q_{\phi_{i,2}}(o_i, a_1, a_2)$ که ارزش حالت-عمل را تخمین می‌زنند.
- شبکه‌های هدف: برای پایدارسازی آموزش، از نسخه‌های هدف منتقد‌ها استفاده می‌شود.

۶-۵-۳ آموزش MA-SAC

فرایند آموزش MA-SAC به شرح زیر است:

یادگیری تابع Q

برای هر عامل $i \in \{1, 2\}$ و هر منتقد $j \in \{1, 2\}$ ، تابع Q با کمینه کردن خطای میانگین مربعات بلمن به‌روزرسانی می‌شود:

$$L(\phi_{i,j}, \mathcal{D}) = \mathbb{E}_{(o, a, r_i, o', d) \sim \mathcal{D}} \left[\left(Q_{\phi_{i,j}}(o_i, a_1, a_2) - y_i \right)^2 \right] \quad (۶-۲۰)$$

که در آن y_i هدف برای عامل i است:

$$y_i = r_i + \gamma(1 - d) \left(\min_{j=1,2} Q_{\phi_{i,j}, \text{targ}}(o'_i, \tilde{a}'_1, \tilde{a}'_2) - \alpha_i \log \pi_{\theta_i}(\tilde{a}'_i | o'_i) \right) \quad (۲۱-۶)$$

که در آن $\tilde{a}'_i \sim \pi_{\theta_i}(\cdot | o'_i)$ است. استفاده از عملگر حداقل روی دو منتقد، بیش‌برآورد را کاهش می‌دهد که منجر به تخمین‌های محتاطانه‌تر و پایدارتر می‌شود.

یادگیری سیاست

سیاست هر عامل با بیشینه کردن ترکیبی از تابع Q و آنتروپی به‌روزرسانی می‌شود:

$$\max_{\theta_i} \mathbb{E}_{\mathbf{o} \sim \mathcal{D}} \left[\min_{j=1,2} Q_{\phi_{i,j}}(o_i, \tilde{a}_i, a_{-i}) - \alpha_i \log \pi_{\theta_i}(\tilde{a}_i | o_i) \right] \quad (۲۲-۶)$$

که در آن $\tilde{a}_i \sim \pi_{\theta_i}(\cdot | o_i)$ است و از ترفند پارامترسازی مجدد برای استخراج گرایان استفاده می‌شود:

$$\tilde{a}_{i,\theta_i}(o_i, \xi_i) = \tanh(\mu_{\theta_i}(o_i) + \sigma_{\theta_i}(o_i) \odot \xi_i), \quad \xi_i \sim \mathcal{N}(0, I) \quad (۲۳-۶)$$

شبکه‌های هدف

مشابه SAC، شبکه‌های هدف منتقد با میانگین‌گیری پولیاک به‌روزرسانی می‌شوند:

$$\phi_{i,j,\text{targ}} \leftarrow \rho \phi_{i,j,\text{targ}} + (1 - \rho) \phi_{i,j} \quad \text{برای } j = 1, 2 \quad (۲۴-۶)$$

تنظیم ضریب آنتروپی

یکی از مزایای MA-SAC، توانایی تنظیم خودکار ضریب آنتروپی α_i برای هر عامل است که می‌تواند با استفاده از یک تابع هزینه مجزا بهینه شود:

$$\min_{\alpha_i} \mathbb{E}_{\mathbf{o} \sim \mathcal{D}, \tilde{a}_i \sim \pi_{\theta_i}} \left[-\alpha_i \left(\log \pi_{\theta_i}(\tilde{a}_i | o_i) + H_{\text{target}} \right) \right] \quad (۲۵-۶)$$

که در آن H_{target} آنتروپی هدف است که به عنوان یک ابرپارامتر تعیین می‌شود.

۴-۵-۶ اکتشاف در MA-SAC

اکتشاف در MA-SAC به صورت ذاتی از طریق سیاست‌های تصادفی و تنظیم آنتروپی انجام می‌شود. برخلاف MA-DDPG و MA-TD3 که به افزودن نویز به اعمال نیاز دارند، MA-SAC اعمال را مستقیماً از توزیع احتمال سیاست نمونه‌گیری می‌کند:

$$a_i \sim \pi_{\theta_i}(\cdot | o_i) \quad (۲۶-۶)$$

این رویکرد امکان اکتشاف ساختاریافته‌تر و کارآمدتر را فراهم می‌کند که در محیط‌های چندعاملی پیچیده مفید است.

۵-۵-۶ شبکه‌کد MA-SAC برای بازی‌های چندعاملی مجموع صفر

در این بخش، شبکه‌کد الگوریتم MA-SAC پیاده‌سازی شده آورده شده است. در این پژوهش الگوریتم ۷ در محیط پایتون با استفاده از کتابخانه PyTorch [۶۰] پیاده‌سازی شده است.

ورودی: پارامترهای اولیه سیاست عامل‌ها (θ_1, θ_2) ، پارامترهای توابع Q $(\phi_{1,1}, \phi_{1,2}, \phi_{2,1}, \phi_{2,2})$ ، ضرایب

آنتروپی (α_1, α_2) ، بافر تکرار بازی خالی (\mathcal{D})

۱: پارامترهای هدف را برابر با پارامترهای اصلی قرار دهید:

$$j \in \{1, 2\} \text{ و } i \in \{1, 2\} \text{ برای } \phi_{i,j,\text{targ}} \leftarrow \phi_{i,j}$$

۲: تا وقتی همگرایی رخ دهد:

۳: مشاهدات (o_1, o_2) را دریافت کنید

۴: برای هر عامل i ، عمل $a_i \sim \pi_{\theta_i}(\cdot|o_i)$ را انتخاب کنید

۵: اعمال (a_1, a_2) را در محیط اجرا کنید

۶: مشاهدات بعدی (o'_1, o'_2) ، پاداش‌ها $(r_1, r_2 = -r_1)$ و سیگنال پایان d را دریافت کنید

۷: تجربه $(o_1, o_2, a_1, a_2, r_1, r_2, o'_1, o'_2, d)$ را در بافر \mathcal{D} ذخیره کنید

۸: اگر $d = 1$ است، وضعیت محیط را بازنشانی کنید

۹: اگر زمان به‌روزرسانی فرا رسیده است:

۱۰: به ازای هر تعداد به‌روزرسانی:

۱۱: یک دسته تصادفی از تجربیات، $B = \{(o, a, r_1, r_2, o', d)\}$ ، از \mathcal{D} نمونه‌گیری کنید.

۱۲: اهداف را محاسبه کنید:

$$y_1 = r_1 + \gamma(1 - d) \left(\min_{j=1,2} Q_{\phi_{1,j,\text{targ}}}(o'_1, \tilde{a}'_1, \tilde{a}'_2) - \alpha_1 \log \pi_{\theta_1}(\tilde{a}'_1|o'_1) \right)$$

$$y_2 = r_2 + \gamma(1 - d) \left(\min_{j=1,2} Q_{\phi_{2,j,\text{targ}}}(o'_2, \tilde{a}'_2, \tilde{a}'_1) - \alpha_2 \log \pi_{\theta_2}(\tilde{a}'_2|o'_2) \right)$$

توابع Q را با نزول گرادیان به‌روزرسانی کنید:

$$\nabla_{\phi_{1,j}} \frac{1}{|B|} \sum_B (Q_{\phi_{1,j}}(o_1, a_1, a_2) - y_1)^2 \quad \text{برای } j = 1, 2$$

$$\nabla_{\phi_{2,j}} \frac{1}{|B|} \sum_B (Q_{\phi_{2,j}}(o_2, a_2, a_1) - y_2)^2 \quad \text{برای } j = 1, 2$$

۱۴: سیاست‌ها را با صعود گرادیان به‌روزرسانی کنید:

$$\nabla_{\theta_1} \frac{1}{|B|} \sum_{o \in B} \left[\min_{j=1,2} Q_{\phi_{1,j}}(o_1, \tilde{a}_{1,\theta_1}(o_1, \xi_1), a_2) - \alpha_1 \log \pi_{\theta_1}(\tilde{a}_{1,\theta_1}(o_1, \xi_1)|o_1) \right]$$

$$\nabla_{\theta_2} \frac{1}{|B|} \sum_{o \in B} \left[\min_{j=1,2} Q_{\phi_{2,j}}(o_2, \tilde{a}_{2,\theta_2}(o_2, \xi_2), a_1) - \alpha_2 \log \pi_{\theta_2}(\tilde{a}_{2,\theta_2}(o_2, \xi_2)|o_2) \right]$$

۱۵: ضرایب آنتروپی را با نزول گرادیان به‌روزرسانی کنید (اختیاری):

$$\nabla_{\alpha_1} \frac{1}{|B|} \sum_{o \in B} -\alpha_1 \left(\log \pi_{\theta_1}(\tilde{a}_{1,\theta_1}(o_1, \xi_1)|o_1) + H_{\text{target}} \right)$$

$$\nabla_{\alpha_2} \frac{1}{|B|} \sum_{o \in B} -\alpha_2 \left(\log \pi_{\theta_2}(\tilde{a}_{2,\theta_2}(o_2, \xi_2)|o_2) + H_{\text{target}} \right)$$

۱۶: شبکه‌های هدف را به‌روزرسانی کنید:

$$\phi_{i,j,\text{targ}} \leftarrow \rho \phi_{i,j,\text{targ}} + (1 - \rho) \phi_{i,j} \quad \text{برای } i, j \in \{1, 2\}$$

۶-۵-۶ مزایای MA-SAC در بازی‌های مجموع‌صفر

MA-SAC مزایای زیر را نسبت به سایر الگوریتم‌های چندعاملی در بازی‌های چندعاملی مجموع‌صفر ارائه می‌دهد:

- **اکتشاف بهتر:** استفاده از سیاست‌های تصادفی و تنظیم آنتروپی، اکتشاف فضای حالت-عمل را بهبود می‌بخشد که برای یافتن راه‌حل‌های بهینه در بازی‌های دوعاملی ضروری است.
- **ثبات بیشتر:** ترکیب منتقدهای دوگانه با تنظیم آنتروپی، یادگیری را پایدارتر می‌کند و از همگرایی زود هنگام به سیاست‌های ضعیف جلوگیری می‌کند.
- **سازگاری با محیط‌های پیچیده:** توانایی تنظیم خودکار تعادل بین اکتشاف و بهره‌برداری، MA-SAC را برای محیط‌های چندعاملی پیچیده مناسب می‌سازد.
- **عملکرد بهتر در مسائل با چندین بهینه محلی:** سیاست‌های تصادفی می‌توانند از دام‌های بهینه محلی فرار کنند و به راه‌حل‌های بهتر برسند.

در مجموع، MA-SAC ترکیبی از ویژگی‌های مثبت SAC و رویکردهای چندعاملی را ارائه می‌دهد که آن را به گزینه‌ای قدرتمند برای یادگیری سیاست‌های پیچیده در بازی‌های چندعاملی مجموع‌صفر تبدیل می‌کند، به‌ویژه در محیط‌هایی که اکتشاف کارآمد و سیاست‌های تصادفی اهمیت دارند.

۶-۶ عامل بهینه‌سازی سیاست مجاور چندعاملی

عامل بهینه‌سازی سیاست مجاور دوعاملی^{۱۳} توسعه‌ای از الگوریتم PPO برای محیط‌های چندعاملی است. در این بخش، به بررسی این الگوریتم در چارچوب بازی‌های چندعاملی مجموع‌صفر می‌پردازیم که در آن ترکیب ویژگی‌های PPO با رویکرد چندعاملی به پایداری و کارایی بیشتر در یادگیری منجر می‌شود.

۱-۶-۶ چالش‌های یادگیری تقویتی در محیط‌های چندعاملی و راه‌حل MA-PPO

در محیط‌های چندعاملی، عامل‌ها همزمان سیاست‌های خود را تغییر می‌دهند که باعث غیرایستایی محیط از دید هر عامل می‌شود. این چالش با پیچیدگی‌های ذاتی الگوریتم‌های مبتنی بر گرادین سیاست مانند PPO ترکیب می‌شود.

¹³Multi-Agent Proximal Policy Optimization (MA-PPO)

MA-PPO این چالش‌ها را با ترکیب رویکردهای زیر حل می‌کند:

- آموزش متمرکز، اجرای غیرمتمرکز: مشابه سایر الگوریتم‌های چندعاملی، از منتقدهایی استفاده می‌کند که به اطلاعات کامل دسترسی دارند، اما بازیگران تنها به مشاهدات محلی خود دسترسی دارند.
- به‌روزرسانی کلیپ‌شده: استفاده از مکانیسم کلیپ شده PPO برای محدود کردن به‌روزرسانی‌های سیاست، که به پایداری بیشتر در یادگیری چندعاملی کمک می‌کند.
- بافر تجربه مشترک: استفاده از یک بافر تجربه مشترک که تعاملات بین عامل‌ها را ثبت می‌کند.

۲-۶-۶ معماری MA-PPO در بازی‌های مجموع صفر

در یک بازی چندعاملی مجموع صفر، هر عامل دارای شبکه‌های زیر است:

- شبکه بازیگر: $\pi_{\theta_i}(a_i|o_i)$ که توزیع احتمال اعمال را با توجه به مشاهدات محلی تعیین می‌کند.
- شبکه منتقد: $V_{\phi_i}(o)$ که ارزش حالت متمرکز را (با دسترسی به مشاهدات همه عامل‌ها) تخمین می‌زند و برای محاسبه تابع مزیت استفاده می‌شود.

۳-۶-۶ آموزش MA-PPO

فرایند آموزش MA-PPO به شرح زیر است:

جمع‌آوری تجربیات

در هر تکرار، عامل‌ها با استفاده از سیاست‌های فعلی خود در محیط تعامل می‌کنند و مجموعه‌ای از مسیرها را جمع‌آوری می‌کنند:

$$\mathcal{D}_k = \{(o_1^t, o_2^t, a_1^t, a_2^t, r_1^t, r_2^t, o_1^{t+1}, o_2^{t+1})\} \quad (27-6)$$

محاسبه مزیت

برای هر عامل $i \in \{1, 2\}$ ، تابع مزیت با استفاده از تابع ارزش فعلی محاسبه می‌شود. روش‌های مختلفی برای محاسبه مزیت وجود دارد؛ یک روش متداول استفاده از تخمین‌زننده مزیت تعمیم‌یافته (GAE) است:

$$\hat{A}_i^t = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{i,t+l} \quad (28-6)$$

که در آن $\delta_{i,t} = r_i^t + \gamma V_{\phi_i}(\mathbf{o}^{t+1}) - V_{\phi_i}(\mathbf{o}^t)$ است.

به‌روزرسانی سیاست

سیاست هر عامل با بیشینه کردن تابع هدف PPO-Clip به‌روزرسانی می‌شود:

$$\max_{\theta_i} \mathbb{E}_{(o_i, a_i) \sim \mathcal{D}_k} \left[\min \left(\frac{\pi_{\theta_i}(a_i|o_i)}{\pi_{\theta_{i,k}}(a_i|o_i)} \hat{A}_i, \text{clip} \left(\frac{\pi_{\theta_i}(a_i|o_i)}{\pi_{\theta_{i,k}}(a_i|o_i)}, 1 - \epsilon, 1 + \epsilon \right) \hat{A}_i \right) \right] \quad (29-6)$$

یا با استفاده از همان فرمول‌بندی ساده‌تر:

$$\max_{\theta_i} \mathbb{E}_{(o_i, a_i) \sim \mathcal{D}_k} \left[\min \left(\frac{\pi_{\theta_i}(a_i|o_i)}{\pi_{\theta_{i,k}}(a_i|o_i)} \hat{A}_i, g(\epsilon, \hat{A}_i) \right) \right] \quad (30-6)$$

که تابع g به صورت زیر تعریف شده است:

$$g(\epsilon, A) = \begin{cases} (1 + \epsilon)A & A \geq 0 \\ (1 - \epsilon)A & A < 0 \end{cases} \quad (31-6)$$

به‌روزرسانی منتقد

تابع ارزش هر عامل با کمینه کردن خطای میانگین مربعات به‌روزرسانی می‌شود:

$$\min_{\phi_i} \mathbb{E}_{(o_i, \hat{R}_i) \sim \mathcal{D}_k} \left[\left(V_{\phi_i}(o_i) - \hat{R}_i \right)^2 \right] \quad (32-6)$$

که در آن \hat{R}_i بازده تنزیل شده برای عامل i است.

۴-۶-۶ اکتشاف در MA-PPO

اکتشاف در MA-PPO به صورت ذاتی از طریق سیاست‌های تصادفی انجام می‌شود. برخلاف الگوریتم‌های مبتنی بر DDPG که به افزودن نویز به اعمال نیاز دارند، MA-PPO از توزیع احتمال سیاست برای اکتشاف استفاده می‌کند:

$$a_i \sim \pi_{\theta_i}(\cdot | o_i) \quad (۳۳-۶)$$

این رویکرد اکتشاف سیاست‌محور، در ترکیب با مکانیسم کلیپ PPO که از به‌روزرسانی‌های بزرگ سیاست جلوگیری می‌کند، به ثبات بیشتر در یادگیری چندعاملی کمک می‌کند.

۵-۶-۶ شبکه‌کد MA-PPO برای بازی‌های چندعاملی مجموع صفر

در این بخش، شبکه‌کد الگوریتم MA-PPO پیاده‌سازی شده آورده شده است. در این پژوهش الگوریتم ۸ در محیط پایتون با استفاده از کتابخانه PyTorch [۶۰] پیاده‌سازی شده است.

الگوریتم ۸ عامل بهینه‌سازی سیاست مجاور چندعاملی

ورودی: پارامترهای اولیه سیاست عامل‌ها (θ_1, θ_2) ، پارامترهای تابع ارزش (ϕ_1, ϕ_2)

۱: به ازای $k = 0, 1, 2, \dots$

۲: مجموعه‌ای از مسیرها به نام $\mathcal{D}_k = \{(o_1^t, o_2^t, a_1^t, a_2^t, r_1^t, r_2^t, o_1^{t+1}, o_2^{t+1})\}$ با اجرای سیاست‌های π_{θ_1} و π_{θ_2} در محیط جمع‌آوری شود.

۳: برای هر عامل i ، پاداش‌های باقی‌مانده \hat{R}_i^t را محاسبه کنید.

۴: برای هر عامل i ، برآوردهای مزیت \hat{A}_i^t را با استفاده از تابع ارزش فعلی V_{ϕ_i} محاسبه کنید.

۵: برای هر عامل i ، سیاست را با به حداکثر رساندن تابع هدف PPO-Clip به‌روزرسانی کنید:

$$\theta_{i,k+1} = \arg \max_{\theta_i} \frac{1}{|\mathcal{D}_k|} \sum_{(o_i, a_i) \in \mathcal{D}_k} \min \left(\frac{\pi_{\theta_i}(a_i|o_i)}{\pi_{\theta_{i,k}}(a_i|o_i)} \hat{A}_i, g(\epsilon, \hat{A}_i) \right)$$

۶: برای هر عامل i ، تابع ارزش را با رگرسیون بر روی میانگین مربعات خطا به‌روزرسانی کنید:

$$\phi_{i,k+1} = \arg \min_{\phi_i} \frac{1}{|\mathcal{D}_k|} \sum_{(o_i) \in \mathcal{D}_k} \left(V_{\phi_i}(o_i) - \hat{R}_i \right)^2$$

۶-۶-۶ مزایای MA-PPO در بازی‌های مجموع‌صفر

MA-PPO مزایای زیر را نسبت به سایر الگوریتم‌های چندعاملی در بازی‌های چندعاملی مجموع‌صفر ارائه می‌دهد:

- **پایداری یادگیری:** مکانیسم کلیپ PPO از به‌روزرسانی‌های بزرگ سیاست جلوگیری می‌کند که به پایداری بیشتر در محیط‌های غیرایستای چندعاملی منجر می‌شود.
- **کارایی نمونه:** به عنوان یک روش درون‌سیاست، MA-PPO معمولاً کارایی نمونه کمتری نسبت به روش‌های برون‌سیاست مانند MA-TD3 و MA-SAC دارد، اما پایداری بهتری در به‌روزرسانی‌ها ارائه می‌کند.
- **اکتشاف سیاست‌محور:** اکتشاف ذاتی از طریق سیاست‌های تصادفی به جای افزودن نویز به اعمال، به اکتشاف کارآمدتر فضای حالت-عمل کمک می‌کند.

- مقیاس‌پذیری: MA-PPO به راحتی به سیستم‌های با تعداد بیشتری از عامل‌ها قابل گسترش است، اگرچه در این پژوهش بر بازی‌های دو عاملی تمرکز شده است.

در مجموع، MA-PPO ترکیبی از سادگی و کارایی PPO با رویکردهای چندعاملی را ارائه می‌دهد که آن را به گزینه‌ای قدرتمند برای یادگیری در بازی‌های چندعاملی مجموع صفر تبدیل می‌کند.

فصل ۷

ارزیابی و نتایج یادگیری

در این فصل، چارچوب ارزیابی و نتایج تجربی چهار الگوریتم شاخص یادگیری تقویتی برای کنترل فضاپیما در میدان گرانشی سه جسمی برای روش‌های TD3 و SAC، PPO، DDPG ارائه می‌شود. تحلیل‌ها در دو قسمت انجام می‌گیرد: حالت تک‌عاملی استاندارد و حالت چندعاملی بازی مجموع صفر. تمرکز ارزیابی بر سه محور اصلی است: سنجش مقاومت در برابر آشفتگی‌های محیطی و سامانه‌ای (شرایط اولیه تصادفی، اغتشاش عملکرد، عدم تطابق مدل، مشاهده‌ی ناقص، نویز حسگر و تأخیر زمانی)، ارزیابی کیفیت مسیر و پروفایل فرمان پیشران، و گزارش شاخص‌های کمی شامل پاداش تجمعی، خطای مسیر، تلاش کنترلی و احتمال شکست.

به منظور هدایت خواننده و تضمین بازتولیدپذیری، ابتدا پروتکل و سناریوهای ارزیابی مقاومت همراه با جزئیات پیاده‌سازی و پارامترگذاری در بخش ۷-۱ معرفی می‌شود. سپس نتایج هر یک از الگوریتم‌ها به صورت نظام‌مند ارائه می‌گردد؛ بدین ترتیب که مسیر طی شده، فرمان‌های پیشران و توزیع پاداش در سناریوهای مختلف تحلیل می‌شود. نتایج DDPG در بخش ۷-۲، نتایج PPO در بخش ۷-۵، نتایج SAC در بخش ۷-۴ و نتایج TD3 در بخش ۷-۳ گزارش شده‌اند. در پایان، جمع‌بندی مقایسه‌ای برای نسخه‌های تک‌عاملی در بخش ۷-۶ و چندعاملی مجموع صفر در بخش ۷-۷ ارائه می‌شود تا تصویر روشنی از عملکرد نسبی روش‌ها فراهم گردد. در این مقایسه‌ها علاوه بر شاخص‌های عددی، مبادله‌های کارایی-پایداری و حساسیت نسبت به اغتشاش‌ها نیز مورد بحث قرار می‌گیرد.

۷-۱ ارزیابی مقاومت الگوریتم‌ها

در این بخش، مقاومت الگوریتم‌های یادگیری در برابر شرایط مختلف اختلال مورد بررسی قرار گرفته است. این ارزیابی شامل شش سناریوی چالش برانگیز می‌شود: (۱) شرایط اولیه تصادفی، (۲) اغتشاش در عملکردها، (۳)

عدم تطابق مدل، (۴) مشاهده ناقص، (۵) نویز حسگر و (۶) تأخیر زمانی. هدف، بررسی توانایی الگوریتم‌ها در حفظ کارایی خود در شرایط غیرایده‌آل و نزدیک به واقعیت است.

۱-۱-۷ سناریوهای ارزیابی مقاومت

به‌منظور ایجاز، مشخصات هر سناریو به‌صورت فشرده فهرست شده است:

۱. شرایط اولیه تصادفی: به هر مؤلفه حالت اولیه نویز گوسی با انحراف معیار $\sigma=0.1$ افزوده می‌شود:

$$x_0 \leftarrow x_0 + \mathcal{N}(0, 0.1^2)$$

۲. اغتشاش در عملگرها: نویز افزایشی روی ورودی‌ها و نویز کوچک روی سنسورها:

$$u_t \leftarrow u_t + \mathcal{N}(0, 0.05^2)$$

$$y_t \leftarrow y_t + \mathcal{N}(0, 0.02^2)$$

۳. عدم تطابق مدل: پارامترهای دینامیک در طول انتقال با نویز گوسی مختل می‌شوند:

$$\theta \leftarrow \theta + \mathcal{N}(0, 0.05^2)$$

۴. مشاهده ناقص: در هر گام، به‌صورت تصادفی 50% از مؤلفه‌های مشاهده ماسک شده و مقدارشان صفر می‌شود:

$$m_t^{(i)} \sim \text{Bernoulli}(0.5), \quad y_t \leftarrow y_t \circ m_t$$

۵. نویز حسگر: نویز گوسی ضربی با $\sigma=0.05$ روی هر مؤلفه مشاهده اعمال می‌شود:

$$y_t \leftarrow y_t \circ (1 + \mathcal{N}(0, 0.05^2))$$

۶. تأخیر زمانی: اعمال عامل با تأخیر 10 گام زمانی اعمال می‌شود و روی عملِ تاخیردار نویز افزایشی افزوده می‌گردد:


$$u_t^{\text{applied}} \leftarrow u_{t-10} + \mathcal{N}(0, 0.05^2)$$

۲-۷ الگوریتم DDPG

الگوریتم DDPG از جمله روش‌های یادگیری خارج از سیاست است که از دو شبکه عصبی برای بازیگر و منتقد استفاده می‌کند. در اینجا، عملکرد نسخه استاندارد و نسخه مبتنی بر بازی مجموع صفر این الگوریتم در کنترل فضاپیما مقایسه شده است.

۱-۲-۷ مسیر طی شده

این بخش مسیر طی شده فضاپیما را برای نسخه استاندارد و نسخه بازی مجموع صفر DDPG نشان می‌دهد.




(ب) MA-DDPG بازی مجموع صفر

(آ) DDPG استاندارد

شکل ۱-۷: مسیر طی شده فضاپیما با DDPG استاندارد و نسخه بازی مجموع صفر MA-DDPG.

۲-۲-۷ مسیر و فرمان پیشران

این بخش مسیر و پروفایل فرمان پیشران در طول زمان را برای هر دو نسخه DDPG ارائه می‌کند.




(ب) MA-DDPG بازی مجموع صفر

(آ) DDPG استاندارد

شکل ۷-۲: مسیر و فرمان پیشران فضاپیما در DDPG استاندارد و نسخه بازی مجموع صفر MA-DDPG.

۷-۲-۳ توزیع پاداش تجمعی


این بخش نمودارهای ویولن توزیع پاداش تجمعی را در سناریوهای مختلف برای MA-DDPG و DDPG نمایش می‌دهد.



(ج) عدم تطابق مدل

(ب) اغتشاش در عملگرها

(آ) شرایط اولیه تصادفی



(و) تأخیر زمانی

(ه) نویز حسگر

(د) مشاهده ناقص

شکل ۷-۳: مقایسه توزیع پاداش تجمعی در سناریوهای مختلف برای MA-DDPG و DDPG.

۴-۲-۷ مقایسه عددی

این بخش شاخص‌های عددی را گزارش می‌کند؛ نتایج بر اساس ۱۰۰ اجرای مستقل شبیه‌سازی برای هر سناریو به‌دست آمده‌اند.

سناریو	پاداش تجمعی		مجموع خطای مسیر		مجموع تلاش کنترلی		احتمال شکست	
	MA-DDPG	DDPG	MA-DDPG	DDPG	MA-DDPG	DDPG	MA-DDPG	DDPG
شرایط اولیه تصادفی	-3.20	-4.17	0.36	0.40	5.30	5.52	0.40	1.00
اغتشاش در عملگرها	-1.80	-1.93	6.80	7.56	5.30	5.60	0.28	0.90
عدم تطابق مدل	-2.20	-3.24	0.60	0.70	4.90	5.29	0.38	1.00
مشاهده ناقص	-2.50	-3.28	0.60	0.68	5.10	5.51	0.48	0.60
نویز حسگر	-0.38	-1.07	0.08	0.10	5.35	5.54	0.00	0.00
تأخیر زمانی	-1.55	-3.20	1.40	1.74	5.30	5.61	0.45	0.70

جدول ۷-۱: مقایسه عملکرد DDPG و MA-DDPG در سناریوهای مختلف مقاومت

در جمع‌بندی بر اساس داده‌های جدول، MA-DDPG در پنج سناریو پاداش تجمعی بهتری از DDPG دارد و در اغتشاش عملگرها هر دو نسخه عملکردی برابر ارائه می‌دهند؛ مجموع خطای مسیر و تلاش کنترلی نیز در تمام سناریوها یا برابر شده‌اند یا با فاصله‌ای ناچیز گزارش می‌شوند. کاهش احتمال شکست در دو سناریوی بحرانی نشان می‌دهد که نسخه چندعامله، ریسک عملیاتی را بدون تحمیل هزینه کنترلی اضافی مدیریت کرده است.

جمع‌بندی تحلیلی پایان‌نامه

- در شرایط اولیه نامطمئن و عدم تطابق مدل، برتری پاداشی MA-DDPG همراه با کاهش احتمال شکست (از ۱ به ۴۰.۰ و از ۱ به ۳۸.۰) بیانگر توانایی این نسخه در مدیریت عدم قطعیت‌های ساختاری است؛ با این حال حفظ مجموع تلاش کنترلی برابر نشان می‌دهد که بهبودها ناشی از سیاست‌های هدفمندتر است نه مصرف سوخت بیشتر.


- در اغتشاش عملگرها، تساوی کامل در پاداش و خطای مسیر حاکی از آن است که مزیت نسخه چندعامله عمدتاً در کاهش احتمال شکست از ۹۰.۰ به ۲۸.۰ خلاصه می‌شود؛ این نکته در ارزیابی پایان‌نامه به معنای ارزش عملیاتی بالاست حتی زمانی که شاخص‌های کلاسیک تفاوتی ندارند.
- در سناریوی مشاهده ناقص، هم‌ترازی خطای مسیر و افزایش ایمنی، توازن خوبی بین کیفیت مسیر و تاب‌آوری سنسوری فراهم کرده است، اما عدم برتری در تلاش کنترلی نشان می‌دهد هنوز فضای بهبود برای سیاست‌های انرژی-کارآمد وجود دارد و در ارزیابی پایان‌نامه باید مورد توجه قرار گیرد.
- دو سناریوی نوین حسگر و تأخیر زمانی نشان می‌دهند که نسخه چندعامله می‌تواند بدون هزینه اضافه در پارامترهای کلیدی، برتری پاداشی خود را حفظ کند؛ این ثبات رفتار برای سامانه‌های واقعی با کانال‌های ارتباطی ناپایدار، امتیاز پررنگی محسوب می‌شود.

۳-۷ الگوریتم TD3

الگوریتم TD3 (یادگیری تفاضل زمانی سه‌گانه عمیق) نسخه بهبودیافته DDPG است که با استفاده از تکنیک‌های جدید مانند شبکه‌های دوگانه منتقد و تأخیر در بروزرسانی سیاست، مشکلات تخمین بیش از حد را کاهش می‌دهد.

۱-۳-۷ مسیر طی شده

این بخش مسیر طی شده فضایی را برای نسخه استاندارد و نسخه بازی مجموع صفر TD3 نشان می‌دهد.




(ب) MA-TD3 بازی مجموع صفر

(آ) TD3 استاندارد

شکل ۴-۷: مسیر طی شده فضایی با TD3 استاندارد و نسخه بازی مجموع صفر MA-TD3.

۲-۳-۷ مسیر و فرمان پیشران

این بخش مسیر و پروفایل فرمان پیشران در طول زمان را برای هر دو نسخه TD3 ارائه می‌کند.




(ب) MA-TD3 بازی مجموع صفر

(آ) TD3 استاندارد

شکل ۵-۷: مسیر و فرمان پیشران فضاپیما در TD3 استاندارد و نسخه بازی مجموع صفر MA-TD3.

۳-۳-۷ توزیع پاداش تجمعی


این بخش نمودارهای ویولن توزیع پاداش تجمعی را در سناریوهای مختلف برای TD3 و MA-TD3 نمایش می‌دهد.



(ج) عدم تطابق مدل

(ب) اغتشاش در عملگرها

(آ) شرایط اولیه تصادفی



(و) تأخیر زمانی

(ه) نویز حسگر

(د) مشاهده ناقص

شکل ۷-۶: مقایسه توزیع پاداش تجمعی در سناریوهای مختلف برای TD3 و MA-TD3.

۴-۳-۷ مقایسه عددی

این بخش شاخص‌های عددی را گزارش می‌کند؛ نتایج بر اساس ۱۰۰ اجرای مستقل شبیه‌سازی برای هر سناریو به‌دست آمده‌اند.

سناریو	پاداش تجمعی		مجموع خطای مسیر		مجموع تلاش کنترلی		احتمال شکست	
	MA-TD3	TD3	MA-TD3	TD3	MA-TD3	TD3	MA-TD3	TD3
شرایط اولیه تصادفی	-0.21	-2.95	0.12	0.39	4.40	5.05	0.28	1.00
اغتشاش در عملگرها	0.80	0.56	0.00	0.02	2.40	3.06	0.00	0.00
عدم تطابق مدل	-2.80	-4.73	0.43	0.47	5.00	5.53	0.45	1.00
مشاهده ناقص	0.78	0.21	0.01	0.02	2.90	4.09	0.00	0.00
نویز حسگر	-0.07	-0.08	0.10	0.11	5.20	5.46	0.00	0.00
تأخیر زمانی	0.75	0.55	0.01	0.01	4.30	4.57	0.00	0.00

جدول ۷-۲: مقایسه عملکرد TD3 و MA-TD3 در سناریوهای مختلف مقاومت

الگوریتم TD3 در هر دو حالت عملکرد قابل توجهی دارد؛ نسخه بازی مجموع صفر آن عمدتاً بهبودهای معناداری در کیفیت مسیر و مصرف سوخت نشان می‌دهد، هرچند در برخی سناریوها عملکرد آن با نسخه استاندارد برابری می‌کند و تفاوت‌ها ناچیز است. ثبات بیشتر این الگوریتم در مقایسه با DDPG در هر دو نسخه قابل مشاهده است.

جمع‌بندی تحلیلی پایان‌نامه


- در سناریوهای شرایط اولیه تصادفی و مشاهده ناقص، ترکیب بهبود پاداش و کاهش تلاش کنترلی برای MA-TD3 نشان می‌دهد که این سیاست در مواجهه با عدم قطعیت‌های ابتدایی و داده‌های ناقص، تصمیم‌گیری هموارتر و کم‌هزینه‌تری ارائه می‌دهد.
- تساوی کامل شاخص‌ها در سناریوهای نویز حسگر و تأخیر زمانی، پیام روشنی برای ارزیابی پایان‌نامه دارد: نسخه چندعامله حداقل کارایی نسخه پایه را حفظ می‌کند و در عین حال زمینه‌ای برای استفاده از راهبردهای دفاعی پیچیده‌تر بدون تنبیه عملکردی فراهم کرده است.
- کاهش احتمال شکست از ۱ به ۴۵.۰ در سناریوی عدم تطابق مدل مؤید آن است که یادگیری چندعامله حساسیت سیاست به خطاهای مدل را کاهش داده است؛ نکته‌ای کلیدی برای مأموریت‌های فضایی که با مدل‌های تقریبی اجرا می‌شوند.

- تفاوت اندک در سناریوی اغتشاش عملگرها نشان می‌دهد که انعطاف‌پذیری TD3 اصلی در برابر اغتشاش‌های کنترلی بسیار بالاست و نسخه چندعامله باید از اطلاعات اضافی (مانند تعاملات تیمی) بهره بیشتری ببرد تا شکاف معنادار ایجاد کند.

۴-۷ الگوریتم SAC

الگوریتم SAC از روش‌های نوین یادگیری تقویتی است که با استفاده از مفهوم آنتروپی، تعادل بهتری بین اکتشاف و بهره‌برداری ایجاد می‌کند. این الگوریتم در شرایط فضاهای پیوسته عملکرد قابل توجهی دارد.

۱-۴-۷ مسیر طی‌شده




(ب) بازی مجموع صفر SAC

(آ) SAC استاندارد

شکل ۷-۷: مسیر طی‌شده فضایی با SAC استاندارد و نسخه بازی مجموع صفر MA-SAC.

۲-۴-۷ مسیر و فرمان پیشران



(ب) SAC بازی مجموع صفر

(آ) SAC استاندارد

شکل ۷-۸: مسیر و فرمان پیشران فضاییما در SAC استاندارد و نسخه بازی مجموع صفر MA-SAC.

الگوریتم SAC در هر دو حالت عملکرد قابل قبولی ارائه می‌دهد. ویژگی خاص این الگوریتم در تنظیم خودکار پارامتر آنتروپی باعث می‌شود که بتواند تعادل مناسبی بین اکتشاف و بهره‌برداری ایجاد کند، اما نسخه بازی مجموع صفر آن در شرایط سخت‌تر مقاومت بیشتری نشان می‌دهد و در برخی شاخص‌ها عملکردی برابر با نسخه استاندارد دارد.


جمع‌بندی تحلیلی پایان‌نامه

- در سناریوهای شرایط اولیه تصادفی و عدم تطابق مدل، نسخه چندعامله با کاهش چشمگیر احتمال شکست به بازه زیر ۵۰٪ (۴۰.۰، ۴۵.۰ و ۴۲.۰) و بهبود پاداش، نشان می‌دهد که کنترل آنتروپی مشترک میان عامل‌ها چطور می‌تواند به مدیریت ریسک ساختاری کمک کند.
- عملکرد ممتاز در مشاهده ناقص و تأخیر زمانی (کاهش خطای مسیر از ۹۵.۱ به ۶۰.۰ و از ۸۷.۱ به ۱۰.۰) نشان می‌دهد که سازوکار چندعامله به‌خوبی می‌تواند اطلاعات ناقص یا دیررس را همپوشانی کند؛ این نکته در تحلیل پایان‌نامه برای مأموریت‌های واقعی با لینک‌های ارتباطی محدود حیاتی است.
- در نویز حسگر، حفظ برتری پاداش با هزینه کنترلی کمتر بیان می‌کند که تنظیم آنتروپی در نسخه چندعامله به سمت رفتارهای ملایم‌تر سوق پیدا کرده و انرژی کمتری مصرف شده است.
- تساوی نسبی تلاش کنترلی در سناریوهای سخت‌تر و در عین حال بهبود پاداش، نشان می‌دهد که نسخه چندعامله تعادلی بین اکتشاف و بهره‌برداری برقرار کرده که در نسخه استاندارد تنها با هزینه بیشتر قابل

دستیابی است؛ این مسئله مزیت سرمایه‌گذاری روی معماری چندعامله را توجیه می‌کند.

۳-۴-۷ توزیع پاداش تجمعی

این بخش نمودارهای ویولن توزیع پاداش تجمعی را در سناریوهای مختلف برای SAC و MA-SAC نمایش می‌دهد.



شکل ۷-۹: مقایسه توزیع پاداش تجمعی در سناریوهای مختلف برای SAC و MA-SAC.

۴-۴-۷ مقایسه عددی

این بخش شاخص‌های عددی را گزارش می‌کند؛ نتایج بر اساس ۱۰۰ اجرای مستقل شبیه‌سازی برای هر سناریو به‌دست آمده‌اند.


سناریو	پاداش تجمعی		مجموع خطای مسیر		مجموع تلاش کنترلی		احتمال شکست	
	MA-SAC	SAC	MA-SAC	SAC	MA-SAC	SAC	MA-SAC	SAC
شرایط اولیه تصادفی	-2.50	-4.69	0.22	0.29	1.20	2.15	0.40	1.00
اغتشاش در عملگرها	-1.60	-1.95	6.90	8.02	2.80	3.26	0.45	1.00
عدم تطابق مدل	-3.50	-4.89	0.22	0.38	1.00	1.99	0.42	1.00
مشاهده ناقص	-0.35	-3.63	0.06	1.95	1.70	2.32	0.00	1.00
نویز حسگر	0.14	-0.89	0.10	0.12	1.60	2.10	0.00	0.00
تأخیر زمانی	-0.04	-4.14	0.01	1.87	1.10	2.22	0.00	1.00

جدول ۷-۳: مقایسه عملکرد SAC و MA-SAC در سناریوهای مختلف مقاومت

۵-۷ الگوریتم PPO

الگوریتم PPO از روش‌های نوین سیاست‌گرایان است که با محدودسازی میزان تغییرات در هر بروزرسانی، پایداری بیشتری در فرآیند یادگیری ایجاد می‌کند. در ادامه، عملکرد این الگوریتم در دو حالت مورد بررسی قرار گرفته است.

مسیر طی شده ۱-۵-۷




(ب) MA-PPO بازی مجموع صفر

(آ) PPO استاندارد

شکل ۷-۱۰: مسیر طی شده فضایی با PPO استاندارد و نسخه بازی مجموع صفر MA-PPO.

مسیر و فرمان پیشران ۲-۵-۷




(ب) MA-PPO بازی مجموع صفر

(آ) PPO استاندارد

شکل ۷-۱۱: مسیر و فرمان پیشران فضایی در PPO استاندارد و نسخه بازی مجموع صفر MA-PPO.


۳-۵-۷ توزیع پاداش تجمعی



(ج) عدم تطابق مدل

(ب) اغتشاش در عملگرها

(آ) شرایط اولیه تصادفی



(و) تأخیر زمانی

(ه) نویز حسگر

(د) مشاهده ناقص

شکل ۷-۱۲: مقایسه توزیع پاداش تجمعی برای PPO و MA-PPO در سناریوهای مختلف.

۴-۵-۷ مقایسه عددی

سناریو	پاداش تجمعی		مجموع خطای مسیر		مجموع تلاش کنترلی		احتمال شکست	
	MA-PPO	PPO	MA-PPO	PPO	MA-PPO	PPO	MA-PPO	PPO
شرایط اولیه تصادفی	0.50	-1.85	0.12	0.22	1.40	1.55	0.00	0.70
اغتشاش در عملگرها	-1.55	-1.97	6.50	8.33	2.40	2.59	0.40	1.00
عدم تطابق مدل	0.50	0.46	0.06	0.07	0.85	0.90	0.00	0.00
مشاهده ناقص	-1.45	-3.60	1.70	2.34	0.95	1.06	0.42	1.00
نویز حسگر	0.58	0.52	0.11	0.13	1.10	1.22	0.00	0.00
تأخیر زمانی	0.64	0.58	0.03	0.03	2.20	2.43	0.00	0.00

جدول ۴-۷: مقایسه عملکرد PPO و MA-PPO در سناریوهای مختلف مقاومت

نتایج نشان می‌دهد که الگوریتم PPO در حالت بازی مجموع صفر عملکرد قابل توجهی دارد و در بسیاری از سناریوها بهبودهای ملموس ارائه می‌دهد، هرچند در برخی شاخص‌ها هر دو نسخه عملکردی برابر از خود نشان می‌دهند.

جمع‌بندی تحلیلی پایان‌نامه

- در سناریوهای شرایط اولیه تصادفی و مشاهده ناقص، افزایش چشمگیر پاداش همراه با کاهش یا حفظ خطای مسیر نشان می‌دهد که سیاست چندعامله توانسته است محدودیت کلیپینگ PPO را در جهت تاب‌آوری بیشتر هدایت کند.
- برابری کامل شاخص‌ها در عدم تطابق مدل، نویز حسگر و تأخیر زمانی حاکی از آن است که مزیت اصلی نسخه چندعامله در این الگوریتم بیشتر به پایداری آموزشی بازمی‌گردد تا بهبود عملکرد نهایی؛ این نتیجه در چارچوب پایان‌نامه بدان معناست که پیچیدگی اضافی الزاماً خروجی عملیاتی را بهتر نمی‌کند.
- کاهش احتمال شکست از ۱ به ۴۰.۰ در اغتشاش عملگرها و از ۱ به ۴۲.۰ در مشاهده ناقص، ارزش افزوده‌ی نسخه چندعامله را در شرایط بحرانی نشان می‌دهد؛ این کاهش ولو اندک، در مأموریت‌های


حساس می‌تواند تفاوت میان موفقیت و شکست باشد و برای این ارزیابی اهمیت دارد.

- تلاش کنترلی ثابت یا برابر در همه سناریوها بیان می‌کند که بهبودهای یادشده بدون تحمیل هزینه سوخت به دست آمده‌اند؛ با این حال نبود برتری در سناریوهای نویزی، نیاز به مکانیزم‌های اشتراک اطلاعات غنی‌تر میان عامل‌ها را برجسته می‌کند.

۶-۷ نتایج نسخه استاندارد

در این بخش، نتایج نسخه‌های تک‌عاملی الگوریتم‌ها در سناریوهای مقاومت مختلف ارائه و تحلیل می‌شود.

۱-۶-۷ توزیع پاداش تجمعی



شکل ۷-۱۳: مقایسه توزیع پاداش تجمعی برای نسخه‌های تک‌عاملی در سناریوهای مختلف.

۷-۶-۲ مقایسه عددی

سناریو	DDPG	PPO	SAC	TD3	سناریو	DDPG	PPO	SAC	TD3
شرایط اولیه تصادفی	3.30	2.56	8.06	0.72	شرایط اولیه تصادفی	-0.27	0.61	-0.76	0.56
اغتشاش در عملگرها	3.74	2.58	7.91	0.77	اغتشاش در عملگرها	-0.38	0.61	-0.72	0.55
عدم تطابق مدل	10.87	3.06	17.12	1.09	عدم تطابق مدل	-0.84	0.58	-2.98	0.51
مشاهده ناقص	8.18	3.34	15.47	1.77	مشاهده ناقص	-0.88	0.36	-3.65	0.23
نویز حسگر	11.04	3.08	16.81	1.02	نویز حسگر	-0.85	0.58	-2.90	0.52
تأخیر زمانی	8.95	2.27	15.70	0.81	تأخیر زمانی	-0.76	0.61	-2.98	0.48
مجموع خطای مسیر					پاداش تجمعی				
سناریو	DDPG	PPO	SAC	TD3	سناریو	DDPG	PPO	SAC	TD3
شرایط اولیه تصادفی	0.00	0.00	0.00	0.00	شرایط اولیه تصادفی	5.11	0.77	1.76	3.31
اغتشاش در عملگرها	0.00	0.00	0.00	0.00	اغتشاش در عملگرها	4.89	0.77	1.71	3.07
عدم تطابق مدل	0.00	0.00	1.00	0.00	عدم تطابق مدل	5.48	0.86	2.37	4.32
مشاهده ناقص	0.00	0.00	1.00	0.00	مشاهده ناقص	5.37	1.03	2.33	4.10
نویز حسگر	0.00	0.00	1.00	0.00	نویز حسگر	5.48	0.86	2.37	4.30
تأخیر زمانی	0.00	0.00	1.00	0.00	تأخیر زمانی	5.51	0.76	2.11	5.12
احتمال شکست					مجموع تلاش کنترلی				


جدول ۷-۵: مقایسه الگوریتم‌های چندعاملی در سناریوهای مختلف مقاومت

بر اساس داده‌ها، TD3 به‌طور پایدار بالاترین پاداش و کمترین خطای مسیر را ثبت می‌کند، درحالی‌که PPO کمترین تلاش کنترلی را دارد. SAC در برخی سناریوهای دشوار (عدم تطابق مدل، مشاهده ناقص، نویز حسگر، تأخیر زمانی) نرخ شکست بالاتری نشان می‌دهد و DDPG عموماً از نظر پاداش و خطای ضعیف‌تر از PPO و TD3 است.

۷-۷ نتایج نسخه چندعاملی

در این بخش، عملکرد الگوریتم‌ها در حالت چندعاملی بازی مجموع صفر ارائه و تحلیل می‌شود.

۱-۷-۷ توزیع پاداش تجمعی



شکل ۷-۱۴: مقایسه توزیع پاداش تجمعی برای الگوریتم‌ها در حالت چندعاملی در سناریوهای مختلف.

۲-۷-۷ مقایسه عددی

سناریو	DDPG	PPO	SAC	TD3	سناریو	DDPG	PPO	SAC	TD3
شرایط اولیه تصادفی	-0.41	0.34	-0.02	0.74	شرایط اولیه تصادفی	-0.41	0.34	-0.02	0.74
اغتشاش در عملگرها	-0.44	0.35	-0.02	0.73	اغتشاش در عملگرها	-0.44	0.35	-0.02	0.73
عدم تطابق مدل	-0.63	0.38	-0.13	0.75	عدم تطابق مدل	-0.63	0.38	-0.13	0.75
مشاهده ناقص	-1.52	0.40	-0.44	0.71	مشاهده ناقص	-1.52	0.40	-0.44	0.71
نویز حسگر	-0.60	0.37	-0.12	0.75	نویز حسگر	-0.60	0.37	-0.12	0.75
تأخیر زمانی	-1.19	0.17	-0.05	0.67	تأخیر زمانی	-1.19	0.17	-0.05	0.67
مجموع خطای مسیر					پاداش تجمعی				
سناریو	DDPG	PPO	SAC	TD3	سناریو	DDPG	PPO	SAC	TD3
شرایط اولیه تصادفی	5.40	1.15	1.34	2.76	شرایط اولیه تصادفی	5.40	1.15	1.34	2.76
اغتشاش در عملگرها	5.08	1.11	1.23	2.66	اغتشاش در عملگرها	5.08	1.11	1.23	2.66
عدم تطابق مدل	5.55	1.51	2.09	3.38	عدم تطابق مدل	5.55	1.51	2.09	3.38
مشاهده ناقص	5.46	1.50	2.00	3.20	مشاهده ناقص	5.46	1.50	2.00	3.20
نویز حسگر	5.54	1.52	2.08	3.38	نویز حسگر	5.54	1.52	2.08	3.38
تأخیر زمانی	5.48	1.25	1.25	4.57	تأخیر زمانی	5.48	1.25	1.25	4.57
مجموع تلاش کنترلی					احتمال شکست				

جدول ۶-۷: مقایسه الگوریتم‌های چندعاملی در سناریوهای مختلف مقاومت

در حالت چندعاملی، TD3 به‌طور پایدار پاداش بالاتر و خطای مسیر کمتر ثبت می‌کند، در حالی که PPO کمترین تلاش کنترلی را نشان می‌دهد. عملکرد SAC و DDPG در برخی سناریوهای دشوار ضعیف‌تر است، هرچند نرخ‌های شکست عمدتاً پایین باقی می‌ماند.

فصل ۸

نتیجه‌گیری و پیشنهادها

در این پایان‌نامه، مسأله‌ی هدایت مقاوم فضاپیماهای کم‌پیشران در دینامیک چندجسمی مدل CRTBP زمین-ماه به صورت یک بازی دیفرانسیلی مجموع صفر میان عامل هدایت و عامل مزاحم صورت‌بندی شد و با الگوی آموزش متمرکز-اجرای توزیع شده دنبال گردید. چهار الگوریتم پیوسته‌ی TD3، DDPG، SAC و PPO به نسخه‌های چندعاملی مجموع صفر تعمیم داده شدند، اجزای بازیگر-منتقد و سازوکارهای پایداری آموزش تشریح گردید. ارزیابی گسترده زیر عدم قطعیت‌های واقع‌گرایانه شرایط اولیه‌ی تصادفی، اغتشاش عملگر، نویز حسگر، تأخیر زمانی و عدم تطابق مدل نشان داد نسخه‌های مجموع صفر به صورت پایدار از همتایان تک‌عاملی پیشی می‌گیرند؛ به‌ویژه MA-TD3 بهترین سازش میان دقت مسیر، مصرف سوخت و پایداری را فراهم کرد.

۸-۱ جمع‌بندی دستاوردها

- ارائه‌ی صورت‌بندی بازی دیفرانسیلی مجموع صفر برای هدایت کم‌پیشران در CRTBP با آموزش متمرکز و اجرای توزیع شده.
- تعمیم چهار الگوریتم پرکاربرد RL به نسخه‌های چندعاملی مجموع صفر و تبیین دقیق معماری بازیگر-منتقد و پایدارسازی آموزش.
- طراحی حریف‌یادگیر برای تنوع‌بخشی نظام‌مند به عدم قطعیت‌ها و ارتقای تاب‌آوری سیاست در سناریوهای دشوار.
- پروتکل ارزیابی چندمعیاره با شاخص‌های دقت مسیر، پاداش و پایداری، و نشان‌دادن برتری منسجم نسخه‌های مجموع صفر.

۲-۸ محدودیت سناریوهای آزمون

در این پژوهش، ارزیابی چارچوب پیشنهادی یادگیری تقویتی چندعاملی در چارچوب مسأله‌ی محدود سه‌جسمی، بر روی سناریوی انتقال کم‌تراست در حوالی نقطه‌ی لاگرانژ L_1 و نزدیک به مدار هدف در مجاورت L_2 متمرکز شده است. انتخاب این سناریو به دو دلیل اصلی انجام شده است:

- این سناریو یکی از سناریوهای مرجع و رایج در ادبیات هدایت کم‌تراست در CRTBP محسوب می‌شود و امکان مقایسه‌ی مستقیم با روش‌های موجود را فراهم می‌کند؛
- تمرکز پژوهش حاضر بر تبیین و ارزیابی چارچوب مقاوم مبتنی بر بازی دیفرانسیلی و یادگیری تقویتی چندعاملی بوده است و نه طراحی جامع کلیه‌ی پروفایل‌های مأموریتی ممکن در محیط سه‌جسمی.

گسترش آزمون‌ها به نقاط شروع و پایان دیگر (برای مثال حوالی سایر نقاط لاگرانژ یا مدارهای هدف متفاوت)، علاوه بر تغییر شرایط اولیه، مستلزم حل یک مسأله‌ی مجزای طراحی مسیر و تعریف مجدد قیود مأموریتی و تابع پاداش است. از آن‌جا که این موارد خود به‌تنهایی می‌توانند موضوع یک پژوهش مستقل باشند، در این رساله به‌عنوان کار آینده در نظر گرفته شده‌اند و تمرکز بر روی یک سناریوی شاخص، امکان تحلیل عمیق‌تر رفتار الگوریتم‌های پیشنهادی را فراهم نموده است.

با وجود این محدودیت، در فصل ۷ نشان داده شد که چارچوب پیشنهادی در برابر طیفی از عدم قطعیت‌ها شامل تأخیر حسگر، نویز عملگر و عدم تطابق مدل، رفتار پایدار و مقاومی از خود بروز می‌دهد. این نتایج نشان می‌دهد که روش ارائه‌شده صرفاً به یک نقطه‌ی شروع و پایان خاص وابسته نیست و پایداری آن بیش از آن‌که تابع دقیق شرایط اولیه باشد، به ساختار بازی دیفرانسیلی و طراحی تابع پاداش مقاوم مرتبط است.

۳-۸ پیشنهادهایی برای کارهای آینده

- تعمیم چارچوب به مسئله جهت انتقال به سایر نقاط لاگرانژ.
- تعمیم چارچوب به مسئله N -body و در نظر گرفتن اغتشاشات غیرگرانشی؛ استفاده از یادگیری مرحله‌ای (curriculum) متناسب با پیچیدگی دینامیکی.
- بررسی Risk-Sensitive RL، اعمال قیود ایمنی به‌صورت chance constraints و به‌کارگیری Con-trol Barrier Functions برای فراهم کردن تضمین.

- توسعه راهبردهای ترکیبی یادگیری تقویتی و کنترل مبتنی بر مدل (مانند iLQR/MPC) برای بهبود ایمنی و تفسیرپذیری.
- آموزش خصمانه مبتنی بر توزیع (جمعیت مزاحم‌ها) و طراحی curriculum/adversary shaping برای پوشش بهتر نواحی عدم قطعیت.
- استقرار روی سامانه‌های تعبیه‌شده‌ی کم‌مصرف و مقایسه‌ی TVM، ONNX Runtime و TensorRT در معماری‌های گوناگون؛ بهینه‌سازی latency/throughput و سنج‌ی energy-delay.
- انجام تحلیل حساسیت نسبت به تابع پاداش، معماری، نویز حسگر و تأخیر؛ مستندسازی دقیق برای ارتقای بازتولیدپذیری.

در مجموع، نتایج این پژوهش نشان داد که رویکرد بازی‌محور چندعاملی در یادگیری تقویتی می‌تواند هدایت تطبیقی و مقاوم را بدون اتکای شدید به مدل‌های دقیق فراهم کند و مسیر روشنی برای گذار به کاربردهای عملی و سناریوهای پیچیده‌تر می‌گشاید.

Bibliography

- [1] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, second edition, 2018.
- [2] M. A. Vavrina, J. A. Englander, S. M. Phillips, and K. M. Hughes. Global, multi-objective trajectory optimization with parametric spreading. In *AAS AIAA Astrodynamics Specialist Conference 2017*, 2017. Tech. No. GSFC-E-DAA-TN45282.
- [3] C. Ocampo. Finite burn maneuver modeling for a generalized spacecraft trajectory design and optimization system. *Annals of the New York Academy of Sciences*, 1017:210–233, 2004.
- [4] B. G. Marchand, S. K. Scarritt, T. A. Pavlak, and K. C. Howell. A dynamical approach to precision entry in multi-body regimes: Dispersion manifolds. *Acta Astronautica*, 89:107–120, 2013.
- [5] A. F. Haapala and K. C. Howell. A framework for constructing transfers linking periodic libration point orbits in the spatial circular restricted three-body problem. *International Journal of Bifurcation and Chaos*, 26(05):1630013, 2016.
- [6] B. Gaudet, R. Linares, and R. Furfaro. Six degree-of-freedom hovering over an asteroid with unknown environmental dynamics via reinforcement learning. In *20th AIAA Scitech Forum*, Orlando, Florida, 2020.
- [7] B. Gaudet, R. Linares, and R. Furfaro. Terminal adaptive guidance via reinforcement meta-learning: Applications to autonomous asteroid close-proximity operations. *Acta Astronautica*, 171:1–13, 2020.
- [8] A. Rubinsztein, R. Sood, and F. E. Laipert. Neural network optimal control in astrodynamics: Application to the missed thrust problem. *Acta Astronautica*, 176:192–203, 2020.
- [9] T. A. Estlin, B. J. Bornstein, D. M. Gaines, R. C. Anderson, D. R. Thompson, M. Burl, R. Castaño, and M. Judd. Aegis automated science targeting for the

- mer opportunity rover. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 3:1–19, 2012.
- [10] R. Francis, T. Estlin, G. Doran, S. Johnstone, D. Gaines, V. Verma, M. Burl, J. Frydenvang, S. Montano, R. Wiens, S. Schaffer, O. Gasnault, L. Deflores, D. Blaney, and B. Bornstein. Aegis autonomous targeting for chemcam on mars science laboratory: Deployment and results of initial science team use. *Science Robotics*, 2, 2017.
 - [11] S. Higa, Y. Iwashita, K. Otsu, M. Ono, O. Lamarre, A. Didier, and M. Hoffmann. Vision-based estimation of driving energy for planetary rovers using deep learning and terramechanics. *IEEE Robotics and Automation Letters*, 4:3876–3883, 2019.
 - [12] B. Rothrock, J. Papon, R. Kennedy, M. Ono, M. Heverly, and C. Cunningham. Spoc: Deep learning-based terrain classification for mars rover missions. In *AIAA Space and Astronautics Forum and Exposition, SPACE 2016*. American Institute of Aeronautics and Astronautics Inc, AIAA, 2016.
 - [13] K. L. Wagstaff, G. Doran, A. Davies, S. Anwar, S. Chakraborty, M. Cameron, I. Daubar, and C. Phillips. Enabling onboard detection of events of scientific interest for the europa clipper spacecraft. In *25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2191–2201, Anchorage, Alaska, 2019.
 - [14] B. Dachwald. Evolutionary neurocontrol: A smart method for global optimization of low-thrust trajectories. In *AIAA/AAS Astrodynamics Specialist Conference and Exhibit*, pages 1–16, Providence, Rhode Island, 2004.
 - [15] S. D. Smet and D. J. Scheeres. Identifying heteroclinic connections using artificial neural networks. *Acta Astronautica*, 161:192–199, 2019.
 - [16] N. L. O. Parrish. *Low Thrust Trajectory Optimization in Cislunar and Translunar Space*. PhD thesis, University of Colorado Boulder, 2018.
 - [17] N. Heess, D. TB, S. Sriram, J. Lemmon, J. Merel, G. Wayne, Y. Tassa, T. Erez, Z. Wang, S. M. A. Eslami, M. A. Riedmiller, and D. Silver. Emergence of locomotion behaviours in rich environments. *CoRR*, abs/1707.02286, 2017.
 - [18] D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton, Y. Chen, T. Lillicrap, F. Hui, L. Sifre, G. van den Driessche, T. Graepel, and D. Hassabis. Mastering the game of go without human knowledge. *Nature*, 550, 2017.

- [19] R. Furfaro, A. Scorsoglio, R. Linares, and M. Massari. Adaptive generalized zem-zev feedback guidance for planetary landing via a deep reinforcement learning approach. *Acta Astronautica*, 171:156–171, 2020.
- [20] B. Gaudet, R. Linares, and R. Furfaro. Deep reinforcement learning for six degrees of freedom planetary landing. *Advances in Space Research*, 65:1723–1741, 2020.
- [21] B. Gaudet, R. Furfaro, and R. Linares. Reinforcement learning for angle-only intercept guidance of maneuvering targets. *Aerospace Science and Technology*, 99, 2020.
- [22] D. Guzzetti. Reinforcement learning and topology of orbit manifolds for station-keeping of unstable symmetric periodic orbits. In *AAS/AIAA Astrodynamics Specialist Conference*, Portland, Maine, 2019.
- [23] J. A. Reiter and D. B. Spencer. Augmenting spacecraft maneuver strategy optimization for detection avoidance with competitive coevolution. In *20th AIAA Scitech Forum*, Orlando, Florida, 2020.
- [24] A. Das-Stuart, K. C. Howell, and D. C. Folta. Rapid trajectory design in complex environments enabled by reinforcement learning and graph search strategies. *Acta Astronautica*, 171:172–195, 2020.
- [25] D. Miller and R. Linares. Low-thrust optimal control via reinforcement learning. In *29th AAS/AIAA Space Flight Mechanics Meeting*, Ka’anapali, Hawaii, 2019.
- [26] C. J. Sullivan and N. Bosanac. Using reinforcement learning to design a low-thrust approach into a periodic orbit in a multi-body system. In *20th AIAA Scitech Forum*, Orlando, Florida, 2020.
- [27] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, Feb. 2015.
- [28] J. Schulman, S. Levine, P. Moritz, M. I. Jordan, and P. Abbeel. Trust region policy optimization. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 1889–1897, 2015.
- [29] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. P. Lillicrap, T. Harley, D. Silver, and K. Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In

- Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1928–1937, 2016. arXiv:1602.01783.
- [30] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning, 2019.
 - [31] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv preprint*, arXiv:1707.06347, 2017.
 - [32] S. Fujimoto, H. V. Hoof, and D. Meger. Addressing function approximation error in actor-critic methods. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 1587–1596, 2018.
 - [33] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 1861–1870, 2018.
 - [34] A. Kumar, A. Zhou, G. Tucker, and S. Levine. Conservative q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems 33 (NeurIPS)*, pages 1179–1191, 2020.
 - [35] K. Prudencio, J. L. Xiang, and A. T. Cemgil. A survey on offline reinforcement learning: Methodologies, challenges, and open problems. *arXiv preprint*, arXiv:2203.01387, 2022.
 - [36] J. Garc a and F. Fern ndez. A comprehensive survey on safe reinforcement learning. *Journal of Machine Learning Research*, 16(42):1437–1480, 2015.
 - [37] F. Ghazalpour, S. Samangouei, and R. Vaughan. Hierarchical reinforcement learning: A comprehensive survey. *ACM Computing Surveys*, 54(12):1–35, 2021.
 - [38] K. Song, J. Zhu, Y. Chow, D. Psomas, and M. Wainwright. A survey on multi-agent reinforcement learning: Foundations, advances, and open challenges. *IEEE Transactions on Neural Networks and Learning Systems*, 2024. In press, arXiv:2401.01234.
 - [39] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. V. D. Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe, J. Nham, N. Kalchbrenner, I. Sutskever, T. Lillicrap, M. Leach, K. Kavukcuoglu, T. Graepel, and D. Hassabis. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.

- [40] O. Vinyals, I. Babuschkin, W. Czarnecki, M. Mathieu, A. Dudzik, J. Chung, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- [41] L. Espeholt, H. Soyer, R. Munos, K. Simonyan, V. Mnih, T. Ward, Y. Doron, V. Firoiu, T. Harley, I. Dunning, S. Legg, and K. Kavukcuoglu. Impala: Scalable distributed deep-rl with importance weighted actor-learner architectures. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 1407–1416, 2018.
- [42] M. Tan. Multi-agent reinforcement learning: Independent vs. cooperative agents. In *Proceedings of the 10th International Conference on Machine Learning (ICML)*, pages 330–337, 1993.
- [43] L. Panait and S. Luke. Cooperative multi-agent learning: The state of the art. *Autonomous Robots*, 8(3):355–377, 2005.
- [44] L. Buşoniu, R. Babuška, and B. D. Schutter. A comprehensive survey of multiagent reinforcement learning. *IEEE Transactions on Systems, Man, and Cybernetics, Part C*, 38(2):156–172, 2008.
- [45] R. Lowe, Y. Wu, A. Tamar, J. Harb, P. Abbeel, and I. Mordatch. Multi-agent actor-critic for mixed cooperative-competitive environments. In *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pages 6379–6390, 2017.
- [46] P. Sunehag, G. Lever, A. Gruslys, W. Czarnecki, V. Zambaldi, M. Jaderberg, M. Lanctot, N. Sonnerat, J. Z. Leibo, K. Tuyls, and T. Graepel. Value-decomposition networks for cooperative multi-agent learning. In *Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems (AAMAS)*, 2018. arXiv:1706.05296.
- [47] T. Rashid, M. Samvelyan, C. S. de Witt, G. Farquhar, J. Foerster, and S. Whiteson. Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 4292–4301, 2018.
- [48] M. Samvelyan, T. Rashid, C. S. de Witt, G. Farquhar, J. Foerster, N. Nardelli, T. G. J. Rudner, and et al. The starcraft multi-agent challenge. *arXiv preprint*, arXiv:1902.04043, 2019.
- [49] K. Son, D. Kim, W. J. Kang, D. E. Hostallero, and Y. Yi. Qtran: Learning to factorize with transformation for cooperative multi-agent reinforcement learning.

- In *Proceedings of the International Conference on Machine Learning (ICML)*, pages 5887–5896, 2019.
- [50] A. Mahajan, T. Rashid, M. Samvelyan, and S. Whiteson. Maven: Multi-agent variational exploration. In *Advances in Neural Information Processing Systems 32 (NeurIPS)*, pages 7611–7622, 2019.
 - [51] T. Wang, Y. Jiang, T. Da, W. Zhang, and J. Wang. Roma: Multi-agent reinforcement learning with emergent roles. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, pages 9876–9886, 2020.
 - [52] K. Zhang, Z. Yang, and T. Başar. Multi-agent reinforcement learning: A selective overview of theories and algorithms. *Handbook of RL and Control*, 2021. arXiv:2106.05230.
 - [53] A. Mitriakov, P. Papadakis, J. Kerdreux, and S. Garlatti. Reinforcement learning based, staircase negotiation learning: Simulation and transfer to reality for articulated tracked robots. *IEEE Robotics & Automation Magazine*, 28(4):10–20, 2021.
 - [54] Y. Yu et al. Heterogeneous-agent reinforcement learning: An overview. *IEEE Transactions on Neural Networks and Learning Systems*, 2022. In press, arXiv:2203.00596.
 - [55] N. B. LaFarge, D. Miller, K. C. Howell, and R. Linares. Autonomous closed-loop guidance using reinforcement learning in a low-thrust, multi-body dynamical environment. *Acta Astronautica*, 186:1–23, 2021.
 - [56] D. Vallado and W. McClain. *Fundamentals of Astrodynamics and Applications*. Fundamentals of Astrodynamics and Applications. Microcosm Press, 2001.
 - [57] D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra, and M. Riedmiller. Deterministic policy gradient algorithms. In *International conference on machine learning*, pages 387–395. Pmlr, 2014.
 - [58] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, C. Citro, G. S. Corrado, A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas,

- O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, and X. Zheng. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. Software available from tensorflow.org.
- [59] S. Fujimoto, H. van Hoof, and D. Meger. Addressing function approximation error in actor-critic methods, 2018.
- [60] A. Paszke, S. Gross, S. Chintala, G. Chanan, E. Yang, Z. DeVito, Z. Lin, A. Desmaison, L. Antiga, and A. Lerer. Automatic differentiation in pytorch. *NeurIPS Autodiff Workshop*, 2017.
- [61] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *CoRR*, abs/1801.01290, 2018.
- [62] J. Achiam. Spinning Up in Deep Reinforcement Learning. *OpenAI*, 2018.
- [63] D. P. Kingma and J. Ba. Adam: A method for stochastic optimization, 2017.

Abstract

In this study, a robust guidance framework is presented for low-thrust spacecraft operating in multi-body dynamical environments (the Earth–Moon three-body system). The problem is formulated as a zero-sum differential game between a guidance agent (the spacecraft) and a disturbance agent (environmental uncertainties), and implemented using a centralized-training, decentralized-execution approach. In this vein, four continuous reinforcement-learning algorithms, DDPG, TD3, SAC, and PPO, are extended to their zero-sum multi-agent counterparts (MA-DDPG, MA-TD3, MA-SAC, and MA-PPO), and their training pipeline together with the network architectures is described in detail under a full-information setting. The algorithms are evaluated under diverse uncertainty scenarios, including random initial conditions, actuator disturbances, sensor noise, time delays, and model mismatch along a Lyapunov-orbit trajectory in the Earth–Moon system. The results clearly show that the zero-sum variants outperform their single-agent counterparts across all evaluation metrics. In particular, MA-TD3 preserves system stability while achieving the smallest trajectory deviation and the most efficient fuel consumption, even in the most challenging test scenarios. Ultimately, the proposed framework demonstrates that zero-sum differential-game-based multi-agent reinforcement learning can ensure adaptive and robust guidance for low-thrust spacecraft in the unstable regions of three-body systems without requiring precise modeling.

Keywords: Deep Reinforcement Learning, Differential Games, Multi-Agent Systems, Low-Thrust Guidance, Zero-Sum Games, Restricted Three-Body Problem, Robust Control.



Sharif University of Technology
Department of Aerospace Engineering

Master Thesis

Robust Reinforcement Learning Differential Game Guidance in Low-Thrust, Multi-Body Dynamical Environments

By:

Ali BaniAsad

Supervisor:

Dr. Hadi Nobahari

September 2025